

# Praca magisterska, wersja robocza

Hubert Guzera

2015-09-02

## Wprowadzenie

Wal-Mart, amerykański gigant handlowy, co godzinę umieszcza w swoich bazach danych 2.5 petabajtów danych, pochodzących z blisko miliona transakcji. I nie jest wyjątkiem - przeciętna ilość danych przechowywanych przez przedsiębiorstwa w Stanach Zjednoczonych jest większa niż zbiory Biblioteki Kongresu (szacowane na 235 terabajtów). W erze informacji większość z danych generowanych przez konsumentów trafia na serwery tej bądź innej firmy, w formie historii transakcji, koordynatu GPS czy zdjęcia.

Często informacje te zbierane są przypadkiem - ze względu na prowadzenie rachunkowości, specyfikę świadczonych usług, lub też względy archiwizacyjne. Jednak wydobyte z nich *wiedzy* może stanowić źródło znaczącej przewagi konkurencyjnej. Jak wskazują Brynjolfsson, Hitt i Kim [? ], przedsiębiorstwa podejmujące decyzje na podstawie analizy dużych zbiorów danych (*data driven decision making*) osiągają efektywność o 5-6 proc. większą niż grupa porównawcza. Mają także większy zwrot z kapitału i wycenę rynkową - jednym słowem, radzą sobie lepiej. Nic więc dziwnego, że coraz częściej data analytics staje się priorytetem wśród dużych spółek. Skalę popularności business intelligence uatracnia badanie PwC [? ], według którego 44 proc. CEO planuje oparcie rozwoju firmy o inwestycje w tej dziedzinie.

Ale dzisiejsze zastosowania *big data* to tylko preludium do tego, co czeka nas w przyszłości. Trwający równolegle trend robotyzacyjny spowoduje, że w ciągu 20 lat w przedsiębiorstwie zamiast kierowców możemy zarządzać flotą autonomicznych pojazdów, a magazynierów zastąpią roboty. Fakt, że Google i Daimler już testują takie auta nie pozwala na nazwanie tego science-fiction. Według Carla Freya i Michela Osborne'a z Uniwersytetu w Oxfordzie [? ], blisko 47 proc. miejsc pracy jest zagrożonych komputeryzacją. Większość z nich to zawody wykonujące rutynowe, mechaniczne czynności, ale postęp technologiczny powoduje, że na tej liście znajdują się też prace wymagające umiejętności kognitywnych i wnioskowania - jak pracownicy biurowi, analitycy czy operatorzy.

Jeśli więc w jednej strony mamy do czynienia z flotą autonomicznych pojazdów, z a drugiej z petabajtami informacji o tym gdzie i co kupują nasi klienci, możemy znaleźć się w sytuacji, gdzie koordynacja łańcucha dostaw będzie wykraczać poza możliwości człowieka. Dla komputera, wyprognozowanie popytu na podstawie danych i zaplanowanie dostaw nie będzie żadnym problemem.

Potwierdza to The McKinsey Global Institute [? ], który wskazuje, że coraz częściej maszyny będą zastępować ludzi w podejmowaniu decyzji i brać udział w sterowaniu przedsiębiorstwem.

W teorii, ze względu na możliwość przeprowadzania złożonych obliczeń i analizy gigabajtów danych, decyzje te będą trafniejsze i poprawią efektywność przedsiębiorstwa.

Niniejsza praca ma na celu skonfrontowanie tej hipotezy. Po pierwsze, poprzez zaproponowanie jednego z wielu możliwych algorytmów optymalizacji działania przedsiębiorstwa poprzez wykorzystanie istniejących technik *modelowania predykcyjnego*. Po drugie przez sprawdzenie, jak tak podejmowane decyzje będą wpływać na funkcjonowanie przedsiębiorstwa i czy będzie ono funkcjonować efektywniej, niż gdyby zastosować w nim dotychczasowe praktyki biznesowe.

## Spis treści

<b>1 Cel, założenia i podstawy teoretyczne pracy</b>	<b>4</b>
1.1 Koncepcja pracy . . . . .	4
1.2 Podstawy teoretyczne . . . . .	4
1.2.1 Przedsiębiorstwo jako system wieloagentowy . . . . .	4
1.2.2 Zadanie optymalizacyjne . . . . .	6
1.2.3 Modelowanie predykcyjne . . . . .	7
1.3 Proponowany algorytm optymalizacyjny . . . . .	9
<b>2 Model</b>	<b>12</b>
2.1 Koncepcja modelu . . . . .	12
2.2 Zastosowane narzędzia . . . . .	13
2.3 Struktura programu . . . . .	13
2.4 Generowanie mapy . . . . .	14
2.4.1 Algorytm wyszukiwania drogi . . . . .	15
2.5 Agenci, ich rodzaje i właściwości . . . . .	16
2.5.1 Konsumenci . . . . .	16
2.5.2 Przedsiębiorstwo . . . . .	17
2.5.3 Produkt . . . . .	17
2.5.4 Konkurencja . . . . .	17
2.6 Symulowanie decyzji konsumenckich . . . . .	18
<b>3 Efekty działania algorytmu optymalizacyjnego</b>	<b>19</b>
3.1 Charakterystyka badanego środowiska . . . . .	19
3.2 Przewidywanie decyzji konsumentów . . . . .	19
3.3 Wyniki przedsiębiorstwa przy braku optymalizacji . . . . .	19
3.4 Optymalizacja przy stałych cenach i braku efektu skali . . . . .	19
3.5 Optymalizacja przy stałych cenach i istnieniu efektu skali . . . . .	19
3.6 Optymalizacja przy zmiennych cenach i istnieniu efektu skali . . . . .	19

# 1 Cel, założenia i podstawy teoretyczne pracy

## 1.1 Koncepcja pracy

Praca ma na celu zaproponowanie algorytmu optymalizacji podejmowania decyzji w przedsiębiorstwie na podstawie modelowania predyktywnego oraz sprawdzenie, jak zaimplementowanie takiego algorytmu wpływa na efektywność firmy.

Przyjmując, że optymalizowane przedsiębiorstwo z sektora FMCG zajmuje zarówno produkcją, jak i dystrybucją towarów do sklepów detalicznych, będziemy starali się w prognozować w krótkiej perspektywie wolumen sprzedaży w każdym ze sklepów. Wykorzystaną wiedzę wykorzystamy do optymalizacji procesów logistycznych, tj. zbudowanie takich tras dostaw i alokację wśród nich wolumenów produktów, żeby zysk firmy był jak największy.

W celu zaprezentowania wyniku działania powstałego w ten sposób algorytmu, zostanie zbudowany model wieloagentowy symulujący rynek i zachowania klientów. Z jego pomocą sprawdzimy funkcjonowanie algorytmu w trzech przypadkach założeń:

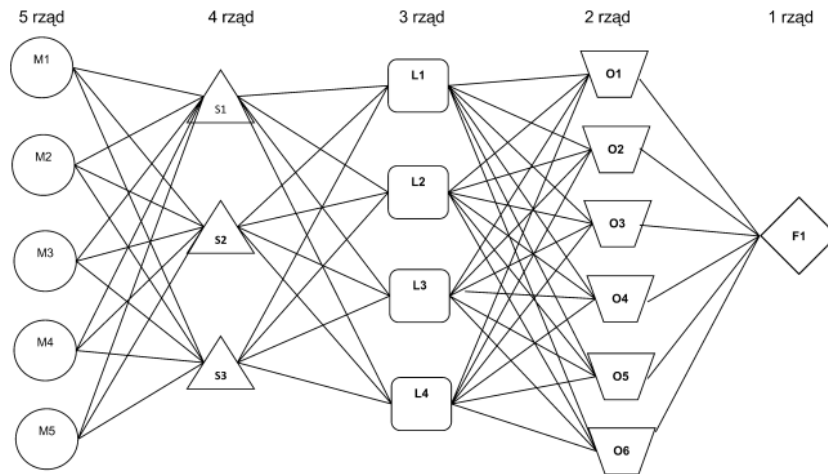
1. Cena produktu jest stała, a w łańcuchu produkcyjnym nie występują efekty skali
2. Cena produktu jest stała, a w łańcuchu produkcyjnym występują efekty skali
3. Cena produktu jest decyzją przedsiębiorstwa, a w łańcuchu produkcyjnym występują efekty skali

## 1.2 Podstawy teoretyczne

### 1.2.1 Przedsiębiorstwo jako system wieloagentowy

Na możliwość wykorzystania modeli wieloagentowych do badania i zarządzania systemami logistycznymi wskazują m.in. Moyaux et al, 2006 [?] czy Kawa, 2010 [?]. W swoich pracach zauważyli oni, że *producenci*, *dostawcy* i *odbiorcy* i inni uczestnicy łańcucha logistycznego mogą być opisani jako sieć autonomicznych, współpracujących ze sobą agentów. Takie podejście, i wynikająca z niego możliwość wykorzystania modeli wieloagentowych pomaga w rozwiązaniu problemów operacyjnych, na jakie wskazuje Moyaux [?]. Należy bowiem zwrócić uwagę, że w zakresie wyboru tras i zarządzania flotą wieloetapowe łańcuchy dostaw wielu produktów są problemami NP-trudnymi, szczególnie, że decyzje podejmowane lokalnie są współzależne.<sup>1</sup> Ponadto, jak zauważa Kawa, w sieci przedsiębiorstw pomiędzy dostawcami kolejnych rzędów (tj. fabryki, magazyny, sklepy) może istnieć wiele połączeń które są wobec siebie konkurencyjne, ponieważ jeden magazyn może zaopatrywać się w wielu fabrykach. Zastosowanie w tej dziedzinie modeli wieloagentowych pozwala więc na zbadanie, jak decyzje podejmowane na jednym z etapów łańcucha dostaw wpłyną na cały system i innych uczestników.

<sup>1</sup>W praktyce, decyzje podjęte na wczesnym etapie łańcucha rezonują na dalsze etapy, co Moyaux opisuje jako "bullwhip effect"



W niniejszej pracy stosowane jest rozszerzenie tego podejścia, poprzez zaprogramowanie jako agentów jednostek organizacyjnych przedsiębiorstwa (*fabryka, magazyn, sklep, zarząd*), które razem tworzą system (*przedsiębiorstwo*).

To podejście opiera się na obserwacji, że relacje pomiędzy jednostkami w przedsiębiorstwie są analogiczne do relacji uczestników łańcucha dostaw. Michael Porter zauważył, że działalność przedsiębiorstwa to de facto sekwencja działań, która na każdym ogniwie zwiększa wartość dla odbiorcy. W przypadku firmy mamy więc również do czynienia z opisanym przez Portera łańcuchem wartości (*value chain*). Ponieważ przedsiębiorstwa często dysponują wieloma duplikującymi swoje działania jednostkami <sup>2</sup>, łańcuch ten jest nieliniowy i w jego przypadku mamy do czynienia z podobnymi wyzwaniem co w łańcuchu logistycznym.

Zdefiniowanie jako agentów poszczególnych jednostek przedsiębiorstwa jest przy tym spójne z określoną przez Wooldridge i Jennings charakterystyką agenta, który według ich postulatów posiada :

- autonomię - poszczególne jednostki przedsiębiorstwa podążają za strategią i celami narzuconymi przez zarząd, ale mają zazwyczaj swobodę w podejmowaniu decyzji mających na celu ich realizację
- zdolności do komunikacji - jednostki przedsiębiorstwa komunikują się z otoczeniem (relacje z klientami) oraz między sobą (raportowanie do zarządu, spotkania), a w ramach pomiędzy jednostkami przedsiębiorstwa istnieje asymetria informacji
- reaktywność - jednostki przedsiębiorstwa reagują na zmiany rynkowe oraz zmiany wewnątrz przedsiębiorstwa
- proaktywność - jednostki przedsiębiorstwa podejmują inicjatywy mające na celu zwiększyć wartość przedsiębiorstwa, jak działalność innowacyjna

<sup>2</sup>Dobrym przykładem są tutaj zakłady samochodowe, które mogą produkować dany model w różnych krajach. Zmiana fabryki powoduje przy tym radykalną zmianę łańcucha dostaw

bądź ekspansja.

Dlatego w niniejszej pracy będziemy rozważać model wieloagentowy, w którym według założeń na przedsiębiorstwo składać się będzie szereg autonomicznych agentów,

- *fabryk*  $\in FA = \{fa_1, fa_2, fa_3..fa_m\}$
- *magazynów*  $\in MA = \{ma_1, ma_2, ma_3..ma_k\}$
- *sklepów*  $\in SK = \{sk_1, sk_2, sk_3..sk_i\}$
- *zarząd*, pełniący rolę centralnego koordynatora i przechowujący wszystkie powyższe  $\in ZA = \{FA, MA, SK\}$

przez które kolejno będzie musiał przejść produkt zanim będzie mógł być zakupiony przez klienta. Rozpatrując ten system w proponowanym przez Kawa, 2013 kontekście teorii grafów oznacza to, że łańcuch produkcyjny może składać się z  $m = \binom{n}{1} \times \binom{k}{1} \times \binom{i}{1}$  kombinacji  $d_m$  połączeń pomiędzy jednostkami przedsiębiorstwa. Jak zauważa Kawa, każde z tych połączeń będzie miało swoją maksymalną przepustowość oraz koszt  $k_d \in f[d]$ , będący sumą kosztów ponoszonych na każdym z ogniw łańcucha wartości. Na krańcach grafu może dojść do sprzedaży towaru i przychodu dla całego systemu - jednak zaopatrzenie sklepu w zbyt dużą ilość towaru doprowadzi do jego zmarnowania i strat.

### 1.2.2 Zadanie optymalizacyjne

Dlatego optymalizując działanie przedsiębiorstwa będziemy dążyć do tego, żeby dla danego poziomu produkcji  $x$  i zbioru *produktów*  $\in PR = \{pr_1, pr_2, pr_3..pr_x\}$  ze zbioru możliwych sterowań (możliwych tras)  $< d_1, d_2, d_3..d_m >$  dla każdego z produktów wybrać trasy maksymalizujący wyrażenie

$$\max \sum_{pr=1}^x \text{zysk}(cena, d) = \begin{cases} cena - k_d & \text{jeśli dokonano sprzedaży} \\ k_d & \text{jeśli nie dokonano sprzedaży} \end{cases} \quad (1)$$

$$\text{gdzie } k_d \in f[d] \wedge k_d < cena$$

To zadanie optymalizacyjne byłoby trywialne, gdybyśmy mieli doskonałą informację na temat poziomu sprzedaży w każdym ze sklepów w  $t + 1$ . Na taką wiedzę nie możemy liczyć ani w tej pracy, ani w rzeczywistości, dlatego rozwiązaniem proponowanym w niniejszej pracy jest zastosowanie modelowania predykcyjnego (predictive analytics), w celu prognozowania ilości klientów i ich wyborów w każdym ze sklepów w najbliższych okresach czasu.<sup>3</sup>

Ponadto, jak warto zauważyć, nie możemy liczyć na to, że  $k_d$  będzie linio-we. Wspominana przez Kawę maksymalna przepustowość każdego z łańcuchów,

<sup>3</sup>Obecnie w przedsiębiorstwach rzadko stosuje się zaawansowane sposoby prognozowania sprzedaży (*Predictive analytics*), a zarządzanie dostawami odbywa się raczej metodą manualnego uzupełniania zapasów.

która w przedsiębiorstwie będzie spowodowana ograniczonymi mocami produkcyjnymi, może spowodować, że funkcja kosztu będzie wykładnicza. W niektórych przypadkach mogą istnieć także korzyści skali, które spowodują, że funkcja będzie logarytmiczna, a całkiem realne jest istnienie obu tych efektów<sup>4</sup>, przez co musimy zakładać, że  $f(d)$  może być dowolną funkcją nieliniową.

Trzecim aspektem który trzeba wziąć pod uwagę jest złożoność obliczeniowa. Nawet dla prostego układu, lecz wolumenu produkcji ponad 1000 sztuk sprawdzenie zysku w przypadku wszystkich kombinacji alokacji wymaga olbrzymiej ilości iteracji. Mimo znaczącego wzrostu mocy komputerów w ostatnich latach, wolumeny produkcji w dużych przedsiębiorstwach oraz złożoność tras logistycznych sprawia, że to podejście jest kompletnie niepraktyczne.

Proponowany algorytm będzie brał wszystkie te aspekty pod uwagę, a pierwszy z wymienionych problemów rozwiążemy wykorzystując *modelowanie predykcyjne*.

### 1.2.3 Modelowanie predykcyjne

Jak wskazuje James, 2013, *modelowanie predykcyjne* zakładając, że dysponujemy zbiorem  $n$  obserwacji  $p$  zmiennych, możemy zbadać ich relację ze zmienną wyjaśnianą  $y$  i otrzymać *model*, który dla nowych - nieanalizowanych wcześniej - obserwacji  $x_1, x_2..x_n$  zwraca przewidywaną wartość zmiennej objaśnianej  $\hat{y}$ . Różnorodne metody dzięki którym możemy otrzymać  $\hat{y}$  James nazywa *Statistical learning* i może być wykorzystany do modelowania predykcyjnego, tj. przewidywania przyszłych wartości  $\hat{y}$ .

Zastosowanie metod *statistical learning* w przedsiębiorstwach potwierdza Buckinx, 2007, który wskazywał na możliwość prognozowania lojalności klienta na podstawie wewnętrznych danych o transakcjach, oraz Davenport, który w Harvard Business Review 12/2011 opisuje szereg *case studies* firm, w których wykorzystuje się istniejące dane o transakcjach do przewidywania przyszłych zakupów klientów. Jednym z podanych przez niego przykładów jest Tesco, które na podstawie zebranych danych przewiduje, jak będzie wyglądał koszyk zakupów klienta podczas następnych zakupów, i odpowiednio wcześniej wysyła mu bony zniżkowe.

To daje nam podstawy, żeby w przypadku optymalizowanego przedsiębiorstwa zakładać, że dane o każdej transakcji są zapisywane i poza podstawowymi informacjami (produkt, cena, data) zawierają one także dane o kliencie, a cały zbiór danych może być wykorzystany do przewidywania sprzedaży w  $t + 1$ . Dla każdej transakcji w sklepie dysponujemy więc zbiorem informacji  $X = n \times x_i = < tr_1..tr_k, pr_1..pr_k, kl_1..kl_k >$  gdzie  $tr$  to identyfikatory transakcji (miejsce, data, rodzaj płatności),  $pr$  to identyfikatory produktu (nazwa, cena, ilość) oraz  $kl$  to identyfikatory klienta (płeć, wiek, zarobki, wykształcenie etc.).

Na podstawie takiego zbioru danych chcemy przewidzieć popyt na produkty w każdym ze sklepów, co w praktyce oznacza konieczność stworzenia modelu estymującego -

<sup>4</sup>Korzyści skali odczuwalne do pewnego optymalnego poziomu produkcji, powyżej którego brak mocy produkcyjnych powoduje drastyczne powiększanie się kosztów krańcowych

- liczbę poszczególnych grup klientów <sup>5</sup> odwiedzających sklep w  $t + 1$ , gdzie  $\hat{y} \in R$

oraz w zależności od zastosowanego podejścia

- prawdopodobieństwo  $p$  z jakim klient o danej charakterystyce kupi produkt  $pr$ , gdzie  $\hat{y} \in (0, 1)$
- jaki produkt wybierze klient o danej charakterystyce, gdzie  $\hat{y} \in \{pr_1, pr_2..pr_n\}$ , a  $pr_i$  to dostępny produkt.

Jak wskazuje James, zmienna objaśniana  $\hat{y}$  może przyjąć formę liczby rzeczywistej, zmiennej binarnej (1/0), prawdopodobieństwa, *log odds* lub klasy, jednak ze względu na różne dziedziny  $\hat{y}$ , każdy z tych przypadków różni się metodami które możemy zastosować. Według sugestii James i Hastie, zastosujemy następujące metody

- do liczby klientów - regresję metodą OLS (*ordinary least squares, metoda najmniejszych kwadratów*)
- do prawdopodobieństwa zakupu - regresję logistyczną (*logistic regression*)
- do wyboru produktu- metody klasyfikacyjne - *k-means* oraz *drzewaklasyfikacyjne*

---

<sup>5</sup>Przez "poszczególne grupy klientów" rozumiemy klientów o wspólnej charakterystyce, czyli takich samych zestawach zmiennych identyfikujących  $\langle kl_1..kl_n \rangle$



### 1.3 Proponowany algorytm optymalizacyjny

Znając przewidywaną sprzedaż na krańcach grafu, proponowany w niniejszej pracy algorytm rozwiązania powyższego problemu opiera się na obserwacji, że równanie 1 będzie równoważne zapisowi sumującemu po możliwych kombinacjach łańcucha (zamiast dla każdego produktu z osobna).

$$\max \sum_{d=1}^m zysk(cena) = cena \times pr_d - k_d \times pr_d \quad (2)$$


gdzie  $pr_d$  to ilość produktów przechodzącym w danym łańcuchu

Ponieważ ścieżka  $d_m$  składa się z  $\langle fa_m, ma_m, sk_m \rangle$ , a koszt ponoszony na całej trasie będzie równie sumie kosztów ponoszonym na każdym z ogniw łańcucha, równanie 2 możemy zapisać jako

$$\max \sum_{d=1}^m zysk(cena) = cena \times pr_d - \left( \sum_{j=1}^m k_j \right) \times pr_d \quad (3)$$

gdzie  $k_j$  to koszty ponoszone na każdym z elementów łańcucha wartości (koszty produkcji, magazynowania, transportu, etc.). Te co do zasady są nam znane, więc zostaje nam znalezienie takich wartości  $pr_d$  i  $ceny$  (jeśli nie przyjmujemy założenia danej, stałej ceny) dla których firma będzie osiągać maksymalny zysk. Ze względu na występujące w przedsiębiorstwie współzależności oraz nieliniowość kosztów (korzyści skali) musimy cały układ rozważać łącznie.

Na przykładzie przedsiębiorstwa  $= \langle fa_1, ma_1, ma_2, sk_1, sk_2, sk_3 \rangle$  mamy do czynienia z  $m = \binom{1}{1} \times \binom{2}{1} \times \binom{3}{1} = 6$  kombinacji połączeń pomiędzy jednostkami przedsiębiorstwa, przy czym każdy do każdego ze sklepów można przeprowadzić dostawę jedną z dwóch tras.



Ponieważ przewidywany wolumen sprzedaży produktu w każdym z krańców grafu jest nam znana <sup>6</sup>, żeby umożliwić obliczenie optymalnego obłożenia każdej z tras prowadzącej do krańca grafu <sup>7</sup> możemy dla każdej z tras ilość przechodzących nią produktów zapisać jako

$$pr_1 = \alpha pr_{sk_1}, \quad pr_2 = \beta pr_{sk_1} \quad \dots \quad pr_{d-1} = \gamma pr_{sk_i}, \quad pr_d = \delta pr_{sk_i}$$

gdzie  $pr_{sk_d}$  to ilość produktów, jakie mają trafić do  $sk_d$  krańca grafu leżącego na trasie  $d$ , a  $\alpha, \beta, \dots, \delta$  to udział tej trasy w przepływie wszystkich towarów do danego krańca grafu. W ten sposób, równanie 3 możemy zapisać jako

$$\max \sum_{d=1}^m zysk(cena) = cena \times \alpha pr_{sk_d} - \left( \sum_{j=1} k_j \right) \times \alpha pr_{sk_d} \quad (4)$$

Co po rozwinięciu pozwoli nam na sprowadzeniu równania 4 do postaci

$$\begin{aligned} zysk(cena) = & \alpha (cena \times pr_{sk_1} - \left( \sum_{j=1} k_j \right) \times pr_{sk_1}) + \\ & \dots + \delta (cena \times pr_{sk_i} - \left( \sum_{j=1} k_j \right) \times pr_{sk_i}) \end{aligned} \quad (5)$$

jeśli przyjmujemy, że

$$\begin{aligned} a = & (cena \times pr_{sk_1} - \left( \sum_{j=1} k_j \right) \times pr_{sk_1}) \dots \\ ..b = & (cena \times pr_{sk_i} - \left( \sum_{j=1} k_j \right) \times pr_{sk_i}) \end{aligned}$$

otrzymamy w ten sposób wielomian, w którym współczynniki  $a, b$  są nam znane, a pary współczynników  $\alpha, \beta$  jednego krańca grafu muszą być mniejsze lub równe 1. <sup>8</sup>.

Możemy więc skorzystać więc z twierdzenia o ekstremach lokalnych funkcji wielu zmiennych z Sydsaeter, 2005, który stwierdza, że jeśli istnieją ekstrema globalne lub lokalne funkcji, to muszą być one położone w punktach stacjonarnych. Punktami stacjonarnymi są takie wartości zmiennych  $x_1, x_2, \dots, x_n$  dla których wszystkie pochodne pierwszego rzędu są równe 0.

Dlatego szukamy rozwiązań układu równań

<sup>6</sup>Zakładamy, że dzięki *Predictive analytics* na podstawie poprzednich obserwacji mamy dokładne prognozy dotyczące sprzedaży w  $t + 1$

<sup>7</sup>Żeby ograniczyć złożoność obliczeniową staramy się unikać pętli, która sprawdza każdą kombinację, zamiast tego szukając bardziej wyrafinowanych sposobów

<sup>8</sup>Warunkiem nie jest "równe 1", ponieważ może istnieć taki udział  $\alpha$  w przedziale  $< 0, 1 >$  powyżej którego przez nieliniowość funkcji kosztów dostawa może być nieopłacalna

$$\begin{aligned}\frac{\partial zysk}{\partial \alpha} &= 0 \\ \frac{\partial zysk}{\partial \beta} &= 0 \\ &\dots \\ \frac{\partial zysk}{\partial \delta} &= 0\end{aligned}$$

których rozwiązania

$$\begin{cases} \alpha_1 = \dots \\ \beta_1 = \dots \\ \delta_1 = \dots \end{cases} \quad \begin{cases} \alpha_2 = \dots \\ \beta_2 = \dots \\ \delta_2 = \dots \end{cases} \quad \dots \quad \begin{cases} \alpha_3 = \dots \\ \beta_3 = \dots \\ \delta_3 = \dots \end{cases}$$

będą określać możliwe punkty, w których *zysk* będzie przyjmował wartość największą. Ostatnim krokiem algorytmu będzie więc dla każdego zbioru punktów  $\{\alpha_1, \beta_1, \delta_1\} \dots \{\alpha_n, \beta_n, \delta_n\}$  sprawdzić wartość funkcji *zysk* w tych punktach i wybrać z nich wartość największą.<sup>9</sup>

---

<sup>9</sup>Wprawdzie możliwe jest także matematyczne wyznaczenie, czy w danym punkcie jest maksimum czy minimum i czy jest to maksimum/minimum globalne, jednak kroki które trzeba przy tym wykonać, m.in. obliczanie Hessianu, dodadzą niepotrzebnej złożoności obliczeniowej w sytuacji, gdy wartość najmniejszą z tego zbioru można sprawdzić szybką pętlą

## 2 Model

### 2.1 Koncepcja modelu

W ramach pracy zbudowany został model wieloagentowy, który symuluje lokalny rynek na wybrany produkt. W modelu agentami są

- **klienci**, których definiują unikalne cechy<sup>10</sup> wpływającą na podejmowane przez niego decyzje
- **przedsiębiorstwo**, sprzedające *produkt* na rynku. Przedsiębiorstwo przy tym ma złożoną strukturę, tj. zamiast działać jako indywidualny agent, składa się z współpracujących ze sobą agentów
  - fabryk
  - magazynów
  - sklepów
  - zarządu, pełniącego funkcje koordynującą
- **konkurencji**, również sprzedającej na rynku swoje produkty, ale pasywnej w stosunku do symulowanego przedsiębiorstwa.<sup>11</sup>
- **produktów**, które z oczywistych względów nie podejmują decyzji, jednak mają swoją charakterystykę wpływającą na decyzje innych agentów (przede wszystkim konsumentów) oraz przemieszczają się w ramach przedsiębiorstwa.

Żeby dobrze odwzorować kluczowy aspekt lokalizacji i drogi w łańcuchach dostaw, symulowany rynek jest osadzony w *wirtualnym mieście*, czyli każdy agent ma swoją lokalizację w macierzy o wymiarach  $x \times y$ . Lokalizacja wpływa na działania agenta - klient kupi produkt tylko w sklepie w pobliżu, a dostawa z magazynu do sklepu będzie tym droższa, im bardziej oddalone będą od siebie.

W każdej jednostce czasu  $t$  klienci z prawdopodobieństwem  $p$  będą potrzebować symulowany produkt, więc odwiedzając bliski sklep, wybiorą jeden z produktów oferowanych przez przedsiębiorstwo i konkurencję. Symulacja wyboru opiera się na danych o preferencjach konsumentckich zebranych w ankiecie na próbie 127 badanych. Ponieważ każdy konsument-agent ma swoje unikalne cechy, w symulowanym procesie wyboru metodą drzewa klasyfikacyjnego przyporządkowujemy wybór, jakiego prawdopodobnie dokonał by jego odpowiednik w świecie rzeczywistym.<sup>12</sup>

Ponieważ konsument wybiera produkt tylko z gamy dostępnych w sklepie, przed rozpoczęciem tury przedsiębiorstwo musi podjąć szereg decyzji o m.in.

<sup>10</sup>Są to między innymi wiek, zarobki, wykształcenie, zainteresowania - zostanie to dokładnie opisane w dalszej części pracy

<sup>11</sup>Tj. konkurencja nie zmienia decyzji podjętych przed rozpoczęciem gry, i w założeniu ma stanowić jedynie alternatywę dla konsumentów

<sup>12</sup>Oczywiście, o wiele lepsze byłoby oparcie pracy o prawdziwe historie transakcji, jednak jest to niemożliwe ze względu na dużą poufność tych danych

- poziomie produkcji
- wolumen dostaw do każdego ze sklepów
- rozdzieleniu wolumenów pomiędzy części przedsiębiorstwa <sup>13</sup>
- jaką trasą powinny zostać wysłane dostawy

Każda z tych decyzji będzie miała wpływ na przychody <sup>14</sup> oraz koszty firmy. Celem pracy jest zbudowanie algorytmu, który na podstawie dotychczasowej historii transakcji pozwoli symulowanemu przedsiębiorstwu przewidzieć potencjalną sprzedaż w czasie  $t + 1$  i ze zbioru możliwych sterowań (wyżej wymienionych decyzji)  $< u_{t+1} >$  wybierze takie, które będą maksymalizować zysk.

## 2.2 Zastosowane narzędzia

Model został zbudowany w języku programowania Python 2.7, z wykorzystaniem elementów języka R oraz następujących bibliotek:

Biblioteka	Źródło	Zastosowanie
Sympy	<a href="http://www.sympy.org">www.sympy.org</a>	Wykorzystanie do obliczeń symbolicznych
rpy2	<a href="http://rpy.sourceforge.net">rpy.sourceforge.net</a>	Uruchomienie poleceń języka R
scikit-learn	<a href="http://scikit-learn.org">scikit-learn.org</a>	Budowania drzew klasyfikacyjnych

Kod źródłowy programu dostępny jest pod adresem [github.com/hubertguzera/master-thesis](https://github.com/hubertguzera/master-thesis)

## 2.3 Struktura programu

Program podzielony jest na trzy części. Pierwsza odpowiada za stworzenie, w drodze losowań, środowiska w ramach którego toczy się symulacja, wraz z agentami i macierzą lokalizacji. <sup>15</sup>

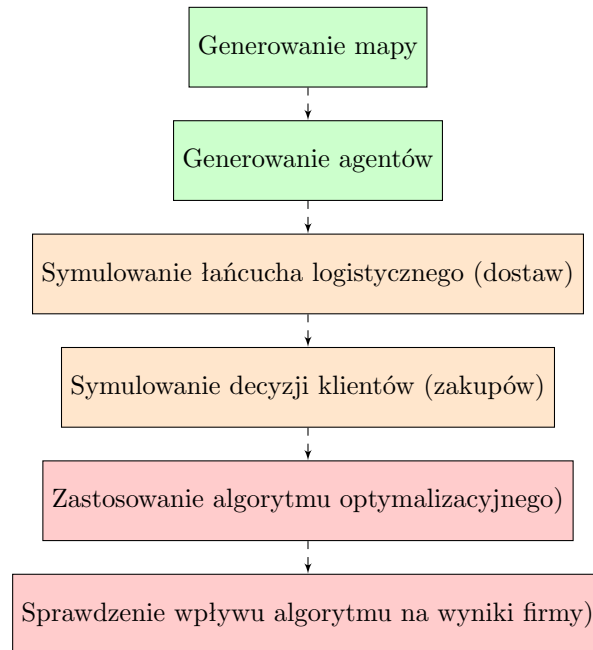
Druga część przez  $t_n$  jednostek czasu egzekwuje decyzje podjęte przez przedsiębiorstwo i symuluje zachowania konsumentów, zwracając na koniec wyniki (przychody i zysk) przedsiębiorstwa w danej jednostce czasu  $t$ .

Trzecia po  $t_n$  rund symulacji aplikuje algorytm optymalizacyjny, który poprzez prognozowanie sprzedaży na krańcach grafu w  $t_{n+1}$ , szuka najlepszych decyzji o alokacji produktów.

<sup>13</sup>Tj. ile z całkowitego wolumenu ma wyprodukować fabryka  $A$ , a ile fabryka  $B$

<sup>14</sup>Przy założeniu stałej ceny, będą to przede wszystkim *utraczone koszty* w przypadku wyczerpania się zapasów w sklepie

<sup>15</sup>Model może pominąć ten część i wczytać pregenerowany świat w celu sprawdzenia różnych scenariuszy w statycznym świecie (*ceteris paribus*).



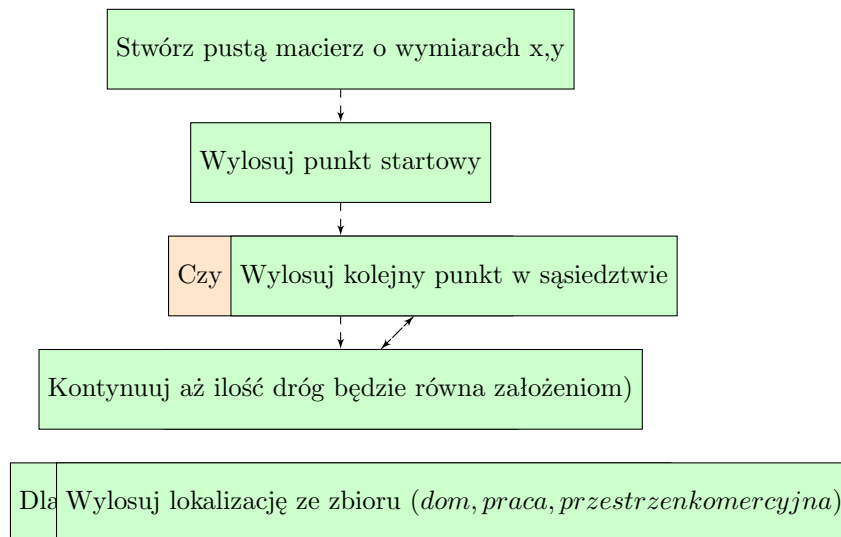
## 2.4 Generowanie mapy

W celu odpowiedniego odwzorowania kluczowego aspektu lokalizacji i dróg w łańcuchach dostaw, a przy tym wzorując się na podejściu !!!, agenci osadzeni są w przestrzeni, reprezentowaną przez macierz klas o wymiarach  $(x,y)$ . Dodatkowo, lokalizacje będą połączone drogami, wymuszając na agentach poruszanie się tylko w obrębie ścieżek. Dzięki temu, w modelu będziemy mogli wiernie odwzorować wpływ odległości i wyboru trasy na efektywność procesów logistycznych, oraz zależność wyników sklepu od zamieszkującej okolicę populacji.

Każdy element macierzy mapa o wymiarach  $(x,y)$  jest instancją klasy lokalizacja o następujących właściwościach

Zmienna	Dziedzina	Opis
x	integer	Współrzędna x w macierzy $[x,y]$
y	integer	Współrzędna y w macierzy $[x,y]$
typ	string	Opis typu posesji
droga	[integer,integer]	Współrzędne drogi dojazdowej - potrzebne do algorytmu wyszukiwania drogi

które generowane są według algorytmu



Każda mapa wygenerowana przez program spełniać będzie następujące założenia

- Drogi krzyżują się i skręcają tylko pod kątem prostym. Poza skrzyżowaniami, drogi nie mają w sąsiedztwie innych dróg
- Inne lokalizacje (domy, sklepy etc.) mogą występować tylko w bezpośrednim sąsiedztwie drogi
- Drogi stanowią ciągłą linię, dzięki czemu nie ma punktu, do którego nie dałoby się dojechać z dowolnego miejsca startowego
- W regionie 2 punktów od skraju mapy nie są generowane ani drogi, ani lokalizacje <sup>16</sup>
- Gęstość sieci dróg oraz prawdopodobieństwo występowania zakrętów jest predefiniowana przez użytkownika

#### 2.4.1 Algorytm wyszukiwania drogi

Odległości pomiędzy zadanymi punktami w modelu są wyszukiwane dynamicznie, na podstawie algorytmu wyszukiwania drogi i zliczaniu ilości punktów w zwracanym przez niego łańcuchu. Algorytm oparty jest na metodach wyszukiwania ścieżek w grafach, dzięki założeniu, że każdy droga o współrzędnej (x,y)

<sup>16</sup> Jest to zabezpieczenie algorytmu, który w odległości 2 pkt od skraju mapy ma 0 proc. szansy na poprowadzenie ścieżki dalej - ponieważ w przypadku iterowania na skrajach mapy niektóre funkcje (jak sprawdzenie sąsiadujących punktów) mogą odnieść się do współrzędnych poza mapą, powodując błąd programu

na mapie jest punktem grafu, który może sąsiadować z punktami o współrzędnych  $(x-1,y), (x+1,y), (x,y+1), (x,y-1)$  <sup>17</sup>, o ile również są drogami. Informacje o punktach i sąsiadujących przechowywane są w zmiennej `nodes`, która jest słownikiem, dla każdego klucza - punktu na mapie - przechowuje informacje o sąsiadujących punktach, np.  $(3,2) = [(3,3)(4,3)]$ . <sup>18</sup>

Algorytm ma następujące cechy

- jest rekurencyjny
- nie jest losowy
- nie gwarantuje znalezienia najkrótszej trasy
- działa według następującego schemtu.

## 2.5 Agenci, ich rodzaje i właściwości

### 2.5.1 Konsumenci

Idąc za Kamiński, w modelu stosujemy modelowanie rynku za pomocą heterogeniczne konsumentów. Stąd, każdy z konsumentów ma swoją unikalną charakterystykę, która wpływa na jego wybory. Ponadto, ponieważ każdy klient ma przypisany dom, pracę i znajomych i mieszka w towarzystwie osób sobie podobnych <sup>19</sup>, pula lokalizacji w ramach których się porusza się zamknięta. Dzięki temu, odzwierciedlamy zjawisko ze świata rzeczywistego, że konsumenci zazwyczaj robią zakupy w ograniczonej liczbie sklepów będących po drodze bądź niedaleko. Jest to bardzo istotny warunek funkcjonowania modelu, ponieważ losowy dobór klientów uniemożliwiłby modelowanie predykcyjne.

Każdy będzie definiowany w klasie o następujących właściwościach

Zmienna	Dziedzina	Opis
---------	-----------	------

Wartości dla każdego z konsumentów są losowane niezależnie na podstawie rozkładów publikowanych przez Główny Urząd Statystyczny oraz danych firmy Sedlak&Sedlak <sup>20</sup> w celu zagwarantowania odzwierciedlenia struktury społeczeństwa. Ze względu na zastosowanie prawdopodobieństw warunkowych dla niektórych cech (np. zarobki są zależne od wykształcenia) istnieje pomiędzy nimi współliniowość. <sup>21</sup>

<sup>17</sup>Punkty  $(x-1,y-1), (x+1,y-1), (x+1,y+1), (x-1,y+1)$  wykluczamy przez wcześniejsze założenie, że drogi krzyżują się tylko pod kątem prostym

<sup>18</sup>Pewnym ograniczeniem jest, że jako punkty grafu definiujemy tylko drogi, tak więc szukając trasy z punktu A do punktu B de facto szukamy trasy z drogi przy punkcie A do drogi przy punkcie B.

<sup>19</sup>Jest to założenie inspirowanie !!!, i osiągnęte w podobny sposób - po wstępnej alokacji konsumentów do lokalizacji przeprowadzamy  $n$  rund, w których jest szansa na przeprowadzkę do miejsca o bardziej podobnym profilu mieszkańców

<sup>20</sup>Raporty firmy Sedlak&Sedlak służyły do zbudowania tabeli prawdopodobieństwa wystąpienia danego wynagrodzenia w zależności od płci i wykształcenia. Reszta danych oparta na GUS

<sup>21</sup>Chociaż współliniowość może być problemem przy modelowaniu, będziemy sobie z nią radzić na późniejszym etapie



## Przykładowe rozkłady cech konsumentów

### 2.5.2 Przedsiębiorstwo

Jak wskazano w rozdziale 1, przedsiębiorstwo nie jest modelowane jako jedna jednostka, a zamiast tego stosowane jest podejście wieloagentowe - każda z jednostek organizacyjnych jest samodzielnym, niezależnym agentem. Stąd, klasa firma jest tylko klasą przechowującą dane o wszystkich jednostkach wchodzących w skład przedsiębiorstwa, z następującymi właściwościami.

Zmienna    Dziedzina    Opis

Fabryki, magazyny i sklepy mają wspólnych zestaw cech podstawowych  
!!!

przy czym sklepy mają dodatkowe zmienne i funkcje przechowujące informacje o inwentarzu, klientach odwiedzających sklep w danej jednostce czasu  $t$  oraz historii transakcji -

!!!

### 2.5.3 Produkt

Opierając się na argumentacji, wedle którego każdy produkt charakteryzuje się cechami wpływającymi na prawdopodobieństwo jego zakupu przez konsumentów, nasz produkt definiujemy przez zestaw dowolnych cech, definiowanych jako *factors*, skalę ocen bądź zmienne binarne, które odróżniają go od produktów konkurencji.<sup>22</sup> Produkt jest więc klasą przechowującą jednowymiarową macierz z cechami produktu  $[x_1, x_2, x_3]$

### 2.5.4 Konkurencja

W założeniach przyjmujemy, że konkurencja jest pasywna - tj. nie podejmuje działań ani decyzji w trakcie trwania symulacji. Wynika to z odmiennego celu badania, którym jest analiza działania algorytmów optymalizacyjnych - nagle zmiany sprzedaży spowodowane np. obniżeniem ceny przez konkurencję spowodowałyby wątpliwości interpretacyjne i są zbędne. Konkurencja jest za to potrzebna do stworzenia alternatywnych dla symulowanego produktu, o odmiennych cechach i przyciągających klientów o specyficznych charakterystykach.

---

<sup>22</sup>Ich istotność nie jest w tym momencie ważna, ponieważ nawet jeśli w zbiorze znajdzie się cecha mająca mały wpływ na decyzje konsumentów, zostanie ona wyeliminowana na etapie tworzenia modelu bądź drzewa klasyfikacyjnego ze względu na brak istotności statystycznej współczynnika

## 2.6 Symulowanie decyzji konsumenckich

W rozważanym modelu decyzje agentów-konsumentów oparte są na następujących założeniach

- Konsumenty są heterogeniczni
- Różne grupy klientów będą inaczej oceniać cechy produktów
- Dla każdego produktu możemy wyznaczyć prawdopodobieństwo zakupu produktu, będącego funkcją preferencji konsumenta i cech produktu

### 3 Efekty działania algorytmu optymalizacyjnego

- 3.1 Charakterystyka badanego środowiska
- 3.2 Przewidywanie decyzji konsumentów
- 3.3 Wyniki przedsiębiorstwa przy braku optymalizacji
- 3.4 Optymalizacja przy stałych cenach i braku efektu skali
- 3.5 Optymalizacja przy stałych cenach i istnieniu efektu skali
- 3.6 Optymalizacja przy zmiennych cenach i istnieniu efektu skali

### Literatura