



SZKOŁA GŁÓWNA HANDLOWA W WARSZAWIE
WARSAW SCHOOL OF ECONOMICS

Studium magisterskie

Kierunek: Finanse i Rachunkowość

Specjalność: Finanse przedsiębiorstw

Forma studiów: stacjonarne

Imię i nazwisko: Hubert Guzera

Nr albumu: 61816

<tytuł>

Praca magisterska napisana

w Kolegium Analiz Ekonomicznych

w Katedrze Matematyki i Ekonomii Matematycznej

pod kierunkiem naukowym

dr hab. Michała Ramszy

Warszawa 2015

Spis treści

| | | |
|----------|--|-----------|
| 1 | Wprowadzenie | 5 |
| 2 | Cel, założenia i podstawy teoretyczne pracy | 7 |
| 2.1 | Koncepcja pracy | 7 |
| 2.2 | Podstawy teoretyczne | 7 |
| 2.2.1 | Przedsiębiorstwo jako system wieloagentowy | 7 |
| 2.2.2 | Zadanie optymalizacyjne | 10 |
| 2.2.3 | Modelowanie predykcyjne | 11 |
| 2.3 | Proponowany algorytm optymalizacyjny | 14 |
| 3 | Model | 17 |
| 3.1 | Koncepcja modelu | 17 |
| 3.2 | Zastosowane narzędzia | 20 |
| 3.3 | Struktura programu | 20 |
| 3.4 | Generowanie środowiska modelu | 20 |
| 3.4.1 | Algorytm wyszukiwania drogi | 24 |
| 3.5 | Agenci, ich rodzaje i właściwości | 26 |
| 3.5.1 | Konsumenci | 26 |
| 3.5.2 | Przedsiębiorstwo | 28 |
| 3.5.3 | Produkt | 31 |
| 3.5.4 | Konkurencja | 32 |
| 3.5.5 | Trasy | 32 |
| 3.6 | Symulowanie decyzji konsumenckich | 33 |
| 4 | Efekty działania algorytmu optymalizacyjnego | 34 |
| 4.1 | Charakterystyka badanego środowiska | 34 |
| 4.2 | Przewidywanie decyzji konsumentów | 36 |
| 4.3 | Wyniki przedsiębiorstwa przy braku optymalizacji | 38 |
| 4.4 | Optymalizacja przy stałych cenach i braku efektu skali | 38 |
| 4.5 | Optymalizacja przy stałych cenach i istnieniu efektu skali | 38 |
| 5 | Rysunki i tablice | 41 |

| | |
|---|-----------|
| A Dodatek: Ważne rzeczy do dodania | 43 |
| Lista tablic | 46 |
| Lista rysunków | 47 |
| Streszczenie | 48 |

1 Wprowadzenie

Wal-Mart, amerykański gigant handlowy, co godzinę umieszcza w swoich bazach danych 2.5 petabajtów danych, pochodzących z blisko miliona transakcji (The Economist (2010)). I nie jest wyjątkiem — przeciętna ilość danych przechowywanych przez przedsiębiorstwa w Stanach Zjednoczonych jest większa niż zbiory Biblioteki Kongresu (szacowane na 235 terabajtów (McKinsey Global Institute (2011))). W erze informacji większość z naszych działań trafia na serwery tej bądź innej firmy, w formie historii transakcji, koordynatu GPS czy zdjęcia.

Często informacje te zbierane są przypadkiem — ze względu na prowadzenie rachunkowości, specyfikę świadczonych usług, lub też względy archiwizacyjne. Jednak wydobywanie z nich *wiedzy* może stanowić źródło znaczącej przewagi konkurencyjnej. Jak wskazują Brynjolfsson et al. (2011), przedsiębiorstwa podejmujące decyzje na podstawie analizy dużych zbiorów danych (*data driven decision making*) osiągają efektywność o 5-6 proc. większą niż grupa porównawcza. Mają także większy zwrot z kapitału i wycenę rynkową — jednym słowem, radzą sobie lepiej. Nic więc dziwnego, że coraz częściej *data analytics* staje się priorytetem wśród dużych spółek. Skalę popularności *business intelligence* unaocznia badanie PwC (2014), według którego 44 proc. prezesów zarządu planuje oparcie rozwoju firmy o inwestycje w tej dziedzinie.

Ale dzisiejsze zastosowania *big data* to tylko preludium do tego, co czeka nas w przyszłości. Trwający równolegle trend robotyzacyjny spowoduje, że w ciągu 20 lat w przedsiębiorstwie zamiast kierowców możemy zarządzać flotą autonomicznych pojazdów, a magazynierów zastąpią roboty. Fakt, że Google i Daimler już testują takie auta nie pozwala na nazwanie tego science-fiction. Według Carla Freya i Michela Osborne’a z Uniwersytetu w Oxfordzie Frey i Osborne (2013), blisko 47 proc. miejsc pracy jest zagrożonych komputeryzacją. Większość z nich to zawody wykonujące rutynowe, mechaniczne czynności, ale postęp technologiczny powoduje, że na tej liście znajdują się też prace wymagające umiejętności kognitywnych i wnioskowania — jak pracownicy biurowi, analitycy czy operatorzy.

Jeśli więc z jednej strony mamy do czynienia z flotą autonomicznych pojazdów, z drugiej z petabajtami informacji o tym gdzie i co kupują nasi klienci, możemy znaleźć się w sytuacji, gdzie koordynacja łańcucha dostaw będzie wykraczać poza możliwości

człowieka. Dla komputera, wyprognozowanie popytu na podstawie danych i zaplanowanie dostaw nie będzie żadnym problemem. Potwierdza to The McKinsey Global Institute (2011), który wskazuje, że coraz częściej maszyny będą zastępować ludzi w podejmowaniu decyzji i brać udział w sterowaniu przedsiębiorstwem.

W teorii, ze względu na możliwość przeprowadzania złożonych obliczeń i analizy gigabajtów danych, decyzje te będą trafniejsze i poprawią efektywność przedsiębiorstwa.

Niniejsza praca ma na celu skonfrontowanie tej hipotezy. Po pierwsze, poprzez proponowanie jednego z wielu możliwych algorytmów optymalizacji działania przedsiębiorstwa poprzez wykorzystanie istniejących technik *modelowania predykcyjnego*. Po drugie przez sprawdzenie, jak tak podejmowane decyzje będą wpływać na funkcjonowanie przedsiębiorstwa i czy będzie ono funkcjonować efektywniej, niż gdyby zastosować w nim dotychczasowe praktyki biznesowe.

2 Cel, założenia i podstawy teoretyczne pracy

Praca ma na celu zaproponowanie algorytmu optymalizacji podejmowania decyzji w przedsiębiorstwie na podstawie modelowania predyktywnego oraz sprawdzenie w modelu wieloagentowym, jak zaimplementowanie takiego algorytmu wpływa na wyniki firmy .

2.1 Koncepcja pracy

Przyjmując, że optymalizowane przedsiębiorstwo z sektora szybko zbywalnych towarów konsumpcyjnych (*fast moving consumer goods, FMCG*) zajmuje się zarówno produkcją, jak i dystrybucją towarów do sklepów detalicznych, na podstawie historycznych danych o transakcjach i zastosowania modelowania predyktywnego prognozowany będzie krótko-terminowy wolumen sprzedaży w każdym z prowadzonych sklepów. Otrzymana wiedza zostanie wykorzystana do optymalizacji procesów logistycznych, co rozumiane jest przez zbudowania takich tras dostaw i alokację wśród nich wolumenów produktów, żeby zysk firmy był jak największy.

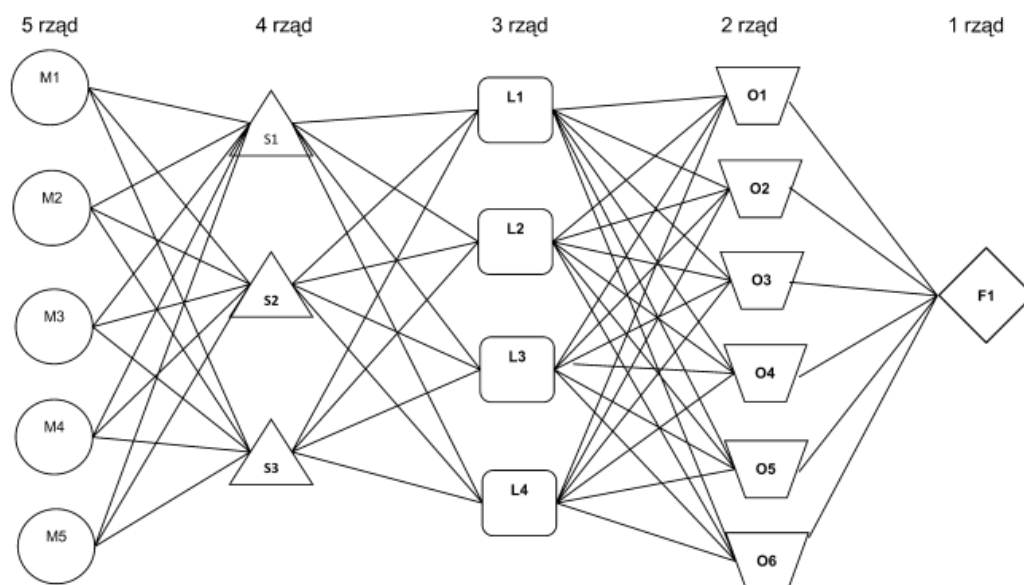
W celu zaprezentowania wyniku działania powstałego w ten sposób algorytmu, zostanie zbudowany model wieloagentowy symulujący rynek i zachowania klientów. Z jego pomocą sprawdzimy funkcjonowanie algorytmu w trzech przypadkach założeń:

1. cena produktu jest stała, a w łańcuchu produkcyjnym nie występują efekty skali,
2. cena produktu jest stała, a w łańcuchu produkcyjnym występują efekty skali,
3. cena produktu jest decyzją przedsiębiorstwa, a w łańcuchu produkcyjnym występują efekty skali.

2.2 Podstawy teoretyczne

2.2.1 Przedsiębiorstwo jako system wieloagentowy

Na możliwość wykorzystania modeli wieloagentowych do badania i zarządzania systemami logistycznymi wskazują m.in. Moyaux et al. (2006) czy Kawa (2010). W swoich pracach zauważyli oni, że *producenci*, *dostawcy* i *odbiorcy* i inni uczestnicy łańcucha logistycznego mogą być opisani jako sieć autonomicznych, współpracujących ze sobą



Wykres 1: Przykładowa sieć relacji w łańcuchu logistycznym

agentów, jak pokazane zostało to na wykres 1. Takie podejście, i wynikająca z niego możliwość wykorzystania modeli wieloagentowych pomaga w rozwiązaniu problemów operacyjnych, na jakie wskazuje Kawa (2010). Należy bowiem zwrócić uwagę, że w zakresie wyboru tras i zarządzania flotą wieloetapowe łańcuchy dostaw wielu produktów są problemami NP-trudnymi, szczególnie, że decyzje podejmowane lokalnie są współzależne.¹ Ponadto, jak zauważa Kawa (2010), w sieci przedsiębiorstw pomiędzy dostawcami kolejnych rzędów (tj. fabryki, magazyny, sklepy) może istnieć wiele połączeń które są wobec siebie konkurencyjne, ponieważ jeden magazyn może zaopatrywać się w wielu fabrykach. Zastosowanie w tej dziedzinie modeli wieloagentowych pozwala więc na zbadanie, jak decyzje podejmowane na jednym z etapów łańcucha dostaw wpłyną na cały system i innych uczestników.

W niniejszej pracy stosowane jest rozszerzenie tego podejścia, poprzez zaprogramowanie jako agentów jednostek organizacyjnych przedsiębiorstwa (*fabryka, magazyn, sklep, zarząd*), które razem tworzą system (*przedsiębiorstwo*).

To podejście opiera się na obserwacji, że relacje pomiędzy jednostkami w przedsiębiorstwie są analogiczne do relacji uczestników łańcucha dostaw. Porter (1985) zauważył, że działalność przedsiębiorstwa to de facto sekwencja działań, która na każdym ogniwie

¹Decyzje podjęte na krańcowych etapach łańcucha wpływają na wcześniejsze lub późniejsze etapy, co Moya et al. (2006) opisuje jako m.in. "bullwhip effect"

zwiększa wartość dla odbiorcy. Zasady funkcjonowania opisywanego przez Portera *łańcucha wartości* są identyczne co do opisywanego przez Moyaux et al. (2006) i Kawa (2010) łańcucha dostaw a relacje pomiędzy nimi można przedstawić w sposób zaproponowany przez Kawa (2010) — sieci neuronowej widocznej na wykresie 1. Podobieństwo to podkreśla fakt, że przedsiębiorstwa poprzez strategię *integracji wertykalnej* swym zasięgiem mogą w rzadkich przypadkach objąć całość łańcucha dostaw.

Ponieważ przedsiębiorstwa często dysponują wieloma duplikującymi swoje działania jednostkami ², łańcuch ten jest nieliniowy i w jego przypadku mamy do czynienia z podobnymi wyzwaniami co w łańcuchu logistycznym.

Zdefiniowanie jako agentów poszczególnych jednostek przedsiębiorstwa jest przy tym spójne z określoną przez Wooldridge i Jennings (1995) charakterystyką agenta, który według ich postulatów posiada :

- autonomię — poszczególne jednostki przedsiębiorstwa podążają za strategią i celami narzuconymi przez zarząd, ale mają zazwyczaj swobodę w podejmowaniu decyzji mających na celu ich realizację,
- zdolności do komunikacji — jednostki przedsiębiorstwa komunikują się z otoczeniem (relacje z klientami) oraz między sobą (raportowanie do zarządu, spotkania), a w ramach pomiędzy jednostkami przedsiębiorstwa istnieje asymetria informacji,
- reaktywność — jednostki przedsiębiorstwa reagują na zmiany rynkowe oraz zmiany wewnątrz przedsiębiorstwa,
- proaktywność — jednostki przedsiębiorstwa podejmują inicjatywy mające na celu zwiększyć wartość przedsiębiorstwa, jak działalność innowacyjna bądź ekspansja.

Dlatego w niniejszej pracy będziemy rozważać model wieloagentowy, w którym według założeń na przedsiębiorstwo składać się będzie szereg autonomicznych agentów,

- $n \text{ fabryk} \in FA = \{fa_1, fa_2, fa_3..fa_m\}$
- $k \text{ magazynów} \in MA = \{ma_1, ma_2, ma_3..ma_k\}$

²Dobrym przykładem są tutaj zakłady samochodowe, które mogą produkować dany model w różnych krajach. Zmiana fabryki powoduje przy tym radykalną zmianę łańcucha dostaw

- i sklepów $\in SK = \{sk_1, sk_2, sk_3..sk_i\}$
- oraz *zarządu*, pełniący rolę centralnego koordynatora

przez które kolejno będzie musiał przejść produkt zanim będzie mógł być zakupiony przez klienta. Rozpatrując ten system w proponowanym przez Kawa (2010) kontekście teorii grafów oznacza to, że w przedsiębiorstwie istnieć będzie m łańcuchów dostaw d , których ilość będzie równa $\binom{n}{1} \times \binom{k}{1} \times \binom{i}{1}$ kombinacji połączeń pomiędzy jednostkami przedsiębiorstwa. Jak zauważa Kawa (2010), każde z tych połączeń będzie miało swoją maksymalną przepustowość oraz koszt $k_d = f(d)$, zależny od łańcucha i będący sumą kosztów ponoszonych na każdym z ogniw łańcucha wartości. Na krańcach grafu może dojść do sprzedaży towaru i przychodu dla całego systemu — jednak zaopatrzenie sklepu w zbyt dużą ilość towaru doprowadzi do jego zmarnowania i strat.

2.2.2 Zadanie optymalizacyjne

Optymalizując działanie przedsiębiorstwa będziemy dążyć do tego, żeby dla danego poziomu produkcji x i zbioru *produktów* $PR = \{pr_1, pr_2, pr_3..pr_x\}$ ze zbioru możliwych sterowań (możliwych tras dostawy) $< d_1, d_2, d_3..d_m >$ dla każdego z produktów wybrać trasy maksymalizujące wyrażenie

$$\max \sum_{pr=1}^x zysk(p, d) = p \times q - k_d \quad (1)$$

gdzie $k_d = f(d)$, p to cena, d to wybrana droga
a q to sprzedaż zapisana jako zmienna binarna

Ponieważ kluczowym elementem powyższego równania jest zmienna q i to, czy przyjmie wartość 1 czy 0 ³ to zadanie optymalizacyjne byłoby względnie proste, gdybyśmy mieli doskonałą informację na temat poziomu sprzedaży w każdym ze sklepów w chwili $t + 1$. Na taką wiedzę nie możemy liczyć ani w tej pracy, ani w rzeczywistości, dlatego rozwiązaniem proponowanym w niniejszej pracy jest zastosowanie modelowania predyk-

³Zmienna przyjmuje wartość 1 jeśli towar znalazł nabywcę i 0 jeśli nie został sprzedany, tak więc dla niesprzedanych towarów przedsiębiorstwo odnotuje koszty bez przychodów.

cyjnego (*predictive analytics*), w celu prognozowania liczby klientów i ich wyborów w każdym ze sklepów w najbliższych okresach czasu.⁴

Ponadto, jak warto zauważyć, nie możemy liczyć na to, że funkcja kosztu k_d będzie liniowa. Wspominana przez Kawa (2010) maksymalna przepustowość każdego z łańcuchów, która w przedsiębiorstwie będzie spowodowana ograniczonymi mocami produkcyjnymi, może spowodować, że funkcja kosztu będzie funkcją wypukłą⁵. W niektórych przypadkach mogą istnieć także korzyści skali, które spowodują, że funkcja będzie funkcją wklęsłą, a całkiem realne jest istnienie obu tych efektów⁶, przez co musimy zakładać, że $f(d)$ może być dowolną funkcją nieliniową.

Trzecim aspektem który trzeba wziąć pod uwagę jest złożoność obliczeniowa. Nawet dla prostego układu, lecz wolumenu produkcji ponad 1000 sztuk sprawdzenie zysku w przypadku wszystkich kombinacji alokacji wymaga olbrzymiej ilości iteracji. Mimo znaczącego wzrostu mocy komputerów w ostatnich latach, wolumeny produkcji w dużych przedsiębiorstwach oraz złożoność tras logistycznych sprawia, że to podejście jest kompletnie niepraktyczne i należy szukać alternatywnych podejść, upraszczających problem.

Proponowany algorytm będzie brał wszystkie te aspekty pod uwagę, a pierwszy z wymienionych problemów rozwiążemy wykorzystując *modelowanie predykcyjne*.

2.2.3 Modelowanie predykcyjne

Jak wskazuje James et al. (2013), zakładając, że dysponujemy zbiorem n obserwacji p zmiennych, możemy zbadać ich relację ze zmienną wyjaśnianą y i otrzymać *model*, który dla nowych - nieanalizowanych wcześniej - obserwacji $x_1, x_2 \dots x_n$ zwraca przewidywaną wartość zmiennej objaśnianej \hat{y} . Różnorodne metody dzięki którym możemy otrzymać zmienną objaśnianą \hat{y} James et al. (2013) nazywa *statistical learning*, i zaznacza, że mogą

⁴Obecnie w przedsiębiorstwach rzadko stosuje się zaawansowane sposoby prognozowania sprzedaży (*predictive analytics*), a zarządzanie dostawami odbywa się raczej metodą manualnego uzupełniania zapasów.

⁵Wyprodukowanie każdego kolejnego produktu ponad moc produkcyjną będzie wymagało nadgodzin, dodatkowej przestrzeni magazynowej, pomocy poddostawców - a każde z tych wydarzeń będzie generowało dodatkowe koszty.

⁶Korzyści skali odczuwalne do pewnego optymalnego poziomu produkcji, powyżej którego brak mocy produkcyjnych powoduje powiększanie się kosztów krańcowych.

one być wykorzystane do modelowania predykcyjnego, tj. przewidywania przyszłych wydarzeń na podstawie przeszłej historii danych.

Zastosowanie metod *statistical learning* w przedsiębiorstwach potwierdza Buckinx et al. (2007), który wskazywał na możliwość prognozowania lojalności klienta na podstawie wewnętrznych danych o transakcjach, oraz Davenport et al. (2011), który opisuje szereg *case studies* firm, w których wykorzystuje się istniejące dane o transakcjach do przewidywania przyszłych zakupów klientów. Jednym z podanych przez niego przykładów jest Tesco, które na podstawie zebranych danych przewiduje, jak będzie wyglądał koszyk zakupów klienta podczas następnych zakupów, i odpowiednio wcześniej wysyła mu bony zniżkowe. Również podczas panelu *Strategia B2C w erze Big Data - jak wykorzystać potencjał danych* na XXV Forum Ekonomicznego w Krynicy przedstawiciele polskiego biznesu zwracali uwagę na szerokie wykorzystanie modelowania predykcyjnego również w nasz gospodarce.⁷

Podane przykłady dają nam podstawy, żeby w przypadku optymalizowanego przedsiębiorstwa zakładać, że dane o każdej transakcji są zapisywane wraz z niektórymi danymi osobowymi klienta⁸, a cały zbiór danych może być wykorzystany do przewidywania sprzedaży w chwili $t + 1$.

Dla każdej transakcji w sklepie dysponujemy więc zbiorem informacji $X = n \times x_i = \langle tr_1..tr_k, pr_1..pr_k, kl_1..kl_k \rangle$ gdzie *tr* to identyfikatory transakcji (miejsce, data, rodzaj płatności), *pr* to identyfikatory produktu (nazwa, cena, ilość) oraz *kl* to identyfikatory klienta (płeć, wiek, zarobki, wykształcenie etc.).

Na podstawie takiego zbioru danych chcemy przewidzieć popyt na produkty w każdym ze sklepów, co w praktyce oznacza konieczność stworzenia modelu estymującego następujące wielkości

⁷Jednak jak zwracano uwagę, *big data* i *modelowanie predykcyjne* służą głównie do zyskiwania wiedzy o kliencie i rynku do manualnego przetworzenia *insight*, a nie automatyzacji podejmowania decyzji, co rozważamy w tej pracy

⁸To stwierdzenie opiera się na opisywanym przez Davenport et al. (2011) przypadku Tesco i zastosowanej przez nich metody zbierania danych. Możliwość zbierania danych o transakcjach określonego klienta daje karta lojalnościowa (lub konto, w przypadku e-commerce), na którą rejestrowana jest każda transakcja. Praktyką jest, żeby przy okazji tworzenia karty lojalnościowej zbierać informacje o kliencie w ankiecie (zakres danych zależy od praktyki korporacyjnej). Dzięki temu, przedsiębiorstwa są w stanie przypisać do zakupów dane osobowe jak płeć, miejsce zamieszkania, wykształcenie etc.

- liczność n poszczególnych grup klientów⁹ odwiedzających sklep w chwili $t + 1$, gdzie $\hat{n} \in R$

oraz, w zależności od zastosowanego podejścia,

- prawdopodobieństwo p z jakim klient o danej charakterystyce kupi produkt pr , gdzie $\hat{p} \in (0, 1)$
- produkt wybrany przez danego klienta, gdzie $\hat{pr} \in \{pr_1, pr_2..pr_n\}$, a pr_i to dostępny produkt.

Jak wskazuje James et al. (2013), zmienna objaśniana może przyjąć różne dziedziny — m.in. zmiennej binarnej (1/0), prawdopodobieństwa, *log odds* lub klasy — i z tego względu każdy z przypadków różni się metodami które możemy zastosować. Według sugestii James et al. (2013) i Hastie et al. (2001) , zastosujemy następujące metody

- do liczby klientów - regresję metodą OLS (*ordinary least squares, metoda najmniejszych kwadratów*)
- do prawdopodobieństwa zakupu - regresję logistyczną (*logistic regression*)
- do wyboru produktu- metody klasyfikacyjne *k-means* oraz *drzewa klasyfikacyjne*

oraz metody nie służące bezpośrednio do modelowania \hat{y} , jednak wspierające proces predykcyjny

- pomiar odległości *distance scaling*, poprzez liczenie odległości euklidesowej (*eucclidean distance*) pomiędzy dwoma zbiorami danych i stworzenie obliczenie macierzy niepodobieństwa (odległości, *dissimilarity matrix*
- eliminację zmiennych (*backward elimination*, która jest jednym z podejść wyboru podzbiorów (*subset selection*) do selekcji zmiennych wyjaśniających które wspólnie tworzą najlepszy model
- prawdopodobieństwo warunkowe do przewidywania, jacy konsumenci odwiedzą sklep w $t + 1$, a co za tym idzie, jakie są wartości zmiennych objaśniających do prognozowania \hat{y}

⁹Przez *poszczególne grupy klientów* rozumiemy klientów o wspólnej charakterystyce, czyli takich samych zestawach zmiennych identyfikujących $\langle kl_1..kl_n \rangle$

2.3 Proponowany algorytm optymalizacyjny

Znając przewidywaną sprzedaż na krańcach grafu, proponowany w niniejszej pracy algorytm rozwiązania powyższego problemu opiera się na obserwacji, że równanie 1 będzie równoważne zapisowi sumującemu po możliwych kombinacjach łańcucha, zamiast dla każdego produktu z osobna. Nie tylko znacząco zmniejszy to liczbę potrzebnych iteracji obliczeń¹⁰

$$\max \sum_{d=1}^m \text{zysk}(p) = p \times pr_d - k_d \times pr_d \quad (2)$$

gdzie pr_d to ilość produktów przechodzącym przez dany łańcuch,
a k_d to funkcja kosztu $f(d)$

Ponieważ ścieżka d składa się z kombinacji jednostek przedsiębiorstwa wchodzących w jej skład, czyli $\langle fa, ma, sk \rangle$, koszt ponoszony na całej trasie będzie równie sumie kosztów ponoszonym na każdym z ogniw łańcucha, a równanie 2 możemy zapisać jako


$$\max \sum_{d=1}^m \text{zysk}(p) = p \times pr_d - \left(\sum_{j=1} k_j \right) \times pr_d \quad (3)$$

gdzie k_j to funkcja kosztu każdego z elementów łańcucha wartości (koszty produkcji, magazynowania, transportu, etc.). Warto odnotować przy tym, że zgodnie z założeniami funkcja k_j ze względu na efekty skali może być nieliniowa. Zakładamy, że funkcja ta jest nam znana, więc zostaje nam znalezienie takich wartości pr_d i *ceny* (jeśli nie przyjmujemy założenia danej, stałej ceny) dla których firma będzie osiągać maksymalny zysk. Ze względu na występujące w przedsiębiorstwie współzależności oraz nieliniowość kosztów (korzyści skali) musimy cały układ rozważać łącznie.

Na przykładzie przedsiębiorstwa będącego zbiorem jednostek $\langle fa_1, ma_1, ma_2, sk_1, sk_2, sk_3 \rangle$ mamy do czynienia z $m = \binom{1}{1} \times \binom{2}{1} \times \binom{3}{1} = 6$ kombinacji połączeń pomiędzy jednostkami przedsiębiorstwa, przy czym każdy do

¹⁰Ze względu na bardzo duży wolumen produkcji w opisywanej branży FMCG, mało prawdopodobne jest, aby liczba kombinacji tras dostaw była większa od liczby produktów, ale nawet wówczas istnieje możliwość rozważania tylko predefiniowanego zestawu tras), ale także umożliwi dalsze obliczenia upraszczające problem.

każdego ze sklepów można przeprowadzić dostawę jedną z dwóch tras.



Ponieważ przewidywany wolumen sprzedaży produktu w każdym z krańców grafu jest nam znany ¹¹, żeby umożliwić obliczenie optymalnego obłożenia każdej z tras prowadzącej do krańca grafu ¹² możemy dla każdej z tras ilość przechodzących nią produktów zapisać jako

$$pr_1 = \alpha pr_{sk_1}, \quad pr_2 = \beta pr_{sk_1} \quad \dots \quad pr_{d-1} = \gamma pr_{sk_i}, \quad pr_d = \delta pr_{sk_i}$$

gdzie pr_{sk_d} to ilość produktów, jakie mają trafić do sk_d krańca grafu leżącego na trasie d , a $\alpha, \beta, \dots, \delta$ to udział tej trasy w przepływie wszystkich towarów do danego krańca grafu. W ten sposób, równanie 3 możemy zapisać jako

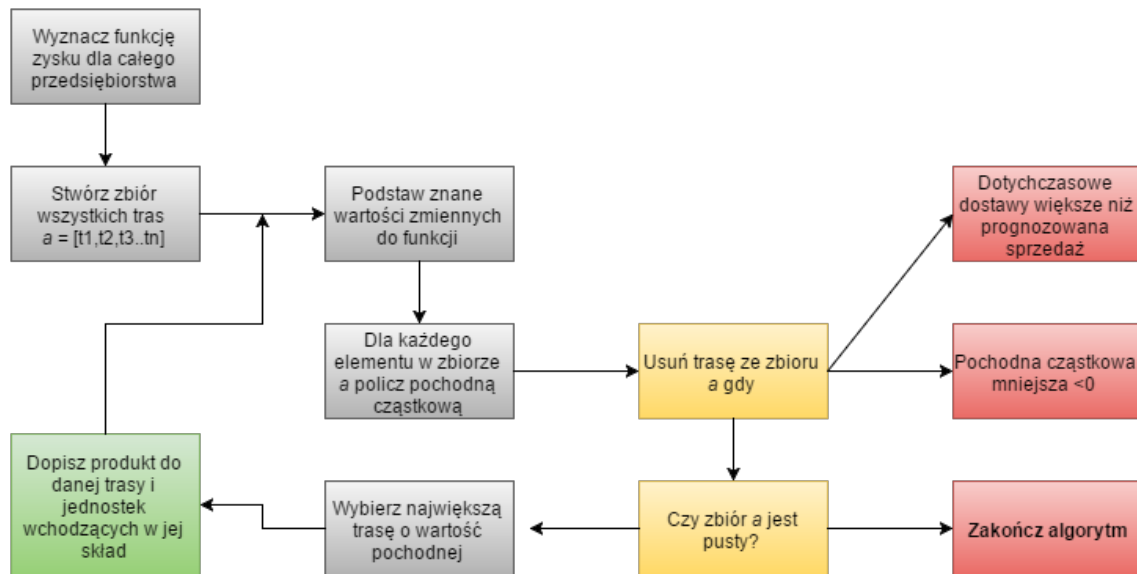
$$\max \sum_{d=1}^m zysk(cena) = cena \times \alpha pr_{sk_d} - \left(\sum_{j=1} k_j \right) \times \alpha pr_{sk_d} \quad (4)$$

Co po rozwinięciu pozwoli nam na sprowadzeniu równania 4 do postaci

$$zysk(cena) = \alpha (cena \times pr_{sk_1} - \left(\sum_{j=1} k_j \right) \times pr_{sk_1}) +$$

¹¹Zakładamy, że dzięki *Predictive analytics* na podstawie poprzednich obserwacji mamy dokładne prognozy dotyczące sprzedaży w chwili $t + 1$

¹²Żeby ograniczyć złożoność obliczeniową staramy się unikać pętli, która sprawdza każdą kombinację, zamiast tego szukając bardziej wyrafinowanych sposobów



Wykres 2: Proponowany algorytm optymalizacyjny

$$\dots + \delta(cena \times pr_{sk_i} - (\sum_{j=1} k_j) \times pr_{sk_1}) \quad (5)$$

jeśli przyjmiemy, że

$$a = (cena \times pr_{sk_1} - (\sum_{j=1} k_j) \times pr_{sk_1}) \dots$$

$$..b = (cena \times pr_{sk_i} - (\sum_{j=1} k_j) \times pr_{sk_1})$$

otrzymamy w ten sposób wieloman, w którym współczynniki a, b są nam znane¹³, a pary współczynników α, β jednego krańca grafu muszą być mniejsze lub równe 1.¹⁴

Za Sydsaeter, 2005 zauważmy, że $\frac{\partial zysk}{\partial \alpha}, \frac{\partial zysk}{\partial \beta} \dots \frac{\partial zysk}{\partial \delta}$ - czyli pierwsze pochodne cząstkowe po α, β, δ z tak zdefiniowanej funkcji - dadzą nam informację, o ile wzrośnie zysk przedsiębiorstwa w przypadku zwiększenia obłożenia tej trasy. Dlatego dla każdego produktu pr_n istnieje możliwość wybrania takiej z tras $< d_1, d_2, d_3 \dots d_m >$, która będzie maksymalizowała wynik przedsiębiorstwa - jak w równaniu 1.

Algorytm będzie więc działał jak zostało to pokazane na wykresie 2

¹³ pr_{sk_1} zostały wyprognozowane modelowaniem predykcyjnym, a k_j to znana nam suma funkcji kosztów w każdej jednostce

¹⁴Warunkiem nie jest żównie 1", ponieważ może istnieć taki udział α w przedziale $< 0, 1 >$ powyżej którego przez nieliniowość funkcji kosztów dostawa może być nieopłacalna

3 Model

W celu sprawdzenia działania algorytmu zbudowany został model wieloagentowy, który symuluje lokalny rynek na wybrany produkt, wraz z zachowaniami konsumentów i funkcjonowaniem przedsiębiorstwa.

3.1 Koncepcja modelu

Zgodnie z argumentacją zawartą w rozdziale 2.2, relacje w przedsiębiorstwie pomiędzy jednostkami tworzącymi wspólnie łańcuch dostaw można przedstawić jako model wieloagentowy. Jednocześnie, inspirować się Kaminski (2012), zakładamy, że możemy stworzyć zbiór heterogenicznych agentów symulujących decyzje konsumentów w celu modelowania rynku. Łącząc te podejścia, celem pracy jest stworzenie modelu wieloagentowego symulującego rynek (w szczególności aspekt sprzedaży oraz dostaw) na którym moglibyśmy sprawdzić wpływ działania algorytmu na wyniki przedsiębiorstwa.

Zgodnie z powyższym, w modelu znajdują się następujące typy agentów:

- **klienci**, którzy zgodnie z założeniem będą heterogeniczni i definiowani przez cechy demograficzne ¹⁵, które wpływającą na podejmowane przez niego decyzje oraz zachowania,
- **przedsiębiorstwo**, sprzedające *produkt* na rynku. Zgodnie z podejściem przedstawionym w 2.2, przedsiębiorstwo będzie rozumiane jako zbiór niezależnych, współpracujących ze sobą agentów
 - fabryk
 - magazynów
 - sklepów
 - zarządu, pełniącego funkcje koordynującą

¹⁵Są to między innymi wiek, zarobki, wykształcenie, zainteresowania - zostanie to dokładnie opisane w dalszej części pracy.

- **konkurencji**, zachowującej się pasywnie w stosunku do rynku, konsumentów i symulowanego przedsiębiorstwa, ale wprowadzającej na rynek szereg produktów stanowiących alternatywę dla produktu symulowanej firmy ¹⁶
- **produktów** dostępnych na rynku, z których każdy zdefiniowany jest unikalnymi cechami określającymi jakość, typ i cenę produktu, przez co każdy z produktów będzie preferowany przez inną grupę konsumentów, a preferencje są oparte na danych ze świata rzeczywistego.

Aspekt lokalizacji

Aby dobrze odwzorować kluczowy aspekt lokalizacji i dróg w łańcuchach dostaw, symulowany rynek jest osadzony w *wirtualnym mieście*. Oznacza to, że każdy agent ma swoją lokalizację w macierzy o wymiarach $x \times y$ i może się w niej poruszać po wyznaczonych drogach.

Lokalizacja wpływa na działania agenta - klient kupi produkt tylko w sklepie który będzie na jego ścieżce, a dostawa z magazynu do sklepu będzie tym droższa, im bardziej oddalone będą od siebie.

Symulowanie decyzji konsumenckich

W modelu konsumenci nieustannie poruszają się po *mapie*, bez związku z działaniem przedsiębiorstwa ¹⁷. W każdej jednostce czasu t klienci z prawdopodobieństwem p będą potrzebować symulowany produkt, więc odwiedzą któryś ze sklepów będących na ich trasie w czasie t , i wybiorą jeden z produktów oferowanych przez przedsiębiorstwo i konkurencję.

Symulacja wyboru opiera się na danych o preferencjach konsumenckich zebranych w ankiecie na próbie 169 badanych, w wyniku których otrzymano 1860 rekordów danych. Na ich podstawie których zbudowane zostało drzewo klasyfikacyjne opisujące prawdopodobieństwo zakupu produktu od cech konsumenta.

¹⁶Tj. konkurencja nie zmienia decyzji podjętych przed rozpoczęciem gry, i w założeniu ma stanowić jedynie alternatywę dla konsumentów.

¹⁷W każdej jednostce czasu t chodzą do pracy i odwiedzają znajomych

Ponieważ każdy konsument-agent w modelu ma swoje unikalne cechy demograficzne i charakteru, wykorzystujemy zbudowane drzewo klasyfikacyjnego do określenia wyboru, jakiego najprawdopodobniej dokonał by jego odpowiednik w świecie rzeczywistym.¹⁸ Przeprowadzając podobny proces dla każdego konsumenta w modelu, otrzymujemy dynamiczną symulację rynku produktów szybkozbywalnych.

Decyzje przedsiębiorstwa

Ponieważ konsument wybiera produkt tylko z gamy dostępnych w sklepie, kluczowe dla sukcesu przedsiębiorstwa jest dostarczenie w każdej jednostce czasu t odpowiedniej ilości produktów¹⁹. Oznacza to, że przed rozpoczęciem każdej tury przedsiębiorstwo musi podjąć szereg decyzji o m.in.

- odpowiednim poziomie produkcji,
- wolumenie dostaw do każdego ze sklepów w sieci,
- rozdzieleniu wolumenów pomiędzy części przedsiębiorstwa, tj. ile z całkowitego wolumenu ma wyprodukować fabryka A , a ile fabryka B
- jaką trasą powinny zostać wysłane dostawy do każdego ze sklepów.²⁰

Każda z tych decyzji będzie miała wpływ na przychody²¹ oraz koszty firmy. Celem pracy jest zbudowanie algorytmu, który na podstawie dotychczasowej historii transakcji pozwoli symulowanemu przedsiębiorstwu przewidzieć potencjalną sprzedaż w czasie $t+1$ i ze zbioru możliwych sterowań (wyżej wymienionych decyzji) $< u_{t+1} >$ wybierze takie, które będą maksymalizować zysk.

¹⁸Oczywiście, o wiele lepsze byłoby oparcie pracy o prawdziwe historie transakcji, jednak jest to niemożliwe ze względu na dużą poufność tych danych

¹⁹W warunkach symulacji nie można zapełnić *półek sklepowych* do pełna, bo brak sprzedaży oznacza stratę dla przedsiębiorstwa, a w sektorze FMCG zakładamy, że w czasie $t + 1$ produkty tracą zdolność do spożycia

²⁰Rozumiemy przez to pytanie, który z magazynów ma być pośrednikiem, ponieważ dobra nie mogą być dostarczane bezpośrednio z fabryki do sklepu.

²¹Przy założeniu stałej ceny, będą to przede wszystkim *utraczone koszty* w przypadku wyczerpania się zapasów w sklepie

3.2 Zastosowane narzędzia

Model został zbudowany w języku programowania Python 2.7, z wykorzystaniem następujących bibliotek:

| Biblioteka | Źródło | Zastosowanie |
|--------------|--|--|
| Sympy | www.sympy.org | Wykorzystanie do obliczeń symbolicznych |
| scikit-learn | scikit-learn.org | Wykorzystanie bibliotek metod statystycznych |

Kod programu dostępny jest pod adresem github.com/hubertguzera/master-thesis

3.3 Struktura programu

Program podzielony jest na trzy moduły, jak zaprezentowano na rysunku 3

- Pierwsza odpowiada za stworzenie, w drodze losowań, środowiska w ramach którego toczy się symulacja, wraz z agentami i macierzą lokalizacji.²²
- Druga część przez t_n jednostek czasu symuluje działanie rynku — decyzji klientów i funkcjonowania przedsiębiorstwa — według predefiniowanych zasad sterowań²³, zwracając na koniec wyniki (przychody, koszty i zysk) przedsiębiorstwa w danej jednostce czasu t .
- Trzecia po t_n rund symulacji aplikuje algorytm optymalizacyjny, który poprzez prognozowanie sprzedaży na krańcach grafu w t_{n+1} , szuka najlepszych decyzji o alokacji produktów. Działanie algorytmu można porównać do miary porównawczej uzyskanej w pkt 2.

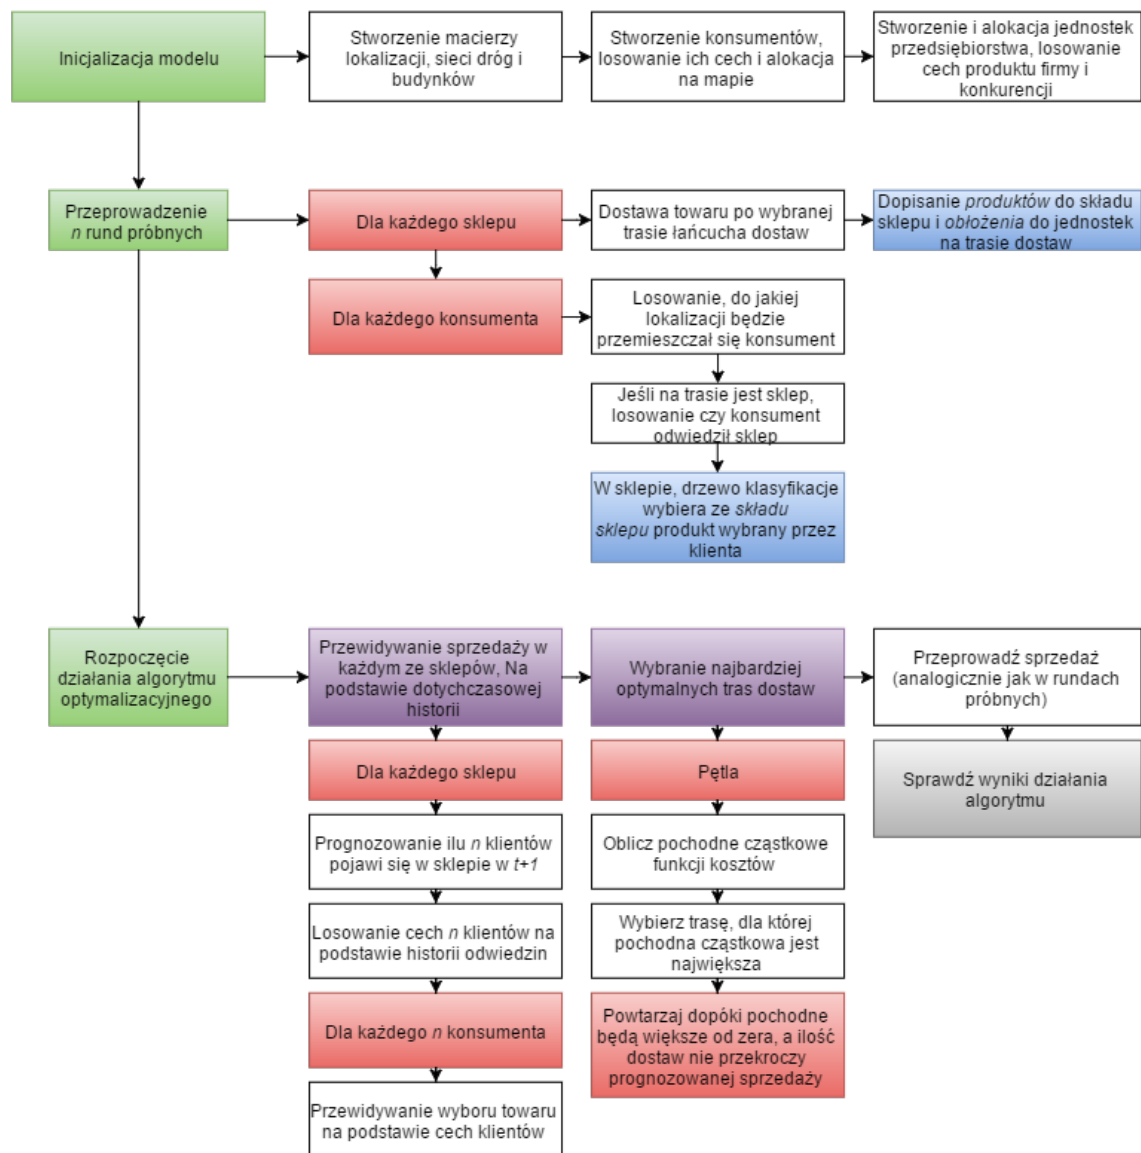
3.4 Generowanie środowiska modelu

Klasa *rynek*

Za reprezentację tak opisanego środowiska modelu odpowiada klasa *rynek*, wobec której dziedziczą wszystkie inne klasy występujące w modelu. Klasa *rynek* i wszystkie

²²Model może pominąć tę część i wczytać pregenerowany świat w celu sprawdzenia różnych scenariuszy w statycznym świecie (*ceteris paribus*).

²³Co istotne, algorytm optymalizacyjny jeszcze nie jest implementowany na tym etapie



Wykres 3: Struktura działania programu

dziedziczone jest generowana dynamicznie i losowo, jednak może być zapisana jeśli istnieje konieczność replikacji obliczeń albo porównań. Konstrukcja klasy *rynek* w programie została zaprezentowana w diagramie 3.4.

| rynek |
|---|
| swiat : class symulowana_firma : class tura : integer produkty_na_ryнку : class |
| __init__(self,swiat) : None sprzedaz_w_sklepach(self) : None nowatura (self) : None |

Klasa *swiat*

Klasa *swiat* zawarta w klasie *rynek* powstała w celu odpowiedniego odwzorowania kluczowego aspektu lokalizacji i dróg w łańcuchach dostaw, wzorując się na podejściu zastosowanym w *modelu segregacji Schellinga* (Schelling (1971)). Agenci osadzeni są w przestrzeni, reprezentowaną przez macierz klas *lokalizacja* o wymiarach (x,y). Dodatkowo, lokalizacje są połączone drogami, wymuszając na agentach poruszanie się tylko w obrębie ścieżek. Dzięki temu, w modelu będziemy mogli wiernie odwzorować wpływ odległości i wyboru trasy na efektywność procesów logistycznych, oraz zależność wyników sklepu od zamieszkującej okolicę populacji.

Macierz *mapa* generowana jest generowana jest według algorytmu widocznego na rysunku 4, który gwarantuje następujące właściwości otrzymanej w ten sposób macierzy lokalizacji.

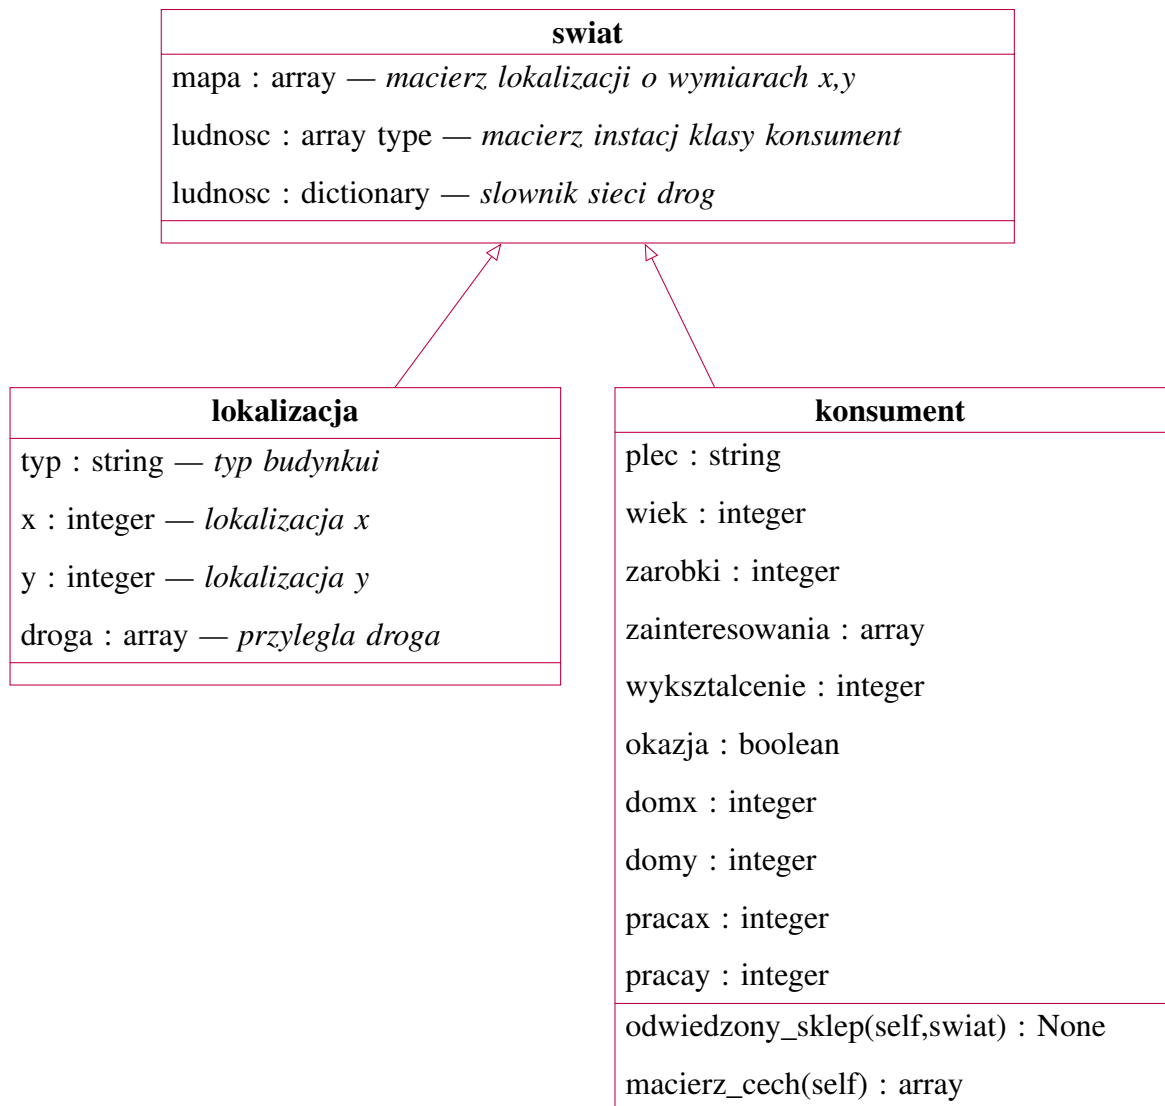
- Drogi krzyżują się i skręcają tylko pod kątem prostym. Poza skrzyżowaniami, drogi nie mają w sąsiedztwie innych dróg,
- Inne lokalizacje (domy, sklepy etc.) mogą występować tylko w bezpośrednim sąsiedztwie drogi,

- Drogi stanowią ciągłą linię, dzięki czemu nie ma punktu, do którego nie dałoby się dojechać z dowolnego miejsca startowego,
- W regionie 2 punktów od skraju mapy nie są generowane ani drogi, ani lokalizacje.

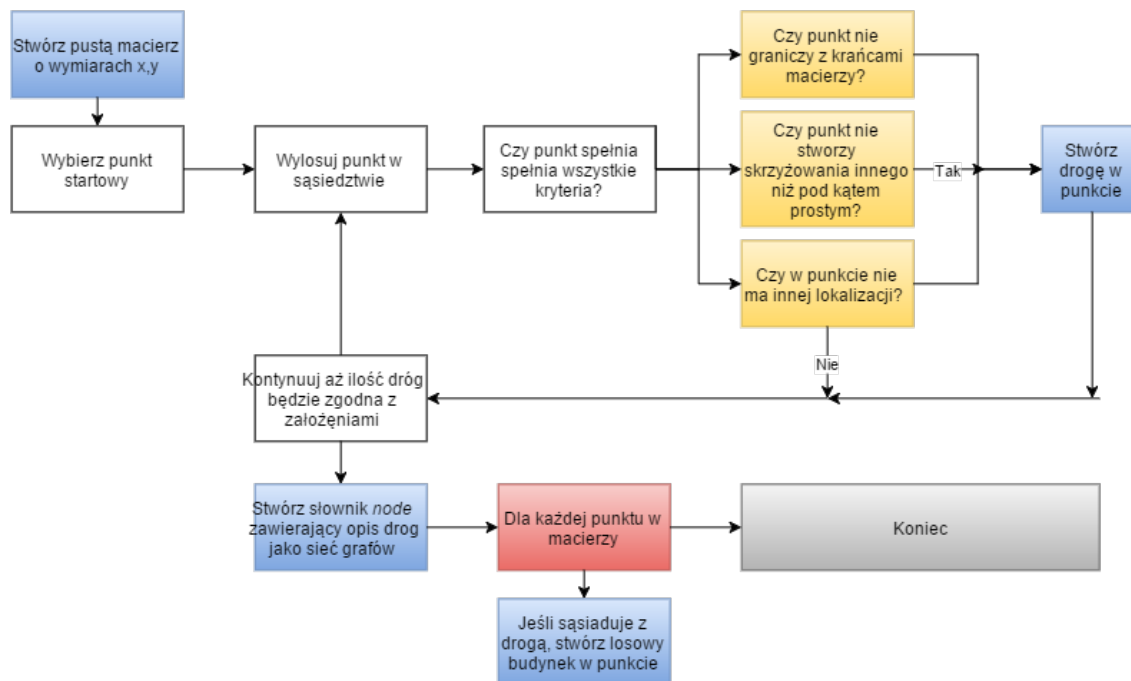
24

- Gęstość sieci dróg oraz prawdopodobieństwo występowania zakrętów jest predefiniowana przez użytkownika

Przykładowa *mapa* otrzymana w wyniku działania algorytmu widoczna jest na rysunku 5.



²⁴Jest to zabezpieczenie algorytmu, który w odległości 2 pkt od skraju mapy ma 0 proc. szansy na poprowadzenie ścieżki dalej - ponieważ w przypadku iterowania na skrajach mapy niektóre funkcje (jak sprawdzenie sąsiadujących punktów) mogą odnieść się do lokalizacji poza macierzą, powodując błąd programu



Wykres 4: Algorytm tworzenia dróg i lokalizacji

3.4.1 Algorytm wyszukiwania drogi

Trasy pomiędzy zadanymi punktami w modelu są wyszukiwane dynamicznie, na podstawie algorytmu wyszukiwania drogi. Odległości z kolei obliczane są poprzez sumowanie ilości punktów w zwracanym przez algorytm łańcuchu.

Algorytm oparty jest na metodach wyszukiwania ścieżek w grafach, dzięki założeniu, że każda droga o współrzędnej (x,y) na mapie jest punktem grafu, który może sąsiadować z punktami o współrzędnych $(x-1,y)$, $(x+1,y)$, $(x,y+1)$, $(x,y-1)$ ²⁵, o ile również są drogami.

²⁶ ²⁷


Algorytm, udostępniony przez Python Foundation²⁸ i zaprezentowany w tabeli 3.4.1 ma następujące cechy

²⁵Punkty $(x-1,y-1)$, $(x+1,y-1)$, $(x+1,y+1)$, $(x-1,y+1)$ wykluczamy przez wcześniejsze założenie, że drogi krzyżują się tylko pod kątem prostym

²⁶Informacje o punktach i sąsiadujących przechowywane są w zmiennej nodes, która jest słownikiem, dla każdego klucza - punktu na mapie - przechowuje informacje o sąsiadujących punktach, np. $(3,2) = [(3,3)(4,3)]$.

²⁷Pewnym ograniczeniem jest, że jako punkty grafu definiujemy tylko drogi, tak więc szukając trasy z punktu A do punktu B de facto szukamy trasy z drogi przy punkcie A do drogi przy punkcie B.

²⁸<https://www.python.org/doc/essays/graphs/>



Wykres 5: Przykładowa mapa - *szary* to drogi, *niebieski* - domy mieszkalne, *czerwony* i *zielony* - biurowce, *pomarańczowy* - sklepy, *żółty* - magazyny, *błękitny* - fabryki

- jest rekurencyjny,
- nie jest losowy,
- nie gwarantuje znalezienia najkrótszej trasy.

```

1  def find_path(graph, start, end, path=[]):
2      path = path + [start]
3      if start == end:
4          return path
5      if not graph.has_key(start):
6          return None
7      for node in graph[start]:
8          if node not in path:
9              newpath = find_path(graph, node, end, path)
10             if newpath: return newpath
11     return None

```

3.5 Agenci, ich rodzaje i właściwości

3.5.1 Konsumenci

Idąc za Kaminski (2012), w modelu stosujemy modelowanie rynku za pomocą heterogeniczne konsumentów. Stąd, każdy z konsumentów ma swoją unikalną charakterystykę rozumianą przez cechy demograficzne oraz cechy charakteru, które będą wpływać na jego wybory.

W dodatku, chociaż agenci nieustannie poruszają się w ramach modelu, to pula lokalizacji w ramach których będą się przemieszczać jest zamknięta — każdy z konsumentów będzie się przemieszczał tylko w wyniku zdarzenia, którym może być podróż do pracy albo odwiedziny znajomych. Ponieważ dla każdego z agentów miejsce pracy jest z góry określona, a pula znajomych zamknięta do trzech, każdy z agentów będzie przemieszczał się pomiędzy maksymalnie czterema lokalizacjami, tworząc pewne wzorce zachowań.

Dzięki temu, odwzierciedlamy zjawisko ze świata rzeczywistego, że konsumenci zazwyczaj robią zakupy w ograniczonej liczbie sklepów będących po drodze bądź niedaleko. Jest to bardzo istotny warunek funkcjonowania modelu, ponieważ losowy dobór klientów uniemożliwiłby modelowanie predykcyjne.

Każdy będzie definiowany w klasie o następujących właściwościach

| konsument |
|---|
| plec : string |
| wiek : integer |
| zarobki : integer |
| zainteresowania : array |
| wykształcenie : integer |
| okazja : boolean — <i>wskazanie powodu wyjścia z domu</i> |
| domx : integer — <i>współrzędna x domu</i> |
| domy : integer — <i>współrzędna y domu</i> |
| pracax : integer — <i>współrzędna x pracy</i> |
| pracay : integer — <i>współrzędna y pracy</i> |
| odwiedzony_sklep(self,swiat) : None |
| macierz_cech(self) : array |

```

1 class konsument:
2     plec = string
3     wiek = integer
4     zarobki = integer
5     zainteresowania = array # macierz trzech string
6     znajomi = array # trzy relacje z innymi agentami
7     wykształcenie = integer # 5-stopniowa skala
8     okazja = boolean # wskazanie czy wychodzi z domu
9     domx = integer # wspolrzedna x domu na mapie
10    domy = integer # wspolrzedna y domu na mapie
11    pracax = integer # wspolrzedna x pracy na mapie
12    pracay = integer # wspolrzedna y pracy na mapie

```

Wartości dla każdego z konsumentów są losowane niezależnie na podstawie rozkładów publikowanych przez Główny Urząd Statystyczny Główny Urząd Statystyczny (2011) oraz danych firmy Sedlak&Sedlak (Sedlak&Sedlak (2013))²⁹ w celu zagwarantowania odzwierciedlenia struktury społeczeństwa. Ze względu na zastosowanie prawdopo-

²⁹Raporty firmy Sedlak&Sedlak służyły do zbudowania tabeli prawdopodobieństwa wystąpienia danego wynagrodzenia w zależności od płci i wykształcenia. Reszta danych oparta na GUS


Wykres 6: Przykładowy rozkład prawdopodobieństwa zmiennej wiek, na podstawie GUS

dobieństw warunkowych dla niektórych cech (np. zarobki są zależne od wykształcenia) istnieje pomiędzy nimi korelacja.³⁰ Przykładowe rozkłady pokazane są na rysunku 6 oraz 7

3.5.2 Przedsiębiorstwo

Zgodnie z założeniami określonymi w rozdziale 1, symulowane przedsiębiorstwo jest w istocie zbiorem niezależnych agentów, tworzących wspólną sieć neuronową. Zbiór ten

³⁰Chociaż korelacja może być problemem przy modelowaniu, będziemy sobie z nią radzić na późniejszym etapie



Wykres 7: Przykładowy rozkład prawdopodobieństwa zmiennej wykształcenie (*zielony* dla mężczyzn, *czerwony* dla kobiet), na podstawie GUS

należy w modelu do klasy *firma*, przechowującej w podzbiorach instancje klas *fabryka*, *magazyn*, *sklep*, jak zaprezentowano na diagramie 3.5.2. W klasie *firma* znajdują się także funkcje przynależne opisywanemu w strukturze modelu zarządowi, mające na celu koordynację działania przedsiębiorstwa.

Warto zauważyć, że klasy te mają wiele wspólnych właściwości, z wyjątkami obecnymi w klasie *sklep*, co wynika z konieczności stworzenia funkcji symulujących sprzedaż oraz faktu, że sklepy mają dodatkowe zmienne przechowujące informacje o składzie towaru, klientach odwiedzających sklep w danej jednostce czasu t oraz historii transakcji.



3.5.3 Produkt

Opierając się na stwierdzeniu Sagan (2011), który wskazuje na nurtu w dziedzinie modelowania strukturalnego zachowań klientów, które wykorzystywało zmienne marketingowe określające jakość produktu i ilość cech³¹, zakładamy, że każdy produkt charakteryzuje się cechami wpływającymi na prawdopodobieństwo jego zakupu przez konsumentów, które mogą być wyrażone ilościowo.

Stąd produkt definiujemy przez zestaw wybranych cech, które odróżniają go od produktów konkurencji, a których dziedziną mogą być *factors*³², skala ocen $\in R$ bądź zmienne binarne.³³, a klasa *produkt* przechowujące jednowymiarową macierz z cechami produktu $[x_1, x_2, x_3]$

Warto odnotować, że w pracy przyjmujemy, że symulowanym produktem z branży FMCG jest piwo. Ten dość nieelegancki wybór motywowany jest głównie specyfiką produktu, która dobrze pasuje do wymagań stawianych przez model (szczególnie w aspekcie możliwości modelowania decyzji konsumenckich), wśród których są

- wysoka sprzedaż i idący za tym wysoki obrót towaru w sklepach — przeciętny Polak pije 99 litrów piwa rocznie, co oznacza butelkę kupioną co mniej więcej drugi dzień,³⁴
- produkt mają silne marki o ugruntowanych cecach i grupach docelowych — reklamy piw zazwyczaj podkreślają w jakich okolicznościach i jaka grupa docelowa pije piwo, co powoduje, że występuje wysoka zależność pomiędzy charakterystyką demograficzną klienta a piwem, które wybierze,³⁵.

³¹Mowa o tzw. nurcie poznawczym albo nurcie teorii przetwarzania informacji - TPI

³²*factors* rozumiany jako zmienne kategoryczne

³³Ich istotność nie jest w tym momencie ważna, ponieważ nawet jeśli w zbiorze znajdzie się cecha mająca mały wpływ na decyzje konsumentów, zostanie ona wyeliminowana na etapie tworzenia modelu bądź drzewa klasyfikacyjnego ze względu na brak istotności statystycznej współczynnika

³⁴Dzięki temu możemy założyć, że prawdopodobieństwo zakupu piwa przez klienta to nawet 50% , a to z kolei gwarantuje odpowiednią ilość iteracji do przeprowadzenia analizy.

³⁵Idealnym przykładem jest Redd's, wybierany głównie przez kobiety. Innymi mogą być Grolsch wybierany przez ludzi zamożnych, kiedy Wojak trafia do najgorzej zarabiających

- produkty mocno różnią się od siebie cechami — w przeciwieństwie do mąki, rola jakości, smaku i właściwości piwa odgrywa znaczącą rolę dla klienta. Powoduje to, że piwo smakowe i pszeniczne będą trafiać do dwóch różnych grup klientów.

3.5.4 Konkurencja

W założeniach przyjmujemy, że konkurencja jest pasywna - tj. nie podejmuje działań ani decyzji w trakcie trwania symulacji. Wynika to z odmiennego celu badania, którym jest analiza działania algorytmów optymalizacyjnych. Nagłe zmiany sprzedaży spowodowane np. obniżeniem ceny przez konkurencję spowodowałyby wątpliwości interpretacyjne i są zbędne. Konkurencja jest za to potrzebna do stworzenia alternatywnych dla symulowanego produktu, o odmiennych cechach i przyciągających klientów o specyficznych charakterystykach, i jej rola ogranicza się do wprowadzenia go na rynek.

3.5.5 Trasy

Klasa *trasy* przechowuje wszystkie możliwe kombinacje łańcuchów dostaw, składające się z instancji klas *fabryka*, *magazyn*, *sklep* oraz *ścieżek* pomiędzy nimi ³⁶. W przypadku złożonych grafów (czyli sytuacji, kiedy przedsiębiorstwo składa się z wielu jednostek) ilość kombinacji może uniemożliwić swobodne przetwarzanie klasy w pamięci komputera, jednak w takim wypadku można predefiniować zbiór możliwych łańcuchów, spośród których model będzie wybierał najbardziej optymalne trasy.

Dla każdej z tras, poza informacjami o jednostkach wchodzących w skład przedsiębiorstwa, przechowujemy także informację o *ścieżkach* pomiędzy jednostkami. Wynika to z faktu, że transporty pomiędzy poszczególnymi jednostkami także mogą doświadczać efektów skali, ³⁷ a długość ścieżki bezpośrednio wpływa na koszt łańcucha - koszt wzrasta w stosunku do długości ścieżki.

³⁶Jako ścieżkę rozumiemy sekwencję punktów z drogami, jakie trzeba przebyć od fabryki do magazynu i od magazynu do sklepu

³⁷Przykładowo, pod kątem kosztów na produkt, transport 100 produktów może być bardziej opłacalny niż 10 ze względu na rozłożenie kosztów stałych na większą ilość produktów

3.6 Symulowanie decyzji konsumenckich

Jak wskazano na diagramie 3, podczas wizyty każdego z wirtualnych konsumentów w sklepie symulujemy jego decyzję co do zakupu towaru. W tej części chcemy, aby decyzje konsumentów w modelu jak najbardziej przypominały decyzje klientów w analogicznych sytuacjach w świecie rzeczywistym.³⁸

Opierając się na Sagan (2011), wiemy, że jesteśmy w stanie zdefiniować kluczowe cechy konsumenta i cechy marketingowe produktu jako zbiór zmiennych ilościowych. Stąd, w grze eksperymentalnej przeprowadzonej na potrzeby pracy³⁹, poproszono uczestników o stwierdzenie, jakie produkty z dostępnej listy kupi klient o charakterystyce wylosowanej przez program. Po odpowiedzi udzielonej przez gracza, predefiniowane, jakościowe cechy produktu były transponowane na wartości liczbowe⁴⁰ i wraz z ilościowymi cechami klienta oraz zmienną binarną przechowującą informacje *kupił/niekupił* zapisywany na serwerze SQL.

W programie dane te służą do budowy drzewa klasyfikacyjnego, które - ponieważ dane liczbowe są w identycznej formie- dla każdej kwerendy o klienta i produkt zwraca prawdopodobieństwo zakupu. Stąd, dla każdego agenta możemy zbudować listę prawdopodobieństw zakupu każdego z towarów dostępnego na rynku, i w ten sposób losowaniem symulować decyzje konsumenckie. To podejście gwarantuje wysokie podobieństwo z wyborami realnych konsumentów ponieważ

- ze względu na wysoką ilość rekordów jest duża szansa, że istnieje zapis o decyzjach klienta o bardzo podobnej charakterystyce
- baza danych jest generowana przez decyzje ludzkie, zapewniając wysoką zgodność z analogicznymi wyborami w świecie rzeczywistym
- wybór drzewa klasyfikacyjnego jako metody i wysoki n rekordów pozwala na bardzo pożądaną w tej sytuacji *overfit*, który jak opisuje James et al. (2013) powoduje, że dostajemy bardzo dokładne odwzorowanie zbioru uczącego.

³⁸Warto odnotować, że to nie jest to samo co późniejsze przewidywanie "prognozowanej sprzedaży"

³⁹Gra dostępna jest pod adresem <http://serwer1418288.home.pl/test/piwo/zapisy.php>

⁴⁰Na przykład, piwo Grolsh jest drogie, klasy premium i jest lager, stąd otrzyma zapis [5,1,1], a tani smakowy Redd's [3,0,0].

4 Efekty działania algorytmu optymalizacyjnego

4.1 Charakterystyka badanego środowiska


Sprawdzenie działania modelu odbędzie się w losowo wygenerowanym środowisku, które ze względu na konieczność wielokrotnej replikacji obliczeń w różnych warunkach zostało zapisane i będzie stosowane we wszystkich obliczeniach w niniejszym rozdziale. Środowisko zostało wygenerowane przy założeniach widocznych w tabeli 1, a wygenerowane mapy zostały przedstawione na rysunkach 8a i 8b.

Tabela 1: Właściwości generowanego świata. *Źródło:* opracowanie własne.

| Właściwość | Założenie |
|--|-----------|
| Populacja | 10000 |
| Wymiar x | 100 |
| Wymiar y | 100 |
| Udział dróg | 0.3 |
| Gęstość zakrętów dróg | 0.05 |
| Udział budynków mieszkalnych | 0.6 |
| Udział biurowców ⁴¹ | 0.2 |
| Udział przestrzeni komercyjnej ⁴² | 0.2 |
| Ilość fabryk | 3 |
| Ilość magazynów | 3 |
| Ilość sklepów | 6 |

Konsumenci

Cechy konsumentów zostały wygenerowane zgodnie z rozkładami zawartymi w Narodowym Spisie Ludności (Główny Urząd Statystyczny (2011)) oraz XI Ogólnopolskim Badaniu Wynagrodzeń Sedlak&Sedlak (2013) w celu zapewnienia spójności z rzeczywistą strukturą społeczną. Wynikająca z tego histogramy cech klientów zostały zaprezentowane na 9. Poza zaprezentowanymi na histogramach danymi demograficznymi agenci posiadają trzy zainteresowania, których rozkład zaprezentowany został w tabeli 2.



(a) Mapa typów lokacji na mapie



(b) Histogram występowania konsumentów na mapie.

Wykres 8: Mapa wygenerowanych macierzy lokalizacji w modelu

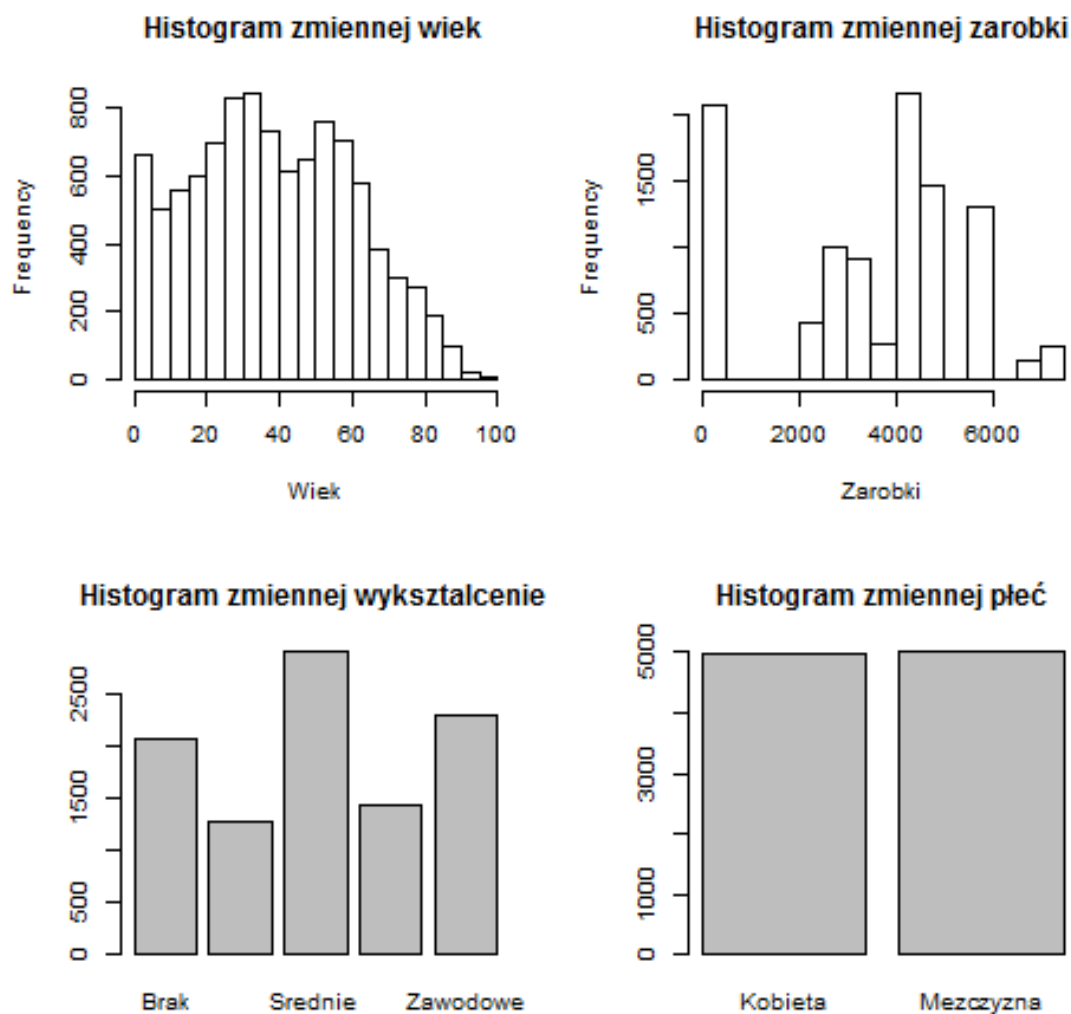
W przeciwieństwie do danych demograficznych, są one niezależne, a każda z nich posiadała identyczną szansę na wylosowanie. Celem tego było wprowadzenie do modelu zmiennych, których nie byłyby skorelowane z innymi, a ponieważ mają wpływ na wybory klientów i nie są zapisywane w historii transakcji, utrudniają przewidywanie sprzedaży.

Przedsiębiorstwo

Symulowane przedsiębiorstwo składa się z zaprezentowanej w tabeli 1 ilości jednostek — 3 fabryk, 3 magazynów i 6 sklepów, które wspólnie tworzą $\binom{3}{1} \times \binom{3}{1} \times \binom{6}{1} = 108$ możliwych kombinacji łańcuchów dostaw. Lokacje poszczególnych jednostek zostały zaprezentowane na rysunku 10.

Produkty


Zakładamy, że na rynku obecnych jest 7 marek piwa, z których jedno należy do symulowanego przez nas przedsiębiorstwa (produkt o nazwie **Symulowane**). Każde z piw zdefiniowane jest 7 zmiennymi marketingowymi, z których *cena*, *smak*, *opakowanie* i *marketing* to liczby całkowite w skali 1 — 5, a *premium*, *budżetowe*, *lager* oraz *smakowe* to zmienne binarne. Cechy produktów zaprezentowane zostały w tabeli 3.



Wykres 9: Histogramy cech agentów. Źródło: opracowanie własne

4.2 Przewidywanie decyzji konsumentów

Przewidywanie decyzji konsumentów odbywa się zgodnie z założeniami przedstawionymi w rozdziale 2.2.3. Jednak ponieważ w modelu stosowane jest pewne uproszczenie, polegające na braku symulacji efektów zewnętrznych, a decyzje klientów o przyjeździe do sklepu są losowe w ramach zamkniętej puli miejsc, do przewidywania liczby klientów odwiedzających sklep w chwili $t + 1$ stosowana jest średnia (ponieważ brak jest zmiennych objaśniających które mogłyby zostać wykorzystane w modelu). Mogłoby to zostać zaaplikowane poprzez wprowadzenie zmiennych losowych typu *pogoda*, *temperatura*, *dzień ty-*



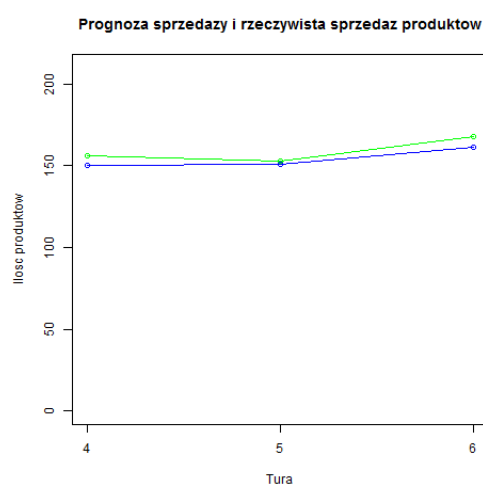
Wykres 10: Mapa z zaznaczonymi jednostkami przedsiębiorstwa. Źródło: opracowanie własne

godnia, jednak wprowadzałoby to niepotrzebną złożoność do modelu, a nie wpływa to bezpośrednio na cel badania.

Jednocześnie, dalsze prognozowanie odbywa się zgodnie z przyjętym podejściem — tak więc dysponując liczbą klientów w chwili $t + 1$ wiemy, ilu konsumentów musimy wylosować na podstawie prawdopodobieństw warunkowych cech zapisanych w historii transakcji. Następnie, dla każdego z tak wylosowanych klientów prognozujemy prawdopodobieństwo wybrania każdego z produktów dostępnych w sklepie, otrzymując jego *decyzję konsumentką*. Estymacja może zostać dokonana metodą regresji logistycznej bądź

klasyfikacji *k-means*, w zależności od wyboru użytkownika. Suma decyzji konsumentów wskazujących symulowany produkt będzie wolumenem sprzedaży w $t + 1$.

Wyniki prognozowanej sprzedaży w stosunku do zrealizowanej sprzedaży w $t + 1$ przedstawiony został na wykresie 11, z kolei porównanie trafności prognoz każdej z metod zostało zaprezentowane w macierzy pomyłek (*confusion matrix*) w tabeli



Wykres 11: Przykładowy pojedynczy wykres. Źródło: opracowanie własne

| | 0 | 1 |
|---|-----|-----|
| 0 | 892 | 222 |
| 1 | 303 | 375 |

(a) Macierz pomyłek dla regresji logistycznej

| | 0 | 1 |
|---|-----|-----|
| 0 | 967 | 147 |
| 1 | 498 | 180 |

(b) Macierz pomyłek dla klasyfikacji *k-means*

Wykres 12: Przykładowy wykres. Wykresy podpisujemy, a więc ten opis znajduje się pod wykresem. Źródło: opracowanie własne

4.3 Wyniki przedsiębiorstwa przy braku optymalizacji

4.4 Optymalizacja przy stałych cenach i braku efektu skali

4.5 Optymalizacja przy stałych cenach i istnieniu efektu skali

Tabela 2: Rozkład zmiennych zainteresowań agentów. *Źródło:* opracowanie własne.

| | Ilość |
|----------------------|---------|
| Moda | 1234.00 |
| Gotowanie | 1246.00 |
| Finanse | 1265.00 |
| Kultura | 1213.00 |
| Historia | 1189.00 |
| Koncerty | 1222.00 |
| Motoryzacja | 1219.00 |
| Kosmetyki | 1241.00 |
| Malarstwo | 1260.00 |
| Ogrodnictwo | 1289.00 |
| Gry | 1358.00 |
| Sport | 1255.00 |
| Boks | 1286.00 |
| Fotografia | 1233.00 |
| Kultura alternatywna | 1252.00 |
| Nightlife | 1231.00 |
| Teatr | 1229.00 |
| Książka | 1264.00 |
| Historia polski | 1243.00 |
| Natura | 1233.00 |
| Piwowarstwo | 1202.00 |
| Muzyka klasyczna | 1293.00 |
| Książki | 1233.00 |

Tabela 3: Cechy symulowanych produktów. *Źródło:* opracowanie własne.

| | Cena | Smak | Opakowanie | P | B | L | S | Marketing ⁴³ |
|------------|------|------|------------|---|---|---|---|-------------------------|
| Symulowane | 1 | 4 | 3 | 1 | 0 | 1 | 0 | 1 |
| Lebskie | 4 | 3 | 4 | 0 | 1 | 1 | 0 | 4 |
| Baltyckie | 1 | 4 | 5 | 1 | 0 | 0 | 1 | 3 |
| Opolskie | 4 | 4 | 4 | 1 | 0 | 1 | 0 | 1 |
| Mocne | 4 | 5 | 4 | 1 | 0 | 0 | 1 | 5 |
| Pyszne | 5 | 1 | 3 | 1 | 0 | 1 | 0 | 2 |
| Babskie | 5 | 4 | 5 | 0 | 0 | 1 | 0 | 3 |

5 Rysunki i tablice

Zarówno rysunki jak i tablice używają podobnej koncepcji osadzania w dokumencie. Aby osadzić tablicę używa się otoczenia `table`. Poniżej jest przykład prostej tablicy.


Tabela 4: Przykład prostej tablicy. Ten tekst będzie automatycznie zawijany.

Źródło: opracowanie własne.

| Name | property 1 | property 2 | property 3 |
|-------------|------------|------------|------------|
| Michael | 23 | 34 | – |
| John | 34 | – | 28 |
| Mr. Niceguy | 123 | 231 | 312 |



Tablica 4 jest przykładem bardzo prostej tablicy ale możliwe jest znacznie więcej rzeczy, w razie konieczności służę pomocą.

Aby osadzić rysunek to w pierwszej kolejności trzeba mieć ten rysunek w pliku. W katalogu są dwa przykładowe rysunki. Następujący przykład korzysta z tych rysunków i jest przykładem wykorzystania otoczenia `figure`.



Wykres 13: Przykładowy pojedynczy wykres. *Źródło:* opracowanie własne

Odwołanie się do wykresu działa podobnie jak do równania: rysunek 13. Możemy również odwoływać się do podwykresów: 14a lub 14b. Zarówno tablice (tabele) jak i rysunki (wykresy) są automatycznie układane przez \LaTeX i nie pozycjonujemy ich sami.



(a) To jest pierwszy podpis. Ten podpis będzie również zawijany ale będzie to powodowało odpowiednie dopasowanie wysokości.

(b) Układ równowag stabilnych

Wykres 14: Przykładowy wykres. Wykresy podpisujemy, a więc ten opis znajduje się pod wykresem. *Źródło:* opracowanie własne

A Dodatek: Ważne rzeczy do dodania

Tutaj można włożyć długie tablice, kod wykorzystane w pracy lub inne elementy, które nie powinny zakłócać czytania tekstu.

Literatura

- Brynjolfsson, E., Hitt, L. M. i Kim, H. H. (2011), 'Strength in Numbers: How does data-driven decision-making affect firm performance?', *ICIS 2011 Proceedings* p. 18.
- Buckinx, W., Verstraeten, G. i den Poel, D. V. (2007), 'Predicting customer loyalty using the internal transactional database', *Expert Systems with Applications* **32**(1), 125 – 134.
URL: <http://www.sciencedirect.com/science/article/pii/S0957417405003143>
- Davenport, T., D'Amboise, L. i Lucker, J. (2011), 'Know what your customers want before they do', *Harvard Business Review* .
- Frey, C. B. i Osborne, M. (2013), 'The future of employment: How susceptible are jobs to computerisation?', Online PDF.
URL: <http://www.oxfordmartin.ox.ac.uk/publications/view/1314>
- Główny Urząd Statystyczny (2011), Narodowy spis ludności 2011, Technical report, Główny Urząd Statystyczny.
- Hastie, T., Tibshirani, R. i Friedman, J. (2001), *The Elements of Statistical Learning*, Springer Series in Statistics, Springer New York Inc., New York, NY, USA.
- James, G., Witten, D., Hastie, T. i Tibshirani, R. (2013), *An Introduction to Statistical Learning with Applications in R*, Springer-Verlag New York.
- Kaminski, B. (2012), *Podejscie wieloagentowe do modelowania rynków*, Oficyna Wydawnicza Szkoły Głównej Handlowej w Warszawie.
- Kawa, A. (2010), 'System wieloagentowy do budowania łańcuchów dostaw w branży komputerowej', *Zarządzanie Przedsiębiorstwem* **13**(1), 26–34.
- McKinsey Global Institute (2011), Big data: The next frontier for innovation, competition, and productivity, Technical report, McKinsey Global Institute.
- Moyaux, T., Chaib-Draa, B. i D'Amours, S. (2006), 'Supply chain management and multiagent systems: An overview', *Multiagent based Supply Chain Management* **4**, 1–27.

- Porter, M. E. (1985), *Competitive advantage: Creating and sustaining superior performance*, Free Press, New York and London.
- PwC (2014), CEO Survey 2014, Technical report.
- Sagan, A. (2011), 'Modele strukturalne w analizie zachowan konsumenta - ewolucja podejsc', *Konsumpcja i rozwoj*.
- Schelling, T. (1971), 'Dynamic models of segregation', *Journal of Mathematical Sociology*.
- Sedlak&Sedlak (2013), Xi ogolnopolskie badanie wynagrodzen 2013, Technical report, Sedlak&Sedlak.
- The Economist (2010), Data, data everywhere, Technical report.
- Wooldridge, M. i Jennings, N. R. (1995), 'Intelligent agents: theory and practice', *The Knowledge Engineering Review* **10**, 115–152.

Spis tablic

| | | |
|---|------------------------------------|----|
| 1 | Przykład prostej tablicy | 34 |
| 2 | Przykład prostej tablicy | 39 |
| 3 | Przykład prostej tablicy | 40 |
| 4 | Przykład prostej tablicy | 41 |

Spis rysunków

| | | |
|----|--|----|
| 1 | Przykładowa sieć relacji w łańcuchu logistycznym | 8 |
| 2 | Proponowany algorytm optymalizacyjny | 16 |
| 3 | Struktura działania programu | 21 |
| 4 | Algorytm tworzenia dróg i lokalizacji | 24 |
| 5 | Przykładowa mapa - <i>szary</i> to drogi, <i>niebieski</i> - domy mieszkalne, <i>czerwony</i> i <i>zielony</i> - biurowce, <i>pomarańczowy</i> - sklepy, <i>żółty</i> - magazyny, <i> błękitny</i> - fabryki | 25 |
| 6 | Przykładowy rozkład prawdopodobieństwa zmiennej wiek, na podstawie GUS | 28 |
| 7 | Przykładowy rozkład prawdopodobieństwa zmiennej wykształcenie (<i>zielony</i> dla mężczyzn, <i>czerwony</i> dla kobiet), na podstawie GUS | 29 |
| 8 | Krótką nazwa II | 35 |
| 9 | Krótką nazwa X | 36 |
| 10 | Krótką nazwa X | 37 |
| 11 | Krótką nazwa X | 38 |
| 12 | Krótką nazwa II | 38 |
| 13 | Krótką nazwa X | 41 |
| 14 | Krótką nazwa II | 42 |

Streszczenie

Tutaj zamieszczają Państwo streszczenie pracy. Streszczenie powinno być długości około pół strony.