



SZKOŁA GŁÓWNA HANDLOWA W WARSZAWIE
WARSAW SCHOOL OF ECONOMICS

Studium magisterskie

Kierunek: Finanse i Rachunkowość

Specjalność: Finanse przedsiębiorstw

Forma studiów: stacjonarne

Imię i nazwisko: Hubert Guzera

Nr albumu: 61816

**Wykorzystanie modelowania predyktywnego
do stworzenia heurystyki optymalizacji
decyzji w przedsiębiorstwie**

Praca magisterska napisana

w Kolegium Analiz Ekonomicznych

w Katedrze Matematyki i Ekonomii Matematycznej

pod kierunkiem naukowym

dr hab. Michała Ramszy

Warszawa 2015

Spis treści

1	Wprowadzenie	5
2	Cel, założenia i podstawy teoretyczne pracy	7
2.1	Koncepcja pracy	7
2.2	Podstawy teoretyczne	7
2.2.1	Przedsiębiorstwo jako system wieloelementowy	7
2.2.2	Modelowanie predykcyjne	9
2.2.3	Zadanie optymalizacyjne	13
2.3	Proponowany algorytm optymalizacyjny	16
2.4	Cechy algorytmu optymalizacyjnego	17
3	Model	20
3.1	Koncepcja modelu	20
3.2	Zastosowane narzędzia	23
3.3	Struktura programu	23
3.4	Generowanie środowiska modelu	24
3.5	Agenci, ich rodzaje i właściwości	28
3.5.1	Konsumenci	28
3.5.2	Przedsiębiorstwo	29
3.5.3	Produkt	30
3.5.4	Konkurencja	31
3.5.5	Ścieżki i trasy dostaw	32
3.6	Symulowanie decyzji konsumenckich	33
4	Efekty działania algorytmu optymalizacyjnego	36
4.1	Założenia modelu	36
4.2	Przewidywanie decyzji konsumentów	39
4.3	Wpływ działania algorytmu na działanie przedsiębiorstwo	40
4.4	Podsumowanie i wnioski	43
5	Dodatek: Dodatkowe wykresy	45

Lista tablic	57
Lista rysunków	58
Streszczenie	59

1 Wprowadzenie

Wal-Mart, amerykański gigant handlowy, co godzinę umieszcza w swoich bazach danych 2.5 petabajtów danych, pochodzących z blisko miliona transakcji (The Economist (2010)). I nie jest wyjątkiem — przeciętna ilość danych przechowywanych przez przedsiębiorstwa w Stanach Zjednoczonych jest większa niż zbiory Biblioteki Kongresu (szacowane na 235 terabajtów (McKinsey Global Institute (2011))). W erze informacji większość z naszych działań trafia na serwery tej bądź innej firmy, w formie historii transakcji, koordynatu GPS czy zdjęcia.

Często informacje zbierane są przypadkiem — ze względu na prowadzenie rachunkowości, specyfikę świadczonych usług, lub też względy archiwizacyjne. Jednak wydobycie z nich *wiedzy* może stanowić źródło znaczącej przewagi konkurencyjnej. Jak wskazują Brynjolfsson et al. (2011), przedsiębiorstwa podejmujące decyzje na podstawie analizy dużych zbiorów danych (*ang. data driven decision making*) osiągają efektywność o 5-6 proc. większą niż grupa porównawcza. Mają także większy zwrot z kapitału i wycenę rynkową — krótko mówiąc, radzą sobie lepiej. Nic więc dziwnego, że coraz częściej metody analizy danych (*ang. data analytics*) stają się priorytetem wśród dużych spółek. Skalę popularności analityki biznesowej (*ang. business intelligence*) unaocznia badanie PwC (2014), według którego 44 proc. prezesów zarządu planuje oparcie rozwoju firmy o inwestycje w tej dziedzinie.

Ale dzisiejsze zastosowania *big data* to tylko preludium do tego, co czeka nas w przyszłości. Trwający równolegle trend robotyzacyjny spowoduje, że w ciągu 20 lat w przedsiębiorstwie zamiast kierowców będziemy zarządzać flotą autonomicznych pojazdów, a magazynierów zastąpią roboty. Fakt, że Google i Daimler już testują takie auta nie pozwala na nazwanie takiego scenariusza *science-fiction*. Dlatego jak wskazuje Frey i Osborne (2013), blisko 47 proc. miejsc pracy jest zagrożonych komputeryzacją. Większość z nich to zawody wykonujące rutynowe, mechaniczne czynności, ale postęp technologiczny powoduje, że na tej liście znajdują się też prace wymagające umiejętności kognitywnych i wnioskowania — jak pracownicy biurowi, analitycy czy operatorzy.

Mając do czynienia z jednej strony z flotą autonomicznych pojazdów, z drugiej z petabajtami informacji o tym gdzie i co kupują nasi klienci, możemy znaleźć się w sytuacji, gdzie koordynacja łańcucha dostaw będzie wykraczać poza możliwości człowieka. Dla

komputera, obliczenie popytu na podstawie danych i zaplanowanie dostaw będzie relatywnie mniejszym problemem. Potwierdza to The McKinsey Global Institute McKinsey Global Institute (2011), który wskazuje, że coraz częściej maszyny będą zastępować ludzi w podejmowaniu decyzji i brać udział w sterowaniu przedsiębiorstwem. W teorii, ze względu na możliwość przeprowadzania złożonych obliczeń i analizy gigabajtów danych, decyzje te będą trafniejsze i poprawią efektywność przedsiębiorstwa.

Niniejsza praca ma na celu analizę tej hipotezy w sztucznym modelu wieloagentowym. Po pierwsze, poprzez zaproponowanie jednego z wielu możliwych algorytmów optymalizacji działania przedsiębiorstwa poprzez wykorzystanie istniejących technik modelowania predykcyjnego (*ang. predictive analytics*). Po drugie przez sprawdzenie, jak tak podejmowane decyzje będą wpływać na funkcjonowanie przedsiębiorstwa i czy będzie ono funkcjonować efektywniej, niż gdyby zastosować w nim dotychczasowe praktyki biznesowe.

2 Cel, założenia i podstawy teoretyczne pracy

Praca ma na celu zaproponowanie heurystyki optymalizacji podejmowania decyzji w przedsiębiorstwie na podstawie modelowania predyktywnego oraz sprawdzenie w modelu wieloagentowym, jak zaimplementowanie takiego algorytmu wpływa na wyniki firmy .

2.1 Koncepcja pracy

Rozważane w pracy przedsiębiorstwo należy do sektora szybko zbywalnych towarów konsumpcyjnych (*ang. fast moving consumer goods, FMCG*) i zajmuje się zarówno ich produkcją, jak i dystrybucją do sklepów detalicznych. Na podstawie historycznych danych o transakcjach i klientach prognozowany będzie krótkoterminowy wolumen sprzedaży w każdym z prowadzonych sklepów. Otrzymana wiedza zostanie wykorzystana do optymalizacji procesów logistycznych, przez co rozumiane jest wybranie tras dostaw i alokację wśród nich wolumenów produktów tak, aby zysk firmy był jak największy.

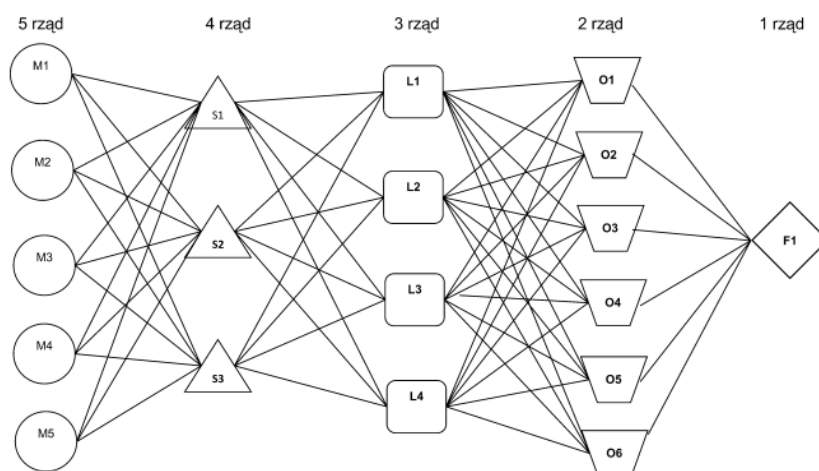
W celu zaprezentowania wyniku działania powstałego w ten sposób algorytmu, zostanie zbudowany model wieloagentowy symulujący rynek i zachowania klientów. Z jego pomocą sprawdzimy wpływ działania algorytmu na decyzje firmy oraz jej wyniki finansowe i operacyjne.

2.2 Podstawy teoretyczne

2.2.1 Przedsiębiorstwo jako system wieloelementowy

Na możliwość wykorzystania modeli wieloagentowych do badania i zarządzania systemami logistycznymi wskazują m.in. Moyaux et al. (2006) czy Kawa (2010). W swoich pracach zauważyli oni, że *producenci, dostawcy, odbiorcy* oraz inni uczestnicy łańcucha logistycznego mogą być opisani jako sieć autonomicznych, współpracujących ze sobą agentów, jak pokazane zostało to na wykresie 1. Takie podejście, i wynikająca z niego możliwość wykorzystania modeli wieloagentowych pomaga w rozwiązywaniu problemów operacyjnych, na jakie wskazuje Kawa (2010). Należy bowiem zwrócić uwagę, że w zakresie wyboru tras i zarządzania flotą wieloetapowe łańcuchy dostaw wielu produktów są problemami NP-trudnymi, szczególnie, że decyzje podejmowane lokalnie są współza-

leżne.¹ Ponadto, jak zauważa Kawa (2010), w sieci przedsiębiorstw pomiędzy dostawcami kolejnych rzędów (tj. fabryki, magazyny, sklepy) może istnieć wiele połączeń które są wobec siebie konkurencyjne. Przykładowo, magazyn może zaopatrywać się w wielu fabrykach. Zastosowanie w tej dziedzinie modeli wieloagentowych pozwala więc na zbadanie, jak decyzje podejmowane na jednym z etapów łańcucha dostaw wpłyną na cały system i innych uczestników.



Wykres 1: Łańcuch dostaw w branży komputerowej przedstawiony przez Kawa (2010) jako graf skierowany *Źródło:* Kawa (2010)

Podjęcie opiera się na obserwacji, że relacje pomiędzy jednostkami w przedsiębiorstwie są analogiczne do relacji uczestników łańcucha dostaw. Porter (1985) zauważył, że działalność przedsiębiorstwa to de facto sekwencja działań, która na każdym ogniwie zwiększa wartość dla odbiorcy. Zasady funkcjonowania opisywanego przez Portera *łańcucha wartości* są identyczne co do opisywanego przez Moyaux et al. (2006) i Kawa (2010) łańcucha dostaw. Relacje pomiędzy kolejnymi jego elementami można przedstawić w sposób zaproponowany przez Kawa (2010) — z wykorzystaniem grafu skierowanego, jak zaprezentowano na wykresie 1. Podobieństwo to podkreśla fakt, że przedsiębiorstwa poprzez strategię *integracji wertykalnej* swym zasięgiem mogą w rzadkich przypadkach objąć całość łańcucha dostaw.

¹Decyzje podjęte na krańcowych etapach łańcucha wpływają na wcześniejsze lub późniejsze etapy, co Moyaux et al. (2006) opisuje jako m.in. "bullwhip effect".

Warto zauważyć, że przedsiębiorstwa często dysponują wieloma duplikującymi swoje działania jednostkami ², przez co łańcuch ten jest nieliniowy i podobne jak w łańcuchu logistycznym problem zarządzania nim będzie problemem NP-trudnym.

Zdefiniowanie jako agentów poszczególnych jednostek przedsiębiorstwa jest przy tym spójne z określoną przez Wooldridge i Jennings (1995) charakterystyką agenta, który według ich postulatów posiada :

- autonomię — poszczególne jednostki przedsiębiorstwa podążają za strategią i celami narzuconymi przez zarząd, ale mają swobodę w podejmowaniu decyzji operacyjnych.
- zdolności do komunikacji — pomiędzy jednostkami przedsiębiorstwa istnieje asymetria informacji, dlatego komunikują się one zarówno między sobą (raportowanie do zarządu, spotkania) jak i z otoczeniem (relacje z klientami).
- reaktywność — jednostki przedsiębiorstwa reagują na zmiany rynkowe oraz zmiany wewnątrz przedsiębiorstwa, poprzez dostosowywanie decyzji operacyjnych.
- proaktywność — jednostki przedsiębiorstwa podejmują inicjatywy mające na celu zwiększyć wartość przedsiębiorstwa, jak działalność innowacyjna bądź ekspansja.

Dlatego w niniejszej pracy będziemy rozważać model wieloagentowy (zob. rozdział 3), w którym według założeń na przedsiębiorstwo składać się będzie wiele powiązanych ze sobą elementów działających w ramach środowiska modelu wieloagentowego.

2.2.2 Modelowanie predykcyjne

W procesach logistycznych i produkcyjnych kluczowym wyzwaniem jest niepewność związana ze zmiennością sprzedaży i jej wartości w chwili $t + 1$. Jak wskazuje James et al. (2013) do zmniejszenia niepewności możemy wykorzystać metody statystyczne, poprzez prognozowanie sprzedaży. Jak stwierdza James et al. (2013), zakładając, że dysponujemy zbiorem n obserwacji p zmiennych, możemy zbadać ich relację ze zmienną

²Dobrym przykładem są tutaj zakłady samochodowe, które mogą produkować dany model w różnych krajach. Zmiana fabryki powoduje przy tym radykalną zmianę łańcucha dostaw.

wyjaśnianą y i otrzymać *model*, który dla nowych — nieanalizowanych wcześniej — obserwacji $x_1, x_2 \dots x_n$ zwraca przewidywaną wartość zmiennej objaśnianej \hat{y} . Różnorodne metody modelowania zmiennej objaśnianej (wspólnie nazywane przez James et al. (2013) uczeniem statystycznym, *ang. statistical learning*) mogą być wykorzystane do modelowania predykcyjnego, tj. przewidywania przyszłych wydarzeń na podstawie przeszłej historii danych, w tym również przyszłego wolumenu sprzedaży w przedsiębiorstwie.

Zastosowanie metod *statistical learning* w przedsiębiorstwach potwierdza Buckinx et al. (2007), który wskazywał na możliwość prognozowania lojalności klienta na podstawie wewnętrznych danych o transakcjach, oraz Davenport et al. (2011), który opisuje szereg studiów przypadku firm, w których wykorzystuje się istniejące dane o transakcjach do przewidywania przyszłych zakupów klientów. Jednym z podanych przez niego przykładów jest Tesco, które na podstawie zebranych danych przewiduje, jakich produktów będzie potrzebował w najbliższym czasie ³, i odpowiednio wcześniej wysyła mu bony na te produkty. ⁴ Również podczas panelu *Strategia B2C w erze Big Data — jak wykorzystać potencjał danych* na XXV Forum Ekonomicznego w Krynicy przedstawiciele polskiego biznesu zwracali uwagę na szerokie wykorzystanie modelowania predykcyjnego również w nasz gospodarce. ⁵

Podane przykłady dają nam podstawy, żeby w przypadku optymalizowanego przedsiębiorstwa zakładać, że dane o każdej transakcji są zapisywane wraz z niektórymi danymi osobowymi klienta ⁶, a cały zbiór danych może być wykorzystany do przewidywania sprzedaży w chwili $t + 1$. Dlatego w pracy będziemy zakładać, że dla każdej transakcji

³W aspekcie praktycznym, można zdobyć taką informację obserwując zakupy klientów o podobnym profilu i dostrzegając w zakupach pewne wzorce.

⁴Klient widząc atrakcyjną ofertę na produkty których właśnie potrzebuje będzie bardziej skłonny do zrobienia zakupów akurat w Tesco.

⁵Jednak jak zwracano uwagę, *big data* i *modelowanie predykcyjne* służą głównie do pozyskiwania danych do późniejszego manualnego przetworzenia i wyciągnięcia z nich wniosków, a nie automatyzacji podejmowania decyzji, co rozważamy w tej pracy

⁶To stwierdzenie opiera się na opisywanym przez Davenport et al. (2011) przypadku Tesco i zastosowanej przez nich metody zbierania danych. Możliwość zbierania danych o transakcjach określonego klienta daje karta lojalnościowa (lub konto, w przypadku e-commerce), na którą rejestrowana jest każda transakcja. Praktyką jest, żeby przy okazji tworzenia karty lojalnościowej zbierać informacje o kliencie w ankiecie (zakres danych zależy od praktyki korporacyjnej). Dzięki temu, przedsiębiorstwa są w stanie przypisać do zakupów dane osobowe jak płeć, miejsce zamieszkania, wykształcenie etc.

w sklepie dysponujemy zbiorem informacji, zawierające dane o transakcji (*data, miejsce, rodzaj płatności*), produkcie (*nazwa produktu, cena, ilość*) oraz dane opisujące klienta (*płeć, wiek, zarobki, wykształcenie*).

Podejście zastosowane w pracy zakłada, że na podstawie tak uzyskanego zbioru danych prognozujemy kolejno następujące wartości, które łącznie dadzą nam informacje o sprzedaży w danym sklepie w chwili $t + 1$:

- liczebność poszczególnych grup klientów ⁷ odwiedzających sklep w chwili $t + 1$,
oraz, w zależności od zastosowanego podejścia,
- prawdopodobieństwo z jakim klient o danej charakterystyce kupi produkt,
- produkt wybrany przez danego klienta.

Dwa wymienione podejścia różnią się fundamentalnie jeśli chodzi o to, czym jest zmienna objaśniana. Jak wskazuje James et al. (2013), zmienna objaśniana może przyjąć różne dziedziny — m.in. zmiennej binarnej (1/0), prawdopodobieństwa, *log odds* lub klasy — i z tego względu każdy z przypadków różni się metodami, które możemy zastosować. W pierwszym przypadku chcemy otrzymać liczbę, której przedział powinien być ograniczony w zakresie (0, 1). W drugim przypadku, zależy nam na przyporządkowaniu rekordu do którejś z już określonych klas. Według sugestii James et al. (2013) i Hastie et al. (2001), do prognoz w modelu zastosowane zostaną następujące metody:

- do prognozowania liczby klientów — regresję metodą OLS (*metoda najmniejszych kwadratów, ang. ordinary least squares*),
- do prognozowania prawdopodobieństwa zakupu — regresję logistyczną (*ang. logistic regression*),
- do prognozowania wyboru produktu — metody klasyfikacyjne np. K-najbliższych sąsiadów (*ang. K-nearest neighbours*), drzewa klasyfikacyjne (*ang. classification tree*),

jak również metody nie służące bezpośrednio do modelowania \hat{y} , jednak wspierające proces predykcyjny oraz symulowanie decyzji konsumenckich w modelu wieloagentowym:

⁷Przez poszczególne grupy klientów rozumiemy klientów o wspólnych cechach.

- pomiar odległości (*ang. distance scaling*), poprzez liczenie odległości euklidesowej (*ang. euclidean distance*) pomiędzy dwoma zbiorami danych i stworzenie obliczenie macierzy niepodobieństwa (*ang. dissimilarity matrix*),
- eliminację zmiennych (*ang. backward elimination*), która jest jednym z podejść wyboru podzbiorów (*ang. subset selection*) do selekcji zmiennych wyjaśniających, które wspólnie tworzą najlepszy model,
- prawdopodobieństwo warunkowe do przewidywania, jakie cechy będą mieli konsumenci odwiedzający sklep w $t + 1$.

2.2.3 Zadanie optymalizacyjne

Rozważmy przedsiębiorstwo, które za argumentacją przedstawioną w rozdziale 2.2 oraz obserwacjami Moyaux et al. (2006) i Kawa (2010) przedstawiamy jako system składający się z wielu elementów. Zakładamy, że rozważane przedsiębiorstwo składa się ze:


- skończonego zbioru *fabryk* oznaczonych przez FA, z generycznym elementem $fa_n \in FA$,
- skończonego zbioru *magazynów* oznaczonych przez MA, z generycznym elementem $ma_n \in MA$,
- skończonego zbioru *sklepów* oznaczonych przez SK, z generycznym elementem $sk_n \in SK$,
- oraz *zarządu*, pełniący rolę centralnego koordynatora.

Jak zauważył Kawa (2010), jeśli rozpatrujemy przedsiębiorstwo pod kątem procesów logistycznych, możemy zaobserwować, że jednostki przedsiębiorstwa będą wspólnie tworzyć graf skierowany $S = \{FA \cup MA \cup SK, D\}$ (zob. wykres 2), gdzie jednostki przedsiębiorstwa $fa \in FA, ma \in MA, sk \in SK$ będą wierzchołkami grafu, a trasy dostaw pomiędzy jednostkami będą krawędziami grafu $d \in D = D_1 \cup D_2 = \{(i, j) : i \in FA, j \in MA\} \cup \{(i, j) : i \in MA, j \in SK\}$.

Planowanie produkcyjno-logistyczne w tak opisanym przedsiębiorstwie będzie polegało na alokacji wolumenów produkcji na poszczególne ścieżki $w \in W = (d_1, d_2)$, gdzie $d_1 = (fa, ma)$, a $d_2 = (ma, sk)$.

Należy zaznaczyć, że optymalizacja alokacji wolumenów dostaw na ścieżkach zamiast na krawędziach ma znaczenie praktyczne dla przedsiębiorstw, szczególnie międzynarodowych. Dzisiejsze trendy globalizacyjne spowodowały, że często produkcja w danym kraju trafia na kilka rynków, a każda z partii musi być dostosowana do warunków rynków lokalnych⁸. Aby to umożliwić, w momencie produkcji produkt musi mieć

⁸Rozumieny przez to zarówno aspekty regulacyjno-prawne, jak i różnice w preferencjach klientów związane z lokalną kulturą (przykładowo, samochody z bydlęcą skórą nie będą hitem na rynku indyjskim). Dodatkowo, w niektórych branżach, jak samochodowej, można dostosowywać specyfikację zamawianego produktu podczas zakupu. W takim przypadku również należy zapewnić, że trafi on do miejsca docelowego.



Wykres 2: Rozważane przedsiębiorstwo przedstawione jako graf kierunkowy.

Źródło: opracowanie własne.

określone miejsce docelowej dostawy. W logice grafu oznacza to, że przedsiębiorstwo musi z góry określić ruch produktu na całej ścieżce, a nie tylko na fragmencie ścieżki do następnej krawędzi. Drugie podejście mogłoby spowodować, że kierowanie produktu do miejsca docelowego byłoby utrudnione i dodawałoby kompleksowość operacyjną żeby kontrolować proces.

Równanie zysku przedsiębiorstwo

W tak zdefiniowanym grafie proces logistyczny odbywa się przepływem wzdłuż krawędzi D , a z każdym z elementów grafu $j \in S$ związany jest koszt przepływu $k_j = f_j(x_j)$ ⁹, gdzie f jest dowolną funkcją kosztu, j rozważanym elementem grafu S , a x_j wolumenem produkcji przechodzącym przez dany element.

Sprzedaż towarów przepływających przez graf następuje w sklepach. Zakładając, że przedsiębiorstwo nie stosuje dyskryminacji cenowej, cena produktu będzie globalna

⁹Warto zauważyć, że koszt przesyłu nie oznacza tylko kosztów transportu, ale także kosztów produkcji w fabryce, kosztów magazynowania oraz kosztów obsługi procesów sprzedaży w sklepie. Dlatego koszt f_j będzie definiowany nie tylko na krawędziach D , ale każdym elemencie grafu S — zarówno wierzchołków, jak i krawędzi.

i stała ¹⁰. Przychód r w każdym ze sklepów $sk \in SK$ przy cenie p będzie równy $r = p \times q_{sk}$, gdzie q to sprzedaż w wybranym sklepie sk ¹¹.

Dla całego systemu funkcja zysku systemu P_s zadana równaniem (1) będzie zależała przede wszystkim od alokacji wolumenów pomiędzy poszczególne elementy grafu,

$$P_s = \sum_{sk \in SK} p \times q_{sk} - \sum_{j \in S} f_j(x_j), \quad (1)$$

gdzie p to stała cena, q_{sk} sprzedaż w sklepie $sk \in SK$ spełniająca warunek $q_{sk} \leq x_{sk}$ ¹², a f_j to dowolna funkcja kosztu zależna od wolumenu x_j w elemencie grafu $j \in S$.

Zadanie maksymalizacji byłoby względnie proste ¹³, gdybyśmy mieli doskonałą informację na temat poziomu sprzedaży w każdym ze sklepów w chwili $t + 1$. Na taką wiedzę nie możemy liczyć ani w tej pracy, ani w rzeczywistości, dlatego rozwiązaniem proponowanym w niniejszej pracy jest zastosowanie modelowania predykcyjnego (*predictive analytics*), w celu prognozowania liczby klientów i ich wyborów w każdym ze sklepów w najbliższych okresach czasu. ¹⁴

Ponadto, jak warto zauważyć, nie możemy liczyć na to, że funkcja kosztu f_j będzie liniowa. Empiryczna obserwacja powszechności efektów skali w każdym z sektorów gospodarki każe nam zakładać, że funkcja kosztu będzie dowolną funkcją nieliniową. Warto przy tym zauważyć, że efekty skali mogą być zarówno dodatnie, jak i ujemne, jak również mogą występować wspólnie ¹⁵.

Trzecim aspektem, który trzeba wziąć pod uwagę jest złożoność obliczeniowa. Nawet dla prostego układu, lecz wolumenu produkcji ponad 1000 sztuk sprawdzenie zysku w przypadku wszystkich kombinacji alokacji wymaga olbrzymiej liczba iteracji — liczba kombinacji będzie liczbą Strilinga II rodzaju. Mimo znaczącego wzrostu mocy kompute-

¹⁰Rozumiemy przez to, że cena jest identyczna dla wszystkich klientów, dla wszystkich sklepów oraz wszystkich okresów czasu t .

¹¹Warto zauważyć, że sprzedaż q_j nie jest tym samym co wolumen n_j , ponieważ dostarczenie towaru do sklepu nie gwarantuje jego sprzedaży.

¹²Sprzedaż w sklepie nie może być większa niż wolumen dostaw który trafił do sklepu.

¹³Pomijając aspekt złożoności obliczeniowej.

¹⁴Obecnie w przedsiębiorstwach rzadko stosuje się zaawansowane sposoby prognozowania sprzedaży (*predictive analytics*), a zarządzanie dostawami odbywa się raczej metodą manualnego uzupełniania zapasów.

¹⁵Dodatnie gdy produkcja będzie mniejsza niż optymalny poziom produkcji, a ujemne po przekroczeniu optymalnych mocy produkcyjnych.

rów w ostatnich latach, wolumeny produkcji w dużych przedsiębiorstwach oraz złożoność tras logistycznych sprawia, że to podejście jest kompletnie niepraktyczne i należy szukać alternatywnych podejść, upraszczających problem.

2.3 Proponowany algorytm optymalizacyjny

W proponowanym algorytmie optymalizacyjnym wykorzystujemy fakt, że dzięki modelowaniu predyktywnemu możemy prognozować wolumen sprzedaży q_{sk} w każdym ze sklepów $sk \in SK$. Ponieważ równolegle zakładamy brak stosowania dyskryminacji cenowej, część przychodowa równania (1) będzie nam znana. Możemy ją oznaczyć jako stałą r_s , oznaczającą przychód całego systemu.

$$P_s = r_s - \sum_j f_j(x_j). \quad (2)$$

Ponieważ w rozdziale 2.2.3 stwierdziliśmy, że ze względów biznesowych naszym celem jest optymalizacja alokacji wolumenu na ścieżkach, zauważmy, że x_j będzie równe $\sum_{w:j \in w} x_w$, sumie wolumenów x_w na wszystkich ścieżkach $w \in W$ przechodzących przez element grafu $j \in S$, co oznaczamy z niewielkim nadużyciem zapisu jako $j \in w$, dzięki czemu równanie możemy zapisać jako:

$$P_s = r_s - \sum_j f_j\left(\sum_{w:j \in w} x_w\right). \quad (3)$$

Dzięki temu przekształceniu możemy wyznaczyć gradient funkcji zysku

$$\nabla P_s = \left[\frac{\partial P_s}{\partial x_{w_1}} \dots \frac{\partial P_s}{\partial x_{w_n}} \right] \quad (4)$$

gdzie n to liczba ścieżek w zbiorze W .

Zauważmy, że jeśli obliczymy gradient w punkcie, wskaże on nam kierunek najszybszych wzrostów wartości funkcji zysku P_s w zależności od ulokowania kolejnej jednostki produktu na wybraną ścieżkę. Proponowany algorytm wykorzystuje tę właściwość i zakładając, że działanie algorytmu zaczyna się, gdy każda ze ścieżek $w \in W$ jest pusta, tj. każde $x_w = 0$, jego działanie składa się z podanych niżej kroków. Dla przejrzystości zapisu przez χ_w będziemy oznaczali wektor $(x_{w_1}, \dots, x_{w_n})$.

Ustal punkt startowy $\chi = (0, \dots, 0)$.

1. Wyznacz funkcję zysku P_s (symbolicznie).
2. Wyznacz gradient ∇P_s (symbolicznie).

Początek pętli

3. Oblicz gradient w punkcie χ .
4. Dla każdego elementu ∇P_s sprawdź
 - czy odpowiadająca mu wartość pochodnej cząstkowej jest mniejsza od 0 (optymalizacja),
 - czy dodanie kolejnego produktu do ścieżki spowoduje, że w sklepie leżącym na ścieżce przestanie być spełniany warunek $q_{sk} \leq x_{sk}$ ¹⁶ (ograniczenia).
5. Jeśli którykolwiek z powyższych jest prawdą, "usuń"¹⁷ ścieżkę z wektora $\nabla P_s(\chi)$.
6. Jeśli wektor $\nabla P_s(\chi)$ nie jest pusty, z pozostałych elementów, wybierz ścieżkę o największej wartości poprzez dodanie 1 na współrzędnej i zmień wektor χ .
7. Powtórz od kroku 3. dopóki wektor $\nabla P_s(\chi)$ nie będzie pusty.

Działanie algorytmu w standardzie UML zaprezentowane zostało na wykresie 3.

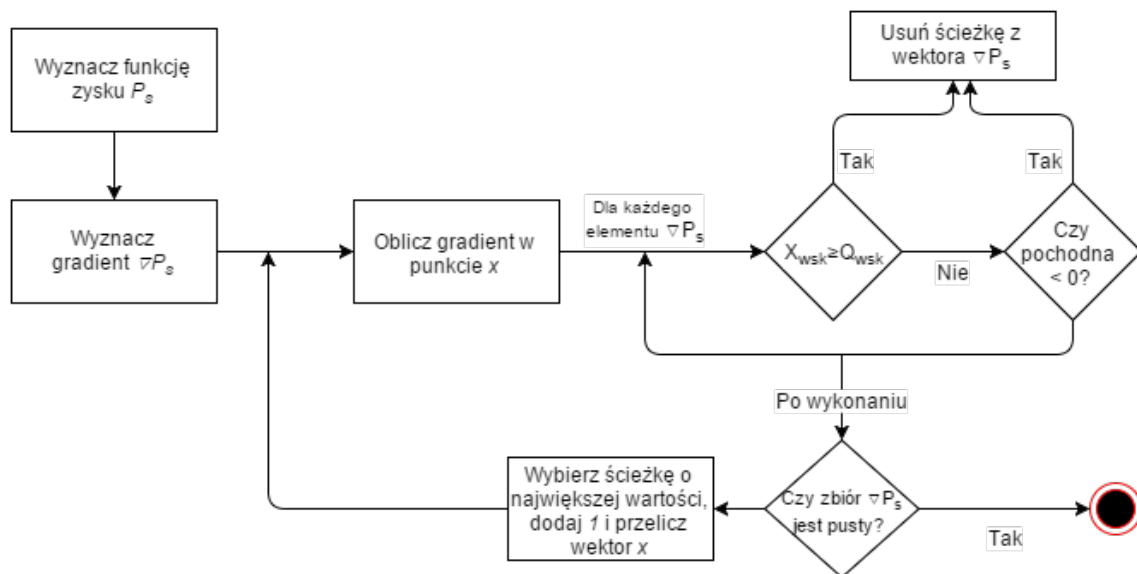
2.4 Cechy algorytmu optymalizacyjnego

Algorytm działający według reguł opisanych w rozdziale 2.3 będzie heurystyką, ponieważ kierując się najszybszymi wzrostami w punkcie obliczania gradientu może ominąć maksimum globalne, przez co nie gwarantuje znalezienia najlepszej alokacji w przypadku wystąpienia nietypowych funkcji kosztu. Gwarantuje za to znalezienie aproksymacji maksimum lokalnego i zakończenie pętli¹⁸. Biorąc pod uwagę, że w aspekcie praktycznym większość funkcji kosztów nie będzie miało nietypowych kształtów, algorytm też powinien być w zupełności wystarczający do większości zastosowań optymalizacyjnych w praktyce.

¹⁶Wolumen dostaw będzie większy niż prognozowany wolumen sprzedaży.

¹⁷Usunięcie oznacza, że na tej współrzędnej nie będziemy już dodawać towaru w kolejnych iteracjach.

¹⁸Tj. nie ma możliwości, żeby iterował w nieskończoność.



Wykres 3: Proponowany algorytm optymalizacyjny

Ograniczeniem algorytmu jest to, że szukając kolejnych optymalnych punktów operuje on wyłącznie na dyskretnych wartościach x_w (zamiast ciągłych). Wynika to z założenia, że w procesach logistycznych nie możemy przekroić i przetransportować pół produktu, a nawet ładunek drobnicowy będzie miał swoją jednostkę najmniejszego możliwego transportu, jak paleta, tona, kontener etc.

Algorytm nie oblicza wszystkich możliwych kombinacji alokacji wolumenów, a używa gradientu do oszacowania najbardziej opłacalnej trasy dla każdego z produktów, dlatego czas jego wykonania będzie znacznie krótszy w stosunku do algorytmu obliczającego wszystkie możliwe sytuacje. Liczba iteracji potrzebnych do kalkulacji zysku w przypadku każdej możliwej kombinacji alokacji będzie liczbą Stirlinga II rodzaju, a w przypadku algorytmu maksymalna liczba iteracji będzie iloczynem liczby produktów oraz liczby ścieżek.¹⁹

Warto zwrócić uwagę na ciekawą właściwość algorytmu. Gdy przez skalę działalności firmy jej graf będzie bardzo rozbudowany, sposób działania algorytmu pozwala rozważać tylko najbardziej prawdopodobne trasy, zamiast wszystkich. Pozwoli to zmniejszyć liczbę iteracji, jednocześnie zachowując integralność grafu. Inne metody, które w większym stopniu opierają się na iteracjach po elementach grafu, do osiągnięcia analogicznego

¹⁹W praktyce będzie mniejsza, ponieważ algorytm pozbywa się nierentownych i zapełnionych ścieżek.

efektu wymagałyby zmiany struktury grafu, co jest rozwiązaniem niepraktycznym i może w wielu przypadkach zaburzyć wynik.

3 Model

W celu sprawdzenia działania algorytmu zbudowany został model wieloagentowy, który symuluje lokalny rynek na wybrany produkt, wraz z zachowaniami konsumentów i funkcjonowaniem przedsiębiorstwa.

3.1 Koncepcja modelu

Celem pracy jest stworzenie modelu wieloagentowe symulującego rynek (w szczególności kładąc nacisk na aspekt sprzedaży oraz dostaw) gdzie moglibyśmy sprawdzić wpływ działania algorytmu na wyniki przedsiębiorstwa. Inspirując się Kaminski (2012), zakładamy, że możemy stworzyć heterogenicznych agentów oraz symulować ich decyzje celu modelowania zachowań i trendów na rynku.

Zgodnie z powyższym, oraz argumentacją zawartą w rozdziale 3.1 w modelu znajdują się następujący typy agentów:

- **klienci**, który zgodnie z założeniem będą heterogeniczni i definiowani przez cechy demograficzne ²⁰, wpływające na podejmowane przez nich decyzje,
- **przedsiębiorstwo**, sprzedające *produkt* na rynku. Zgodnie z podejściem przedstawionym w 2.2, przedsiębiorstwo będzie rozumiane jako zbiór:
 - fabryk
 - magazynów
 - sklepów
 - oraz zarządu, pełniącego funkcje koordynującą,
- **konkurencji**, zachowującej się pasywnie w stosunku do rynku, konsumentów i symulowanego przedsiębiorstwa, ale wprowadzającej na rynek szereg produktów stanowiących alternatywę dla produktu symulowanej firmy ²¹,

²⁰Są to między innymi wiek, zarobki, wykształcenie, zainteresowania — zostanie to dokładnie opisane w dalszej części pracy.

²¹Tj. konkurencja nie zmienia decyzji podjętych przed rozpoczęciem gry, i w założeniu ma stanowić jedynie alternatywę dla konsumentów.

- **produktów** dostępnych na rynku, z których każdy zdefiniowany jest unikalnymi cechami określającymi jakość, typ i cenę produktu, przez co każdy z produktów będzie preferowany przez inną grupę konsumentów, a preferencje są oparte na danych ze świata rzeczywistego (zob. rozdział 3.5.3).

Aspekt lokalizacji Aby dobrze odwzorować kluczowy aspekt lokalizacji i dróg w łańcuchach dostaw, symulowany rynek jest osadzony w *wirtualnym mieście*. Oznacza to, że każdy agent ma swoją lokalizację w macierzy o wymiarach $x \times y$ i może się w niej poruszać po wyznaczonych drogach.

Lokalizacja wpływa na działania agenta. Przykładowo, klient kupi produkt tylko w sklepie który będzie na jego ścieżce, a dostawa z magazynu do sklepu będzie tym droższa, im bardziej oddalone będą od siebie.

Symulowanie decyzji konsumenckich W modelu konsumenci nieustannie poruszają się po *mapie*, bez związku z działaniem przedsiębiorstwa ²². W każdej jednostce czasu t klienci z prawdopodobieństwem p będą potrzebować symulowany produkt. Wywołanie tego zdarzenia spowoduje, że podczas losowej podróży z punktu A do B odwiedzą oni losowy sklep ze wszystkich sąsiadujących z trasą ²³, a następnie wybiorą jeden z produktów dostępnych w sklepie ²⁴.

Symulacja wyboru opiera się na danych o preferencjach konsumenckich zebranych w grze ekonomicznej na próbie 169 badanych, w wyniku których otrzymano 1860 rekordów danych ²⁵. Na ich podstawie zbudowane zostało drzewo klasyfikacyjne opisujące prawdopodobieństwo zakupu produktu o określonych cechach (zob. rozdział 3.5.3) przez danego konsumenta.

²²Ruchy są wywołane przez losowe zdarzenia którym może być poddany konsument. Zdarzenia wymagają od niego podróży do jednego z predefiniowanych miejsc — jak praca czy dom innego agenta

²³Warto zwrócić uwagę na założenie, że klient musi być "fizycznie obecny" w sklepie (na tyle, ile jest to możliwe w modelu) jest bardzo ważne dla modelu. Wynika z tego, że lokalizacja jest bardzo ważna dla wyników sklepu. Ponadto, najczęściej sklep mijając będą klienci mieszkający w pobliżu, dlatego zakupy w kolejnych okresach czasu będą tworzyć wzorce.

²⁴Sklepy nie przynależą do przedsiębiorstwa, więc znajdują się tam także produkty konkurencji, i spośród wszystkich klient dokonuje wyboru.

²⁵Gra ekonomiczna została dokładniej opisana w rozdziale 3.6

Ponieważ każdy konsument-agent w modelu ma swoje unikalne cechy demograficzne i charakteru, spójne z danymi zebranymi w ankiecie, wykorzystujemy zbudowane drzewo klasyfikacyjnego do określenia wyboru, jakiego najprawdopodobniej w świecie rzeczywistym dokonał by jego odpowiednik, posiadający identyczne bądź zbliżone cechy ²⁶. Przeprowadzając podobny proces dla każdego konsumenta w modelu, otrzymujemy dynamiczną symulację rynku produktów szybkozbywalnych (*ang. FMCG*).

Decyzje przedsiębiorstwa

Ponieważ, jak zostało wspomniane, konsument wybiera produkt tylko z gamy dostępnych w sklepie, kluczowe dla sukcesu przedsiębiorstwa w modelu jest dostarczenie w każdej jednostce czasu t odpowiedniej ilości produktów do każdego ze sklepów ²⁷. Oznacza to, że przed rozpoczęciem każdej tury przedsiębiorstwo musi podjąć szereg decyzji o m.in.

- odpowiednim poziomie produkcji,
- wolumenie dostaw do każdego ze sklepów w sieci,
- rozdzieleniu wolumenów pomiędzy jednostki przedsiębiorstwa, tj. ile z całkowitego wolumenu ma wyprodukować fabryka A , a ile fabryka B ,
- jaki wolumen dostaw powinien zostać skierowany na każdą z możliwych ścieżek.

W modelu przedsiębiorstwo agenci korzystają z predefiniowanych zasad podejmowania decyzji przez n jednostek czasu przed inicjalizacją działania algorytmu. Oparte są one na najczęstszych praktykach spotykanych w świecie rzeczywistym:

- towar zamawiamy jest zawsze z najbliższego magazynu,

²⁶Oczywiście, o wiele lepsze byłoby oparcie pracy o prawdziwe historie transakcji, jednak jest to niemożliwe ze względu na dużą poufność tych danych

²⁷W warunkach symulacji nie można zapełnić *półek sklepowych* do pełna, ponieważ a w sektorze FMCG zakładamy, że w czasie $t + 1$ produkty tracą zdolność do spożycia. Brak sprzedaży w czasie t oznacza stratę dla przedsiębiorstwa.

- ilość zamówionego towaru do każdego ze sklepów równa jest sprzedaży t_0 ²⁸.

Po n rundach, przez pozostałą ilość okresów t decyzje w przedsiębiorstwie podejmowane są na podstawie algorytmu optymalizującego, opisanego w rozdziale 2.3.

3.2 Zastosowane narzędzia

Model został zbudowany w języku programowania Python 2.7, z wykorzystaniem następujących bibliotek (zob.tabela 1) :

Tabela 1: Zastosowane biblioteki języka Python. Źródło: opracowanie własne.

Biblioteka	Źródło	Zastosowanie
Sympy	www.sympy.org	Wykorzystanie do obliczeń symbolicznych
scikit-learn	scikit-learn.org	Wykorzystanie bibliotek metod statystycznych

Kod programu dostępny jest pod adresem github.com/hubertguzera/master-thesis

3.3 Struktura programu

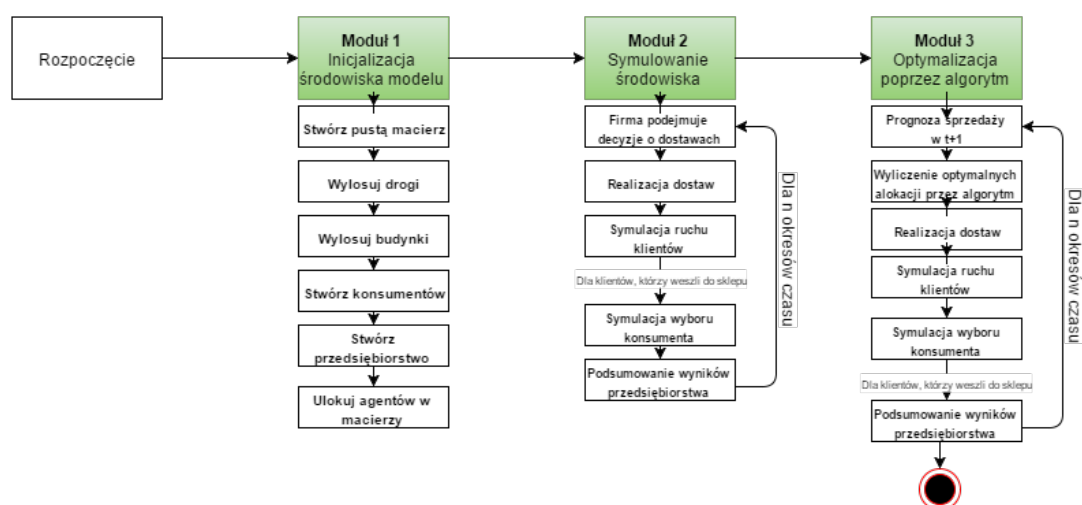
Program podzielony jest na trzy moduły, jak zaprezentowano na rysunku 4

- Pierwszy moduł odpowiada za stworzenie, w drodze losowań, środowiska w ramach którego toczy się symulacja, wraz z agentami i macierzą lokalizacji. ²⁹
- Drugi moduł przez n jednostek czasu t symuluje działanie rynku, w którym przedsiębiorstwo podejmuje decyzje według predefiniowanych zasad sterowań.
- Trzecia moduł po n rund symulacji inicjalizuje modelowanie predyktywne, które na koniec każdego czasu t prognozuje sprzedaż w $t + 1$. Wartość sprzedaży w

²⁸ t_0 to runda próbna, która ma na celu sprawdzenie popytu na rynku i nie jest zapisywana do wyników firmy. Jej wdrożenie ma na celu odzwierciedlenie w modelu wiedzy powszechnej o rynku. Przedsiębiorcy zazwyczaj wiedzą ile mogą sprzedać na podstawie tego, co sprzedawali w przeszłości albo na podstawie raportów rynkowych.

²⁹Model może pominąć tą część i wczytać pregenerowany świat w celu sprawdzenia różnych scenariuszy w statycznym świecie (ceteris paribus).

każdym ze sklepów jest przekazana do algorytmu optymalizacyjny, który wybiera optymalną alokację wolumenów dostaw na każdą ze ścieżek.



Wykres 4: Podglądowa struktura działania programu. *Źródło:* opracowanie własne.

3.4 Generowanie środowiska modelu

Klasa rynek

Za reprezentację tak opisanego środowiska modelu (zob. rozdział 3.1) odpowiada klasa *rynek*, wobec której dziedziczą wszystkie inne klasy występujące w modelu. Klasa *rynek* (i wszystkie dziedziczące) jest generowana dynamicznie i losowo³⁰. Konstrukcja klasy *rynek* w programie została zaprezentowana w diagramie 5.

Klasa świat

Klasa *swiat* zawarta w klasie *rynek* i zaprezentowana na diagramie 6 powstała w celu odpowiedniego odwzorowania kluczowego aspektu lokalizacji i dróg w łańcuchach dostaw, wzorując się na podejściu zastosowanym w *modelu segregacji Schellinga* (Schelling (1971)). Agenci osadzeni są w przestrzeni, reprezentowanej przez macierz klas *lokalizacja* o wymiarach (x,y). Dodatkowo, lokalizacje są połączone drogami, wymuszając na

³⁰Jednak może być zapisana jeśli istnieje konieczność replikacji obliczeń albo porównań.

rynek
swiat : class
symulowana_firma : class
tura : integer
produkty_na_rynku : class
__init__(self,swiat) : None
sprzedaz_w_sklepach(self) : None
nowatura (self) : None

Wykres 5: Diagram UML klasy *rynek* Źródło: opracowanie własne.

agentach poruszanie się tylko w obrębie ścieżek. Dzięki temu, w modelu będziemy mogli wiernie odwzorować wpływ odległości i wyboru trasy na efektywność procesów logistycznych, oraz zależność wyników sklepu od zamieszkującej okolicę populacji.

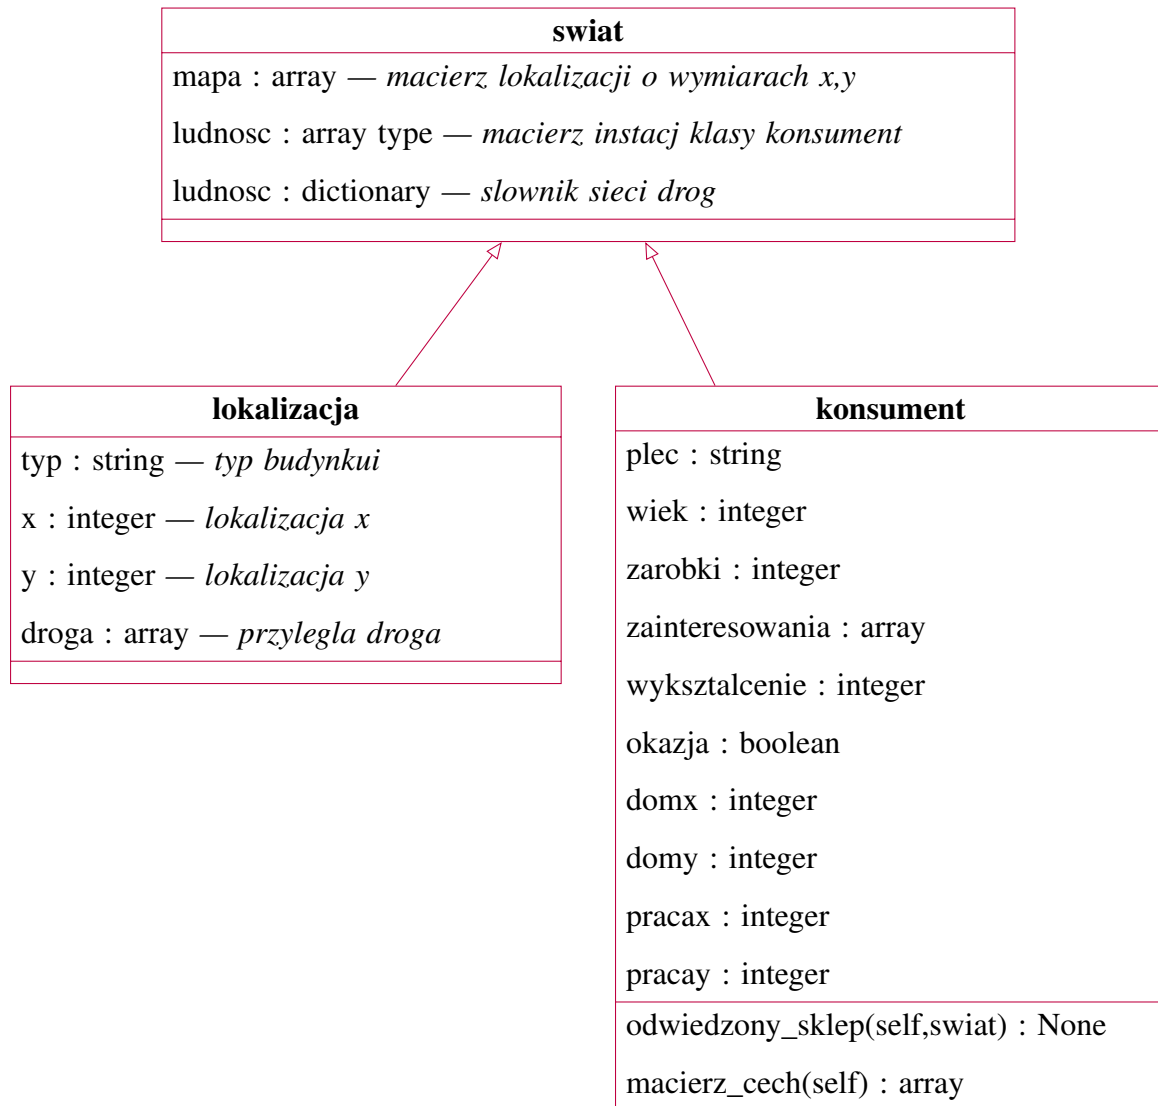
Macierz *mapa* generowana jest według algorytmu, który gwarantuje, że tak otrzymana mapa środowiska będzie spełniać warunki przedstawione w tabeli 2. Przykładowa *mapa* otrzymana w wyniku działania algorytmu widoczna jest na rysunku 7.

Tabela 2: Warunki generowania mapy środowiska. Źródło: opracowanie własne.

l.p	Warunek
1	Drogi krzyżują się i skręcają tylko pod kątem prostym
2	Poza skrzyżowaniami, drogi nie mają w sąsiedztwie innych dróg
3	Budynki mogą występować tylko w bezpośrednim sąsiedztwie drogi
4	Drogi stanowią ciągłą linię (nie ma drogi, do której nie można dojechać)
5	2 punkty od skraju mapy nie są generowane ani drogi, ani lokalizacje. ³¹
6	Budynki mogą występować tylko w bezpośrednim sąsiedztwie drogi

Trasy pomiędzy zadanymi punktami w modelu są wyszukiwane dynamicznie, na podstawie algorytmu wyszukiwania drogi. Odległości z kolei obliczane są poprzez sumowanie ilości punktów w zwracanym przez algorytm łańcuchu.

Algorytm oparty jest na metodach wyszukiwania ścieżek w grafach, dzięki założeniu, że każda droga o współrzędnej (x, y) na mapie jest punktem grafu, który może sąsiadować




Wykres 6: Diagram UML klasy swiat, lokalizacja i konsument *Źródło:* opracowanie własne.

z punktami o współrzędnych $(x - 1, y)$, $(x + 1, y)$, $(x, y + 1)$, $(x, y - 1)$ ³², o ile również są drogami.^{33 34}

³²Punkty $(x - 1, y - 1)$, $(x + 1, y - 1)$, $(x + 1, y + 1)$, $(x - 1, y + 1)$ wykluczamy przez wcześniejsze założenie, że drogi krzyżują się tylko pod kątem prostym.

³³Informacje o punktach i sąsiadujących przechowywane są w zmiennej nodes, która jest słownikiem, dla każdego klucza — punktu na mapie — przechowuje informacje o sąsiadujących punktach, np. $(3, 2) = [(3, 3)(4, 3)]$.

³⁴Pewnym ograniczeniem jest, że jako punkty grafu definiujemy tylko drogi, tak więc szukając trasy z punktu A do punktu B, de facto szukamy trasy z drogi przy punkcie A do drogi przy punkcie B.



Wykres 7: Przykładowa mapa — szary to drogi, niebieski — domy mieszkalne, czerwony i zielony — biurowce, pomarańczowy — sklepy, żółty — magazyny, błękitny — fabryki Źródło: opracowanie własne.

Algorytm, udostępniony przez Python Foundation ³⁵ i zaprezentowany w tabeli 8 ma następujące cechy

- jest rekurencyjny,
- nie jest losowy,
- nie gwarantuje znalezienia najkrótszej trasy.

```

1  def find_path(graph, start, end, path=[]):
2      path = path + [start]
3      if start == end:
4          return path
5      if not graph.has_key(start):
6          return None
7      for node in graph[start]:
8          if node not in path:
9              newpath = find_path(graph, node, end, path)
10             if newpath: return newpath
11  return None

```

Wykres 8: Algorytm wyszukiwania drogi Źródło: opracowanie własne.

³⁵<https://www.python.org/doc/essays/graphs/>

3.5 Agenci, ich rodzaje i właściwości

3.5.1 Konsumenci

Idąc za Kaminski (2012), w modelu stosujemy modelowanie rynku za pomocą heterogenicznych konsumentów. Stąd, każdy z konsumentów ma swoją unikalną charakterystykę rozumianą przez cechy demograficzne oraz cechy charakteru, które będą wpływać na jego wybory.

Aspekt lokalizacji i ruchu agenta jest symulowane zgodnie z opisem zawartym w rozdziale 3.1. Warto zwrócić uwagę na to, że chociaż agenci nieustannie poruszają się w ramach modelu, to pula lokalizacji w ramach których będą się przemieszczać jest ograniczona. Każdy z konsumentów będzie się przemieszczał tylko w wyniku predefiniowanych zdarzeń, których liczba dla każdego konsumenta jest ograniczona do czterech ³⁶, tak więc agent będzie przemieszczał się pomiędzy maksymalnie czterema lokalizacjami, tworząc pewne wzorce zachowań.

Dzięki temu, odwziewiamy zjawisko ze świata rzeczywistego, że konsumenci zazwyczaj robią zakupy w ograniczonej liczbie sklepów będących po drodze bądź niedaleko. Jest to bardzo istotny warunek funkcjonowania modelu, ponieważ losowy dobór klientów uniemożliwiłby modelowanie predykcje.

Każdy będzie definiowany w klasie o właściwościach zdefiniowanych w diagramie 9. Wartości cech dla każdego z konsumentów są losowane na podstawie rozkładów publikowanych przez Główny Urząd Statystyczny Główny Urząd Statystyczny (2011) oraz danych firmy Sedlak&Sedlak (Sedlak&Sedlak (2013)) ³⁷ w celu zagwarantowania odwziewiania struktury społeczeństwa. Ze względu na zastosowanie prawdopodobieństw warunkowych dla niektórych cech (np. zarobki są zależne od wcześniej wylosowanego wykształcenia) istnieje pomiędzy nimi korelacja. Przykładowe rozkłady pokazane są na rysunku 10a oraz 10b.

Poza zaprezentowanymi na histogramach danymi demograficznymi agenci posiadają zainteresowania określone zmiennymi binarnymi. W przeciwieństwie do danych demo-

³⁶Warto zauważyć, że każde ze zdarzeń wywołuje przemieszczenie do korespondującej lokalizacji, tak zdarzenie będzie zawsze wywoływać podróże tej samej lokacji

³⁷Raporty firmy Sedlak&Sedlak służyły do zbudowania tabeli prawdopodobieństwa wystąpienia danego wynagrodzenia w zależności od płci i wykształcenia. Reszta danych oparta na GUS

konsument
<p>plec : string</p> <p>wiek : integer</p> <p>zarobki : integer</p> <p>zainteresowania : array</p> <p>wykształcenie : integer</p> <p>okazja : boolean — <i>wskazanie powodu wyjścia z domu</i></p> <p>domx : integer — <i>współrzędna x domu</i></p> <p>domy : integer — <i>współrzędna y domu</i></p> <p>pracax : integer — <i>współrzędna x pracy</i></p> <p>pracay : integer — <i>współrzędna y pracy</i></p>
<p>odwiedzony_sklep(self,swiat) : None</p> <p>macierz_cech(self) : array</p>

Wykres 9: Diagram UML klasy konsument *Źródło:* opracowanie własne.

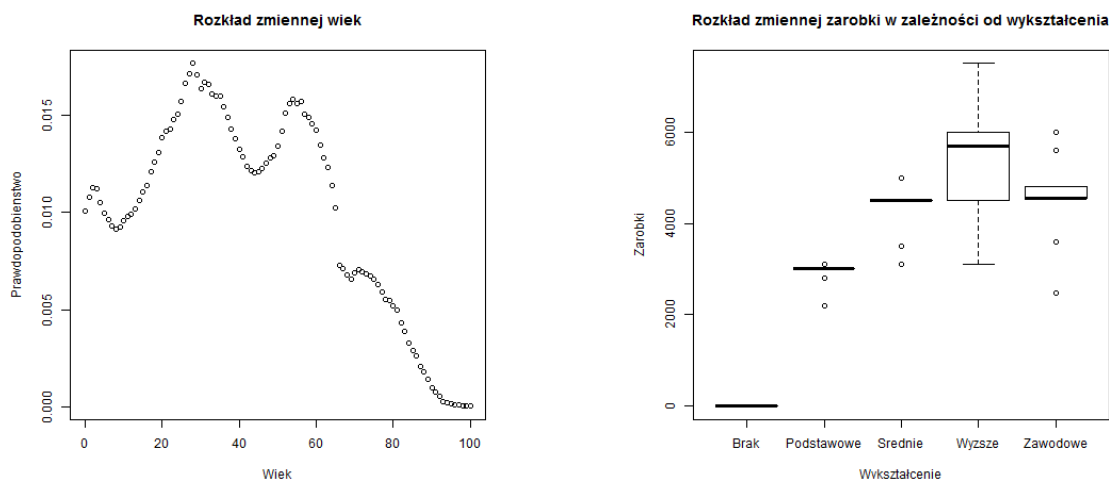
graficznych, są one niezależne, a każda z nich posiada identyczną szansę na wylosowanie. Celem ich wprowadzenia było stworzenie zmiennych, których nie byłyby skorelowane z danymi demograficznymi. Ponieważ mają wpływ na wybory klientów i nie są zapisywane w historii transakcji ³⁸, utrudniają przewidywanie sprzedaży.

3.5.2 Przedsiębiorstwo

Zgodnie z założeniami określonymi w rozdziale 1, symulowane przedsiębiorstwo jest zbiorem elementów. Zbiór ten należy w modelu do klasy *firma*, przechowującej w macierzach instancje klas *fabryka*, *magazyn*, *sklep*, jak zaprezentowano na diagramie 11. W klasie *firma* znajdują się także funkcje przynależne opisywanemu w strukturze modelu zarządowi, mające na celu koordynację działania przedsiębiorstwa.

Warto zauważyć, że klasy te mają wiele wspólnych właściwości, z wyjątkami obecnymi w klasie *sklep*. Wynika to z konieczności stworzenia funkcji symulujących procesy sprzedażowe oraz faktu, że sklepy mają dodatkowe zmienne przechowujące informacje o

³⁸W przeciwieństwie do danych demograficznych (wiek, wykształcenie, płeć) nie są znane przedsiębiorstwu w modelu i dlatego nie są zapisywane w historii transakcji.



(a) Rozkład prawdopodobieństwa zmiennej wiek

(b) Rozkład prawdopodobieństwa zmiennej wykształcenie

Wykres 10: Rozkłady zmiennych cech klasy konsument *Źródło:* opracowanie własne na podstawie danych Narodowego Spisu Ludności 2011, Główny Urząd Statystyczny (2011).

składzie towaru, klientach odwiedzających sklep w danej jednostce czasu t oraz historii transakcji.

3.5.3 Produkt

Jak zauważa Sagan (2011), który wskazuje na istnienie nurtu w dziedzinie modelowania strukturalnego zachowań klientów, które wykorzystywało zmienne marketingowe określające jakość produktu i liczbę cech³⁹. Opierając się tej obserwacji zakładamy, że każdy produkt charakteryzuje się cechami wpływające na prawdopodobieństwo jego zakupu przez konsumentów które mogą być wyrażone ilościowo.

Piwo jako symulowany produkt

Dlatego w modelu produkt definiujemy przez zestaw wybranych cech które odróżniają go od produktów konkurencji, które mogą przyjąć formę skali ocen, zmiennych

³⁹Mowa o tzw. nurcie poznawczym albo nurcie teorii przetwarzania informacji — TPI

binarnych bądź zmiennych kategorycznych.⁴⁰, a klasa *produkt* przechowujące jednowymiarową macierz z cechami produktu.

Warto odnotować, że w pracy przyjmujemy, że symulowanym produktem z branży FMCG jest piwo. Ten dość nieelegancki wybór motywowany jest głównie specyfiką produktu, która dobrze pasuje do wymagań stawianych przez model (szczególnie w aspekcie możliwości modelowania decyzji konsumenckich), wśród których należy zwrócić uwagę na:

- Wysoka sprzedaż i idący za tym wysoki obrót towaru w sklepach. Przeciętny polak pije 99 litrów piwa rocznie, co oznacza butelkę kupioną co mniej więcej drugi dzień. Dzięki temu możemy założyć, że prawdopodobieństwo zakupu piwa przez klienta to nawet 50% , a to z kolei gwarantuje odpowiednią liczbę iteracji do przeprowadzenia symulacji.
- Piwa mają silne marki o ugruntowanych cechach i grupach docelowych — reklamy piw zazwyczaj kierowane są do precyzyjnie określonych grup docelowych, co powoduje, że występuje wysoka zależność pomiędzy charakterystyką demograficzną klienta a piwem które wybierze,⁴¹. Przykładowo, piwo smakowe i pszeniczne będą trafiać do dwóch różnych grup klientów.

3.5.4 Konkurencja

W założeniach przyjmujemy, że konkurencja jest pasywna, tj. nie podejmuje działań ani decyzji w trakcie trwania symulacji. Wynika to z odmiennego celu badania, którym jest analiza działania algorytmów optymalizacyjnych. Nagłe zmiany sprzedaży spowodowane np. obniżeniem ceny przez konkurencję spowodowałyby wątpliwości interpretacyjne i są zbędne. Konkurencja jest za to potrzebna do stworzenia alternatywnych dla symulowanego produktu, o odmiennych cechach i przyciągających klientów o specyficznych cha-

⁴⁰Ich istotność nie jest w tym momencie ważna, ponieważ nawet jeśli w zbiorze znajdzie się cecha mająca mały wpływ na decyzje konsumentów, zostanie ona wyeliminowana na etapie tworzenia modelu bądź drzewa klasyfikacyjnego ze względu na brak istotności statystycznej współczynnika

⁴¹Idealnym przykładem jest Redd's, wybierany głównie przez kobiety. Innymi mogą być Grolsch wybierany przez ludzi zamożnych, kiedy Wojak trafia do najgorzej zarabiających.

Tabela 3: Cechy charakteryzujące produkt w modelu. *Źródło:* opracowanie własne.

Cecha	Skala	Opis
Cena	1-5	Relatywna cena produktu
Smak	1-5	Relatywna jakość smaku produktu
Opakowanie	1-5	Relatywna atrakcyjność opakowania produktu
Premium	0-1	Czy produkt jest postrzegany jako marka premium?
Budżetowy	0-1	Czy produkt jest postrzegany jako marka budżetowa?
Lager	0-1	Czy produkt należy do piw typu lager?
Smakowe	0-1	Czy produkt należy do piw smakowych?
Marketing	0-5	Wysokość nakładów na marketing marki

rakterystykach, i jej rola ogranicza się do wprowadzenia go na rynek oraz zapewnienie dostaw do każdego ze sklepów.

3.5.5 Ścieżki i trasy dostaw

Klasa *trasy* przechowuje wszystkie możliwe kombinacje elementów grafu (ścieżki), zdefiniowanych w rozdziale 2.2.3, składające się z instancji klas *fabryka*, *magazyn*, *sklep* oraz *krawędzi* pomiędzy nimi ⁴². W przypadku złożonych grafów (czyli sytuacji, kiedy przedsiębiorstwo składa się z wielu jednostek) liczba kombinacji może uniemożliwić swobodne przetwarzanie klasy w pamięci komputera, jednak w takim wypadku można predefiniować zbiór możliwych łańcuchów, spośród których model będzie wybierał najbardziej optymalne trasy (zob. rozdział 2.4).

Dla każdej z tras, poza informacjami o jednostkach wchodzących w skład przedsiębiorstwa, przechowujemy także informację o *ścieżkach* pomiędzy jednostkami. Wynika to z faktu, że transporty pomiędzy poszczególnymi jednostkami także mogą doświad-

⁴²Jako ścieżkę rozumiemy sekwencję punktów z drogami, jakie trzeba przebyć od fabryki do magazynu i od magazynu do sklepu.

czać efektów skali,⁴³ a długość ścieżki bezpośrednio wpływa na koszt łańcucha — koszt wzrasta wraz z długością ścieżki.

3.6 Symulowanie decyzji konsumenckich

Jak wskazano na diagramie 4, podczas wizyty każdego z wirtualnych konsumentów w sklepie symulujemy jego decyzję co do zakupu towaru. Naszą intencją jest, aby decyzje konsumentów w modelu jak najbardziej przypominały decyzje klientów w analogicznych sytuacjach w świecie rzeczywistym⁴⁴.

Opierając się na Sagan (2011) (zob. rozdział 3.5.3), wiemy, że jesteśmy w stanie zdefiniować kluczowe cechy konsumenta i cechy marketingowe produktu jako zbiór zmiennych ilościowych. Wykorzystując to stwierdzenie, w grze eksperymentalnej przeprowadzonej na potrzeby pracy⁴⁵, poproszono uczestników o stwierdzenie, jakie produkty z dostępnej listy kupi klient o charakterystyce wylosowanej przez program. Po odpowiedzi udzielonej przez gracza, predefiniowane, jakościowe cechy produktu były transponowane na wartości liczbowe⁴⁶⁴⁷ i wraz z ilościowymi cechami klienta oraz zmienną binarną przechowującą informacje *kupił/niekupił* zapisywany na serwerze SQL.

W programie dane te służą do budowy drzewa klasyfikacyjnego, które — ponieważ dane cech agentów oraz dane z gry ekonomicznej są w identycznej formie — dla każdej kwerendy o klienta i produkt zwraca prawdopodobieństwo zakupu. Dla każdego agenta możemy zbudować listę prawdopodobieństw zakupu każdego z towarów dostępnego na rynku. Zastosowane podejście gwarantuje wysokie podobieństwo z wyborami realnych konsumentów ze względu na:

- wysoką liczbą rekordów istnieje duże prawdopodobieństwo, że istnieje zapis o decyzjach klienta o bardzo podobnej charakterystyce,

⁴³Przykładowo, pod kątem kosztów na produkt, transport 100 produktów może być bardziej opłacalny niż 10 ze względu na rozłożenie kosztów stałych na większą ilość produktów.

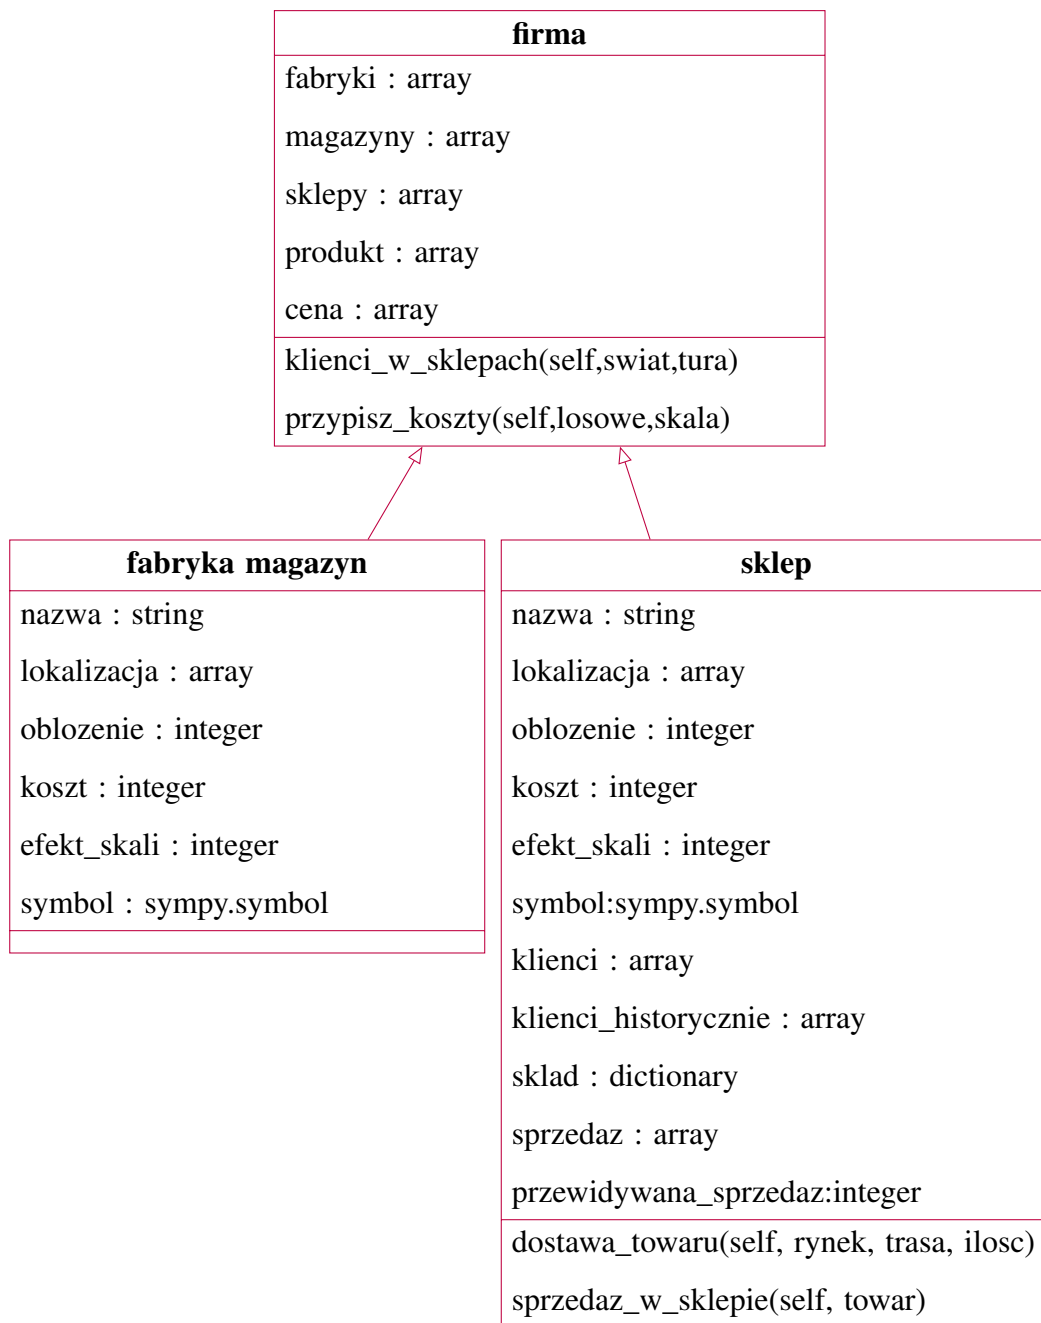
⁴⁴Warto odnotować, że to nie jest to samo co późniejsze przewidywanie "prognozowanej sprzedaży".

⁴⁵Gra dostępna jest pod adresem <http://serwer1418288.home.pl/test/piwo/zapisy.php>

⁴⁶Produkty obecne w ankiecie należą do jednego z większych koncernów browarniczych, a w celu zapewnienia realistycznego oddania cech produktów i preferencji klientów konstrukcja gry ekonomicznej była konsultowana z pracownikami wspomnianego koncernu.

⁴⁷Na przykład, piwo Grolsh jest drogie, klasy premium i jest lager, stąd otrzyma zapis [5,1,1], a tani smakowy Redd's [3,0,0].

- baza danych jest generowana przez decyzje ludzkie, zapewniając wysoką zgodność z analogicznymi wyborami w świecie rzeczywistym,
- wybór drzewa klasyfikacyjnego jako metody i duża ilość danych użytych do jego stworzenia, pozwala na bardzo bardzo dokładne odwzorowanie zbioru uczącego, które James et al. (2013) określa jako *overfit*.



Wykres 11: Diagram UML klasy firma, fabryka, magazyn oraz sklep *Źródło:*
opracowanie własne.

4 Efekty działania algorytmu optymalizacyjnego

Proponowany algorytm został zaimplementowany do modelu wieloagentowego symulującego przedsiębiorstwo i rynek. Wyniki działania algorytmu sugerują, że jego zastosowanie w przedsiębiorstwach pozwala na zwiększenie rentowności przez dostosowanie wolumenu dostaw do popytu w każdym ze sklepów, oraz minimalizacji kosztów dostaw.

4.1 Założenia modelu


Weryfikacja działania algorytmu odbywać się będzie w modelu stworzonym zgodnie z założeniami opisanymi w rozdziale 3.1, w oparciu o losowo wygenerowane środowisko działania modelu (*świat i rynek*). Właściwości środowiska modelu zostały opisane zostały opisane w w tabeli 4, a *mapy* powstałego w ten sposób środowiska zostały przedstawione na wykresach 12a i 12b.

Tabela 4: Założenia generowanego świata. *Źródło:* opracowanie własne.


Właściwość	Założenie
Populacja	2500
Wymiar x	60
Wymiar y	60
Udział dróg	0.3
Gęstość zakrętów dróg	0.05
Udział budynków mieszkalnych	0.6
Udział biurowców ⁴⁸	0.2
Udział przestrzeni komercyjnej ⁴⁹	0.2
Ilość fabryk	2
Ilość magazynów	2
Ilość ilość sklepów	4
Cena produktu	7

Konsumenci

Cechy konsumentów zostały wygenerowane zgodnie z rozkładami zawartymi w Naro-



(a) Mapa typów lokacji na mapie



(b) Histogram występowania konsumentów na mapie.

Wykres 12: Wygenerowane mapy środowiska modelu. *Źródło:* opracowanie własne.

dowym Spisie Ludności (Główny Urząd Statystyczny (2011)) oraz XI Ogólnopolskim Badaniu Wynagrodzeń Sedlak&Sedlak (2013) w celu zapewnienia spójności z rzeczywistą strukturą społeczną. Przykładowe histogramy cech klientów w rozważanym modelu zostały zaprezentowane na wykresie 14.

Jak zostało opisane w rozdziale 3.5.1, cechy klientów wpływają na ich decyzji konsumencie i wybór produktów w sklepie. Dlatego profil klienta konsumującego symulowany produkt (zob. tabela 6) będzie dystynktywny, tak jak w normalnych warunkach rynków różne marki przyciągają klientów o różnych profilach i cechach demograficznych. Właściwość tą wykorzystujemy do modelowania predyktywnego prawdopodobieństwa zakupu przy danej charakterystyce klienta w czasie $t + 1$. Porównanie rozkładów cech ogółu klientów i konsumentów marki zaprezentowano na wykresie 15.

Przedsiębiorstwo

Symulowane przedsiębiorstwo, zdefiniowane jak w rozdziale 2.2.3, zostało wygenerowane zgodnie z założeniami przedstawionymi w tabeli 4. Składa się z 2 fabryk, 2 magazynów i 4 sklepów, które wspólnie tworzą $\binom{2}{1} \times \binom{2}{1} \times \binom{4}{1} = 16$ możliwych ścieżek

w (zob. rozdział 2.2.3). Lokalizacje poszczególnych jednostek przedsiębiorstwa zostały zaprezentowane na rysunku 16.

Jak opisanano w rozdziale 3.1, każdy z j elementów przedsiębiorstwa oraz krawędzie d je łączące powiązane jest z funkcją kosztu f_j , które w celu symulacji efektów skali są nieliniowe. Dla fabryk, magazynów i sklepów zakładamy ujemne korzyści skali, podczas gdy dla transportu na krawędziach — dodatnie. Dokładne funkcje kosztów wykorzystane w modelu opisane są w tabeli 5.

Tabela 5: Założone w modelu funkcje kosztów. *Źródło:* opracowanie własne.

Jednostka	Symbol	Funkcja kosztu ⁵⁰
Fabryka	$fa \in FA$	$f_{fa} = 1.3 \times x_{fa}^{1.03}$
Magazyn	$ma \in MA$	$f_{ma} = 1.2 \times x_{ma}^{1.05}$
Sklep	$sk \in SK$	$f_{sk} = 1.1 \times x_{sk}^{1.07}$
Droga (krawędź)	$d \in D^{51}$	$f_d = 0.005 \times l_d \times x_d^{0.95}$

Produkty

W modelu zakładamy, że na rynku obecnych jest 7 marek piwa, z których jedno należy do symulowanego przez nas przedsiębiorstwa (produkt o nazwie **Symulowane**). Jak opisano w rozdziale 3.5.3, każde z piw zdefiniowane jest 7 zmiennymi marketingowymi, których wartości zostały wylosowane dla każdego z produktów na rynku. Cechy produktów zostały zaprezentowane w tabeli 6. Wyniki sprzedaży poszczególnych marek w jednostkach czasu t zaprezentowane są na wykresie 17.

Analiza wyników sprzedaży oraz cech produktu symulowanego przedsiębiorstwa pozwala zauważyć (zob. wykres 17, tabela 6), że piwo należące do symulowanego przez nas przedsiębiorstwa należy do jednych z najtańszych piw na rynku, jest piwem smakowym o przeciętnych walorach smakowych, ale za to intensywnych nakładach na marketing i dużej uwadze poświęconej projektowaniu opakowania. Skonfrontowanie tego z profilem klienta widocznym na wykresie 15 pozwala zrozumieć, dlaczego nabywcy naszego piwa należą do grupy gorzej sytuowanych finansowo, raczej młodszych ⁵², z dominującą grupą

⁵²Wynika to z połączenia faktów, że młode osoby mniej zarabiają, oraz piwa smakowe nie są zbyt popularne wśród starszych roczników

kobiet. Profil wykształcenia nie różni się znacząco od przeciętnej, z delikatnie mniejszym udziałem klientów o wyższym wykształceniu.

Tabela 6: Cechy symulowanych produktów.^{53 54} Źródło: opracowanie własne.

	Cena	Smak	Opakowanie	P	B	L	S	Marketing
Symulowane	1	3	5	0	0	0	1	4
Slaskie	4	4	2	1	0	1	0	4
Lebskie	4	2	2	1	0	0	1	5
Babskie	4	3	5	0	1	0	1	5
Pszczeniczne	2	2	2	0	0	0	1	2
Opolskie	4	3	5	0	0	0	1	4
Mocne	4	2	2	1	0	1	0	3

4.2 Przewidywanie decyzji konsumentów

Przewidywanie decyzji konsumentów odbywa się zgodnie z założeniami przedstawionymi w rozdziale 2.2.2.⁵⁵ Kolejne kroki prognozowania sprzedaży w każdym ze sklepów w czasie $t + 1$ to

1. Na podstawie historii transakcji obliczamy średnią ilość klientów n odwiedzających sklep w jednostce czasu t ,
2. Na podstawie historii cech klientów kupujących produkt, obliczamy prawdopodobieństwo warunkowe wystąpienia wszystkich zestawów cech, i losujemy cechy dla n klientów w $t + 1$,

⁵⁵W modelu stosowane jest pewne uproszczenie podczas prognozowania ilości klientów w sklepie w $t + 1$. Ponieważ wizyta klienta w sklepie jest w modelu zdarzeniem losowym (losuje się jedna z czterech lokalizacji docelowych), a model nie symuluje efektów zewnętrznych jak pogoda czy dzień tygodnia, do przewidywania liczby klientów odwiedzających sklep w chwili $t + 1$ stosowana jest po prostu średnia z ilości odwiedzin z poprzednich okresów. Brak jest bowiem zmiennych objaśniających które mogłyby zostać wykorzystane w modelu. Ich wprowadzenie dodawałoby niepotrzebną złożoność do modelu, a zastosowane uproszczenie nie ma wpływu na badanie wyników działania algorytmu.

3. Dla każdego z tak otrzymanych klientów na podstawie przeszłej historii wyborów klientów, wykorzystując metodę regresji logistycznej bądź klasyfikacji k -nearest neighbours, obliczamy prawdopodobieństwo zakupu produktu symulowanej firmy,
4. Kroki 1-3 powtarzamy założoną ilość razy ⁵⁶ i obliczamy średnią z trzech obserwacji.

Analizując wyniki prognozowania, przedstawione na wykresie 18 możemy zobserwować ciekawe różnice w skuteczności prognoz obu stosowanych metod — *regresji logistycznej* oraz *k-nearest neighbours*. Chociaż współczynnik determinacji R^2 jest wyższy dla metody regresji logistycznej ($R_{lg}^2 = 0,7912$) niż dla K-nearest neighbours ($R_{kn}^2 = 0,7591$), to ważnym aspektem działania regresji logistycznej jest nie przeszacowywanie sprzedaży (tak jak to robi K-nearest neighbours). Nadmierny optymizm metody K-nearest neighbours powoduje, że algorytm dostarcza do sklepów produkty o których wiemy, że nie zostaną sprzedane. Powoduje to ponoszenie niepotrzebnych koszty produkcji i transportu (zob. wykres 22).

Jak możemy to zaobserwować na wykresie 19, wynika to z faktu, że K-nearest neighbours dla współczynnika $k = 3$ ma większe trudności z jednoznacznym określeniem klasy przewidywanej zmiennej ⁵⁷ niż regresja logistyczna. Regresja logistyczna jest o wiele bardziej skłonna to przyporządkowania niskiego prawdopodobieństwa zakupu, jednak z większą pewnością określa klientów którzy kupią produkt. Tymczasem, K-nearest neighbours często wskazuje wartość prawdopodobieństwa w środku przedziału $(0, 1)$, co należy interpretować jako odpowiedź niejednoznaczną. Możliwe, że manipulacja współczynnikiem k wpłynęłaby zwracane przez metodę wartości prawdopodobieństwa, jednak w przypadku modelu za bardziej skuteczną będziemy uważać metodę regresji logistycznej.

4.3 Wpływ działania algorytmu na działanie przedsiębiorstwo

Po uruchomieniu programu przez $n = 20$ jednostek czasu t , przedsiębiorstwo podejmuje decyzje na podstawie predefiniowanych zasad opisanych w rozdziale 3.1 w celu uzyska-

⁵⁶W modelu przyjmujemy 3 iteracje prognoz z których obliczana jest średnia.

⁵⁷Warto przypomnieć, że w tym momencie modelujemy to, czy dany klient będzie w klasie 0 (*nie kupił*) czy 1 (*kupił*).

nia punktu odniesienia dla porównania wyników firmy. Po $n = 20$ jednostkach czasu, na podstawie dotychczas zebranych w modelowanych sklepach historiach transakcji, inicjalizowane są modele regresji logistycznej oraz K-nearest neighbours. Służą one służą do prognozowania sprzedaży w każdym ze sklepów w $t + 1$. Zgodnie z przyjętymi w rozdziale 2.2.3, wiedza o sprzedaży w każdym ze sklepów w $t + 1$ pozwala nam, po odpowiednich przekształceniach, zbudować algorytm optymalizujący procesy produkcyjno-logistyczne, przede wszystkim pod kątem alokacji wolumenów produkcji i tras dostaw pomiędzy poszczególne jednostki przedsiębiorstwa.

Alokacje na trasach dostaw (ścieżkach)

W rezultacie działania modelu otrzymujemy wektor A , który dla każdego elementu zbioru $w \in W$ (zob. rozdział 2.2.3) zawiera optymalny⁵⁸ wolumen dostaw w $t + 1$. Wektory otrzymane w toku działania modelu zostały zaprezentowane na w formie wykresu na rysunku 20.

Obserwując wolumeny dostaw na ścieżkach można zauważyć, że przedsiębiorstwo sterowane przez algorytm jest o wiele bardziej elastyczne co do wyboru ścieżek. Wskazuje wskazuje rosnąca po $t = 20$ wariancja wolumenów alokacji na poszczególnych ścieżkach. Ponadto, algorytm wielokrotnie decyduje się dostarczyć towar do sklepu z wielu źródeł. Biorąc pod uwagę, że funkcje kosztów są nieliniowe a we wszystkich jednostkach firmy występują negatywne efekty skali, pozwala to znaczące ograniczenie kosztów, których spadek widoczny jest na wykresie 22.

To o tyle istotna obserwacja, że w praktyce biznesowej podobne metody ograniczenia kosztów nie są szeroko stosowane. Wręcz przeciwnie, często pracownicy firmy podczas składania zamówień podejmują decyzje, które lokalnie wydają się im być najlepsze (np. zamawianie z najbliższego magazynu) lub też podyktowane stałymi regulacjami korporacyjnymi. Chociaż lokalnie dla pracowników firmy mogą one wydawać się racjonalne, z punktu widzenia całego systemu nie są optymalne. Obserwacje wyników działania algorytmu sugerują, że zastąpienie stałych zasad alokacji tras dostaw algorytmami optymalizacyjnymi może skutkować znaczącą redukcją kosztów dla przedsiębiorstw.

⁵⁸Zastrzeżenia wobec optymalności alokacji sugerowanych przez algorytm znalazły się w rozdziale 2.3

Przychody i koszty

Obserwacja przychodów, kosztów i zysków przedsiębiorstw w poszczególnych jednostkach czasu t , przedstawione odpowiednio na wykresach 22b oraz 22a, pozwala zauważyć, że działanie algorytmu wpłynęło *in plus* na wyniki firmy. Warto odnotować, że przedsiębiorstwo w początkowych turach miało stabilne koszty, które jak wspomniano w rozdziale 3.1, starano się minimalizować, zamawiając towary tylko z najbliższego magazynu, jednak negatywne wyniki finansowe były spowodowane przez okresowo spadające przychody.

Podążanie za predefiniowanymi zasadami alokacji tras dostaw opartych na racjonalnych kryteriach, które powodowały stabilność kosztów, pozornie stanowiły dobrą strategię. Nie była ona jednak skuteczna w obliczu dużej zmienności ilości klientów w sklepach, którą można zaobserwować na wykresie 18. Zyskowe okresy przeplatały się z nierentownym, a straty w niektórych okresach wynikały przede wszystkim z niepotrzebnie wysokich kosztów zamówień. Sugeruje to nieumiejętność dostosowania się do wysokiej zmienności wolumenu sprzedaży przy predefiniowanych zasadach składania zamówień. Dynamiczny algorytm, jak zaobserwowano w 4.3 jest bardziej elastyczny, dzięki czemu mógł lepiej dostosowywać się do popytu i odnotowywać zysk w każdej turze, niezależnie od wariancji przychodów. Warto zauważyć, że dzieje się to przede wszystkim przez dostosowanie wolumenu dostaw do popytu w każdym ze sklepów, ale także zamawianiu towarów z wielu źródeł — co przy negatywnych efektach skali powoduje spadek kosztu jednostkowego i większy margines marży.

Dodatkowo, gdyby zmienność sprzedaży nie była wywołana losowo, jak w modelu, ale zależna od serii czynników (pogoda, dzień tygodnia, etc), możliwe byłoby stworzenie modelu który wyłapywałby subtelne zmiany w tendencjach i potrafiłby dostosować do nich produkcję. Dobrym przykładem opisywanego algorytmu byłby model przewidujący sprzedaż lodów, który przy prognozie dobrej pogody zwiększałby zapasy, a przy ochłodzeniach reduktował produkcję. Zazwyczaj takie procesy koordynowane są przez ludzi, jednak duża liczba zmiennych oraz możliwa ich heterogeniczność (różna pogoda w różnych częściach Polski) powoduje, że pewne prognozy są zbyt złożone żebyśmy mogli je przewidywać z wysoką dokładnością bez metod matematycznych.

4.4 Podsumowanie i wnioski

Wyniki finansowe i operacyjne przedsiębiorstwa w symulowanym modelu agentowym uległy znaczącej poprawie po inicjalizacji algorytmu optymalizacyjnego. Chociaż prognoza sprzedaży obciążona jest pewnym błędem ($R^2 = 0,7912$), to w satysfakcjonujący sposób określa popyt w najbliższych jednostkach czasu t . Należy zaznaczyć, że modelowanie predykcyjne mogłoby być dokładniejsze gdyby nie założenia konstrukcji modelu, w których wizyta klienta w sklepie jest zdarzeniem losowym. Chociaż dla danego profilu klienta model potrafi z dużą dozą dokładności przewidzieć prawdopodobieństwo zakupu każdego z produktów, to trudno jest dokładnie przewidzieć ilość klientów odwiedzających sklep w $t + 1$ — szczególnie, że wartość tą cechuje wysoka wariancja.

Uzyskane wolumeny sprzedaży w każdym ze sklepów w przedsiębiorstwie zostały wykorzystane przez algorytm optymalizacyjny do optymalnej alokacji towarów na ścieżkach. Wykresy zysków, przychodów i kosztów wskazują na drastyczną poprawę wyników finansowych przedsiębiorstwa po inicjalizacji modelu. Spowodowane jest to przede wszystkim trzema aspektami działania algorytmu

1. Algorytm, posilając się danymi uzyskanymi w modelowaniu predykcyjnym, potrafi dostarczyć wolumeny zbliżone do rzeczywistej sprzedaży. Dzięki temu przedsiębiorstwo nie ponosi ani niepotrzebnych kosztów, ani nie występują utracone korzyści,
2. Algorytm potrafi skierować dostawy do miejsca docelowego z wielu źródeł. W przypadku, gdy w jednostkach przedsiębiorstwa występują negatywne bądź pozytywne efekty skali, pozwala to na optymalne rozłożenie wolumenów i zmniejszenie kosztu jednostkowego.
3. Nawet w sytuacji, gdy prognozowana sprzedaż jest wysoka, algorytm zaprzestaje dostaw na ścieżkach, które nie będą one opłacalne.


Warto zwrócić uwagę, że chociaż powyższe źródła oszczędności nie są wyrafinowane ani niemożliwe do zreplikowania za pomocą manualnego podejmowania decyzji, skala procesów logistycznych w dużych przedsiębiorstwach przekracza możliwości ludzkiej koordynacji. Ponadto, w dużych przedsiębiorstwach gdzie podejmowanie decyzji jest

zdecentralizowane, bardzo trudno pojedynczemu pracownikowi będzie dostrzec i zareagować na sytuacje podobne do opisanych w punktach 2. i 3.

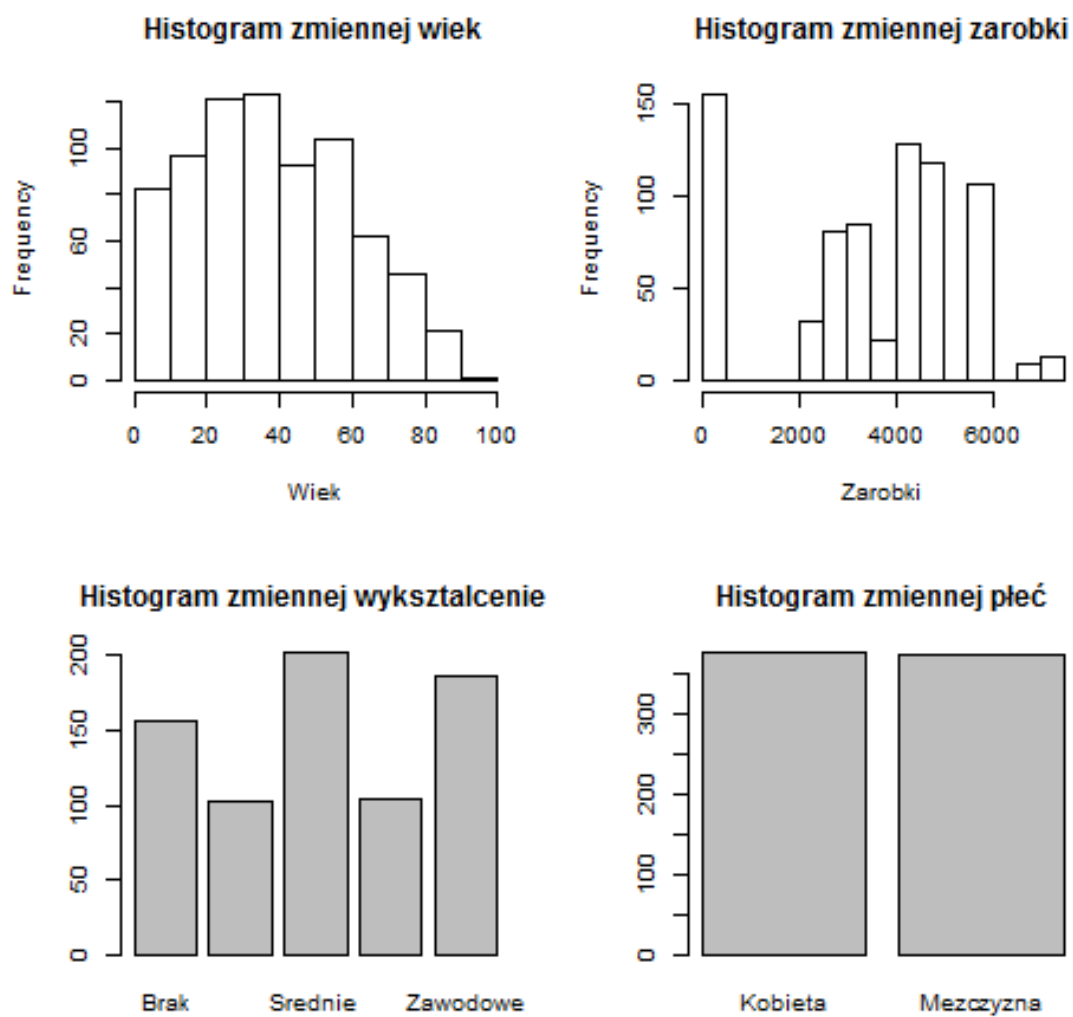
Co więcej, porównanie początkowych rund symulacji do pracy algorytmu daje ciekawe wnioski. Predefiniowane zasady podejmowania decyzji okazały się mniej skuteczne przede wszystkim przez brak elastyczności. Mimo stabilności wysokości kosztów i zabiegów służących ich minimalizacji, znaczącą wadą był brak możliwości reagowania na wariacje w sprzedaży. Ponieważ zasady podejmowania decyzji w początkowych rundach były oparte na praktykach rynkowych (tj. zamawianie wyłącznie z najbliższego magazynu, oraz zamawianie wolumenu podobnego do sprzedaży w ostatnich okresach), wyniki pracy sugerują, że należy zastępować sztywne regulaminy i zasady bardziej elastycznymi metodami zarządzania, możliwie wspieranymi komputerowo.

Biorąc pod uwagę powyższe, i obserwując wyniki finansowe na wykresie 22 potwierdza się hipoteza, że algorytm zadany w rozdziale 2.2.3 ma pozytywny wpływ na funkcjonowanie przedsiębiorstwa. Ponadto, symulacja przeprowadzona w modelu wieloagentowym pokazała duży potencjał redukcji kosztów, jaki jest możliwy w przedsiębiorstwach po wprowadzeniu opisywanego, albo podobnych, algorytmów do operacji biznesowych.

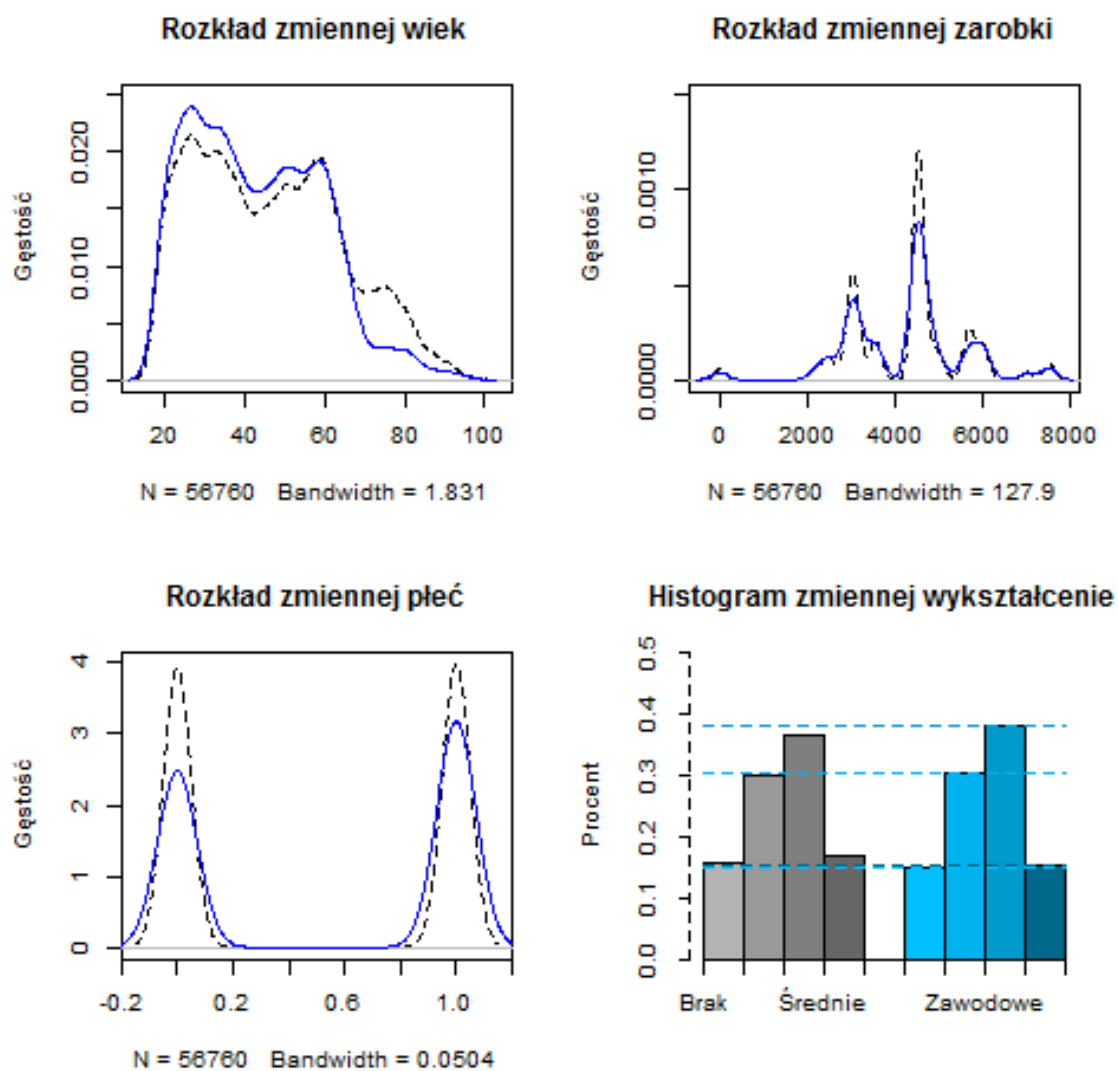
5 Dodatek: Dodatkowe wykresy



Wykres 13: Modelowane przedsiębiorstwo przedstawione jako graf kierunkowy *Źródło:* opracowanie własne.



Wykres 14: Histogramy cech agentów. Źródło: opracowanie własne.




Wykres 15: Cechy konsumentów marki w porównaniu do wszystkich agentów (czarny — ogół klientów, niebieski — dla klientów marki). Źródło: opracowanie własne.



Wykres 16: Mapa z zaznaczonymi lokalizacjami jednostek przedsiębiorstwa (szary — drogi, *pomarańczowy* — sklepy, *błękitny* – fabryki, *żółty* – fabryki).

Źródło: opracowanie własne.




Wykres 17: Statystyki sprzedaży marek symulowanych w modelu. Źródło: opracowanie własne.




Wykres 18: Przewidywana i realna sprzedaż w modelu (textitniebieski — regresja logistyczna, *czerwony* — K -nearest neighbours). Źródło: opracowanie własne.


Rozkład prawdopodobieństwa zakupu według metod prognozowania




Wykres 19: Rozkład prawdopodobieństwa zakupu w prognozach według metod prognoz. (*regresja logistyczna — niebieski, K-nearest neighbours — czerwony*) Źródło: opracowanie własne.



Wykres 20: Alokacje wolumenów dostaw wśród możliwych ścieżek. Prze-
rywana liniia oznacza inicjalizację działania modelu, kolory oznaczają różne
trasy. Źródło: opracowanie własne.




(a) Przychody i koszty symulowanego przedsiębiorstwa w symulacji z metodą prognozowania regresji logistycznej.




(b) Przychody i koszty symulowanego przedsiębiorstwa w symulacji z metodą prognozowania *K*-neareast neighbours.

Wykres 21: Wyniki finansowe symulowanego przedsiębiorstwa w zależności od metody prognozowania. Przerywana linia oznacza inicjalizację algorytmu (zielony — przychody, czerwony — koszty). Źródło: opracowanie własne.



(a) Zysk symulowanego przedsiębiorstwa z metodą prognozowania regresji logistycznej.



(b) Zysk symulowanego przedsiębiorstwa w symulacji z metodą prognozowania K -nearest neighbours.

Wykres 22: Zysk symulowanego przedsiębiorstwa w zależności od metody prognozowania. Przerywana linia oznacza inicjalizację algorytmu (*fioletowy* — zysk, *czerwony* — średni zysk przed implementacją algorytmu, *zielony* — średni zysk po implementacji algorytmu). Źródło: opracowanie własne.

Literatura

- Brynjolfsson, E., Hitt, L. M. i Kim, H. H. (2011), 'Strength in Numbers: How does data-driven decision-making affect firm performance?', *ICIS 2011 Proceedings* p. 18.
- Buckinx, W., Verstraeten, G. i den Poel, D. V. (2007), 'Predicting customer loyalty using the internal transactional database', *Expert Systems with Applications* **32**(1), 125 – 134.
URL: <http://www.sciencedirect.com/science/article/pii/S0957417405003143>
- Davenport, T., Dalle Mule, L. i Lucker, J. (2011), 'Know what your customers want before they do', *Harvard Business Review* .
- Frey, C. B. i Osborne, M. (2013), 'The future of employment: How susceptible are jobs to computerisation?', Online PDF.
URL: <http://www.oxfordmartin.ox.ac.uk/publications/view/1314>
- Główny Urząd Statystyczny (2011), Narodowy spis ludności 2011, Technical report, Główny Urząd Statystyczny.
- Hastie, T., Tibshirani, R. i Friedman, J. (2001), *The Elements of Statistical Learning*, Springer Series in Statistics, Springer New York Inc., New York, NY, USA.
- James, G., Witten, D., Hastie, T. i Tibshirani, R. (2013), *An Introduction to Statistical Learning with Applications in R*, Springer-Verlag New York.
- Kaminski, B. (2012), *Podejście wieloagentowe do modelowania rynków*, Oficyna Wydawnicza Szkoły Głównej Handlowej w Warszawie.
- Kawa, A. (2010), 'System wieloagentowy do budowania łańcuchów dostaw w branży komputerowej', *Zarządzanie Przedsiębiorstwem* **13**(1), 26–34.
- McKinsey Global Institute (2011), Big data: The next frontier for innovation, competition, and productivity, Technical report, McKinsey Global Institute.
- Moyaux, T., Chaib-Draa, B. i D'Amours, S. (2006), 'Supply chain management and multiagent systems: An overview', *Multiagent based Supply Chain Management* **4**, 1–27.

- Porter, M. E. (1985), *Competitive advantage: Creating and sustaining superior performance*, Free Press, New York and London.
- PwC (2014), CEO Survey 2014, Technical report.
- Sagan, A. (2011), 'Modele strukturalne w analizie zachowan konsumenta - ewolucja podejsc', *Konsumpcja i rozwoj*.
- Schelling, T. (1971), 'Dynamic models of segregation', *Journal of Mathematical Sociology*.
- Sedlak&Sedlak (2013), Xi ogolnopolskie badanie wynagrodzen 2013, Technical report, Sedlak&Sedlak.
- The Economist (2010), Data, data everywhere, Technical report.
- Wooldridge, M. i Jennings, N. R. (1995), 'Intelligent agents: theory and practice', *The Knowledge Engineering Review* **10**, 115–152.

Spis tablic

1	Zastosowane biblioteki języka Python	23
2	Warunki generowania mapy środowiska	25
3	Cechy charakteryzujące produkt w modelu	32
4	Właściwości generowanego świata	36
5	Założone w modelu funkcje kosztów	38
6	Cechy symulowanych produktów	39

Spis rysunków

1	Łańcuch dostaw w postaci grafu kierunkowego	8
2	Rozważane przedsiębiorstwo przedstawione jako graf kierunkowy	14
3	Proponowany algorytm optymalizacyjny	18
4	Struktura działania programu	24
5	Diagram UML klasy rynek	25
6	Diagram UML klasy swiat, lokalizacja i konsument	26
7	Przykładowa wygenerowana mapa	27
8	Algorytm wyszukiwania drogi	27
9	Diagram UML klasy konsument	29
10	Rozkłady zmiennych cech klasy konsument	30
11	Diagram UML klasy firma, fabryka, magazyn oraz sklep	35
12	Wygenerowane mapy środowiska modelu	37
13	Modelowane przedsiębiorstwo przedstawione jako graf kierunkowy	45
14	Histogramy cech agentów	46
15	Cechy konsumentów marki w porównaniu do wszystkich agentów	47
16	Mapa z zaznaczonymi lokalizacjami jednostek przedsiębiorstwa	48
17	Statystyki sprzedaży marek symulowanych w modelu	49
18	Przewidywana i realna sprzedaż w modelu	50
19	Rozkład prawdopodobieństwa zakupu w prognozach	51
20	Alokacje wolumenów dostaw wśród możliwych ścieżek	52
21	Wyniki finansowe symulowanego przedsiębiorstwa w zależności od metody prognozowania	53
22	Zysk symulowanego przedsiębiorstwa w zależności od metody prognozowania	54

Streszczenie

Celem pracy jest zaproponowanie heurystyki optymalizacji podejmowania decyzji w przedsiębiorstwie na podstawie modelowania predyktywnego. Proponowany algorytm optymalizuje alokację wolumenów dostaw na wszystkie możliwe trasy dostaw, posługując się prognozami popytu uzyskanymi na podstawie przeszłej historii transakcji.

W celu weryfikacji działania algorytmu zbudowany został model wieloagentowy, który symuluje lokalny rynek. Model w oparciu o lokalizację jednostek przedsiębiorstwa oraz konsumentów symuluje procesy logistyczny oraz decyzje konsumenckie.

Wyniki działania algorytmu w opisywanym modelu sugerują, że jego zastosowanie w przedsiębiorstwach pozwala na zwiększenie rentowności przez dostosowanie wolumenu dostaw do popytu w każdym ze sklepów, oraz minimalizacji kosztów dostaw.